

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Hệ thống gợi ý nhạc Việt theo cảm xúc và màu sắc
(Brightify)

HỌ VÀ TÊN SINH VIÊN

hoten.msv@sis.hust.edu.vn

Ngành (hoặc Chương trình đào tạo)

Giảng viên hướng dẫn: (Học hàm, học vị, Họ và tên GVHD)

Khoa/Viện: (Tên khoa/viện)

Trường: Công nghệ Thông tin và Truyền thông

HÀ NỘI, .../2026

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Hệ thống gợi ý nhạc Việt theo cảm xúc và màu sắc
(Brightify)

HỌ VÀ TÊN SINH VIÊN

hoten.msv@sis.hust.edu.vn

Ngành (hoặc Chương trình đào tạo)

Giảng viên hướng dẫn: (Học hàm, học vị, Họ và tên GVHD) _____

Chữ kí GVHD

Khoa/Viện: (Tên khoa/viện)

Trường: Công nghệ Thông tin và Truyền thông

HÀ NỘI, .../2026

LỜI CẢM ƠN

Lời cảm ơn của sinh viên (SV) tới người yêu, gia đình, bạn bè, thầy cô, và chính bản thân mình vì đã chăm chỉ và quyết tâm thực hiện ĐATN để đạt kết quả tốt nhất, nên viết phần cảm ơn ngắn gọn, tránh dùng các từ sáo rỗng, giới hạn trong khoảng 100-150 từ.

TÓM TẮT NỘI DUNG ĐỒ ÁN

Trên các nền tảng nhạc số hiện nay, khám phá nhạc chủ yếu dựa vào siêu dữ liệu hoặc lịch sử nghe, chỉ hiệu quả khi người nghe đã biết rõ mình muốn gì. Họ lại thường tìm nhạc theo cảm xúc nhưng rất khó gọi tên chính xác cảm xúc ấy. Các hướng hiện có hoặc phụ thuộc dữ liệu hành vi (gặp cold-start), hoặc dùng đặc trưng âm thanh thủ công nắm bắt cảm xúc yếu; các hệ gợi ý theo màu lại gắn với dữ liệu phương Tây và ánh xạ thủ công. Với nhạc Việt, chưa có tập dữ liệu cảm xúc được gán nhãn để huấn luyện trực tiếp.

Vì chọn một màu dễ hơn nhiều so với gọi tên cảm xúc, đồ án xây dựng Brightify với chức năng chính là gợi ý nhạc theo màu sắc, bổ sung gợi ý bài hát tương tự. Cả màu lẫn bài hát được quy về cùng không gian cảm xúc Valence–Arousal (mô hình Russell) — nơi màu và nhạc gặp nhau, do liên kết màu–nhạc được trung gian hóa bởi cảm xúc. Mỗi bài được gán sẵn tọa độ cảm xúc (Valence từ lời, Arousal từ mô hình âm thanh MuQ với nhịp độ và độ to); màu cũng được ánh xạ về không gian này qua chuẩn ICEAS và Whiteford. Hệ thống truy hồi các bài gần nhau về cảm xúc và bảo đảm nhất quán âm thanh.

Đóng góp chính gồm: quy trình gán cảm xúc cho nhạc Việt có cơ sở khoa học và tái lập được (không tinh chỉnh, phục vụ tất định); cơ chế gợi ý theo màu qua không gian cảm xúc dùng chung; và quy trình đánh giá nhiều tầng kèm khảo sát so sánh mô hình. Trên kho 5.138 bài hát, hệ thống vượt các phương pháp nền trên độ đo ngoại tuyến có kiểm định thống kê và kiểm chứng độc lập (nhịp độ thật, PMEmo, GPT). Do chưa có nghiên cứu nghe thực tế, các kết quả này là độ đo ngoại tuyến.

Sinh viên thực hiện
(Ký và ghi rõ họ tên)

MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI.....	1
1.1 Đặt vấn đề.....	1
1.2 Mục tiêu và phạm vi đề tài.....	2
1.3 Định hướng giải pháp.....	3
1.4 Đóng góp của đồ án	5
1.5 Bố cục đồ án	5
CHƯƠNG 2. KHẢO SÁT VÀ PHÂN TÍCH YÊU CẦU.....	6
2.1 Khảo sát hiện trạng	6
2.1.1 Các hệ thống gợi ý nhạc đang vận hành.....	6
2.1.2 Nghiên cứu nhận dạng cảm xúc trong âm nhạc	8
2.1.3 Liên kết màu sắc và âm nhạc.....	9
2.1.4 Bối cảnh và thách thức dữ liệu nhạc Việt.....	11
2.1.5 Đánh giá hệ gợi ý khi không có người dùng.....	11
2.2 Tác nhân và tổng quan chức năng	12
2.2.1 Các tác nhân của hệ thống.....	12
2.2.2 Biểu đồ use case tổng quát.....	13
2.3 Yêu cầu chức năng	15
2.4 Đặc tả chi tiết use case	16
2.5 Yêu cầu phi chức năng	21
CHƯƠNG 3. NỀN TẢNG LÝ THUYẾT VÀ CÔNG NGHỆ SỬ DỤNG.....	24
3.1 Mô hình cảm xúc Valence–Arousal	24
3.2 Cơ sở liên kết màu sắc với cảm xúc	27
3.3 Biểu diễn âm nhạc bằng học tự giám sát	30
3.4 Biểu diễn lời và cảm xúc văn bản tiếng Việt.....	32

3.5 Phương pháp tổ hợp, hậu xử lý và sắp xếp	35
3.6 Công cụ và nền tảng triển khai	38
3.7 Ánh xạ yêu cầu sang nền tảng	38
3.8 Phát biểu bài toán hình thức	39
CHƯƠNG 4. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG	41
4.1 Thiết kế kiến trúc	41
4.1.1 Kiến trúc tổng thể	41
4.1.2 Pha ngoại tuyến và luồng dữ liệu	41
4.1.3 Pha phục vụ và triển khai	42
4.1.4 Thiết kế lớp động cơ gợi ý	43
4.1.5 Mô hình dữ liệu kho đặc trưng	44
4.2 Thiết kế chi tiết hai chức năng cốt lõi	44
4.2.1 Gán tọa độ cảm xúc cho bài hát	44
4.2.2 Ánh xạ màu sắc sang tọa độ cảm xúc	46
4.2.3 Truy hồi, chấm điểm và sắp xếp	47
4.2.4 Ví dụ minh họa	50
CHƯƠNG 5. XÂY DỰNG VÀ TRIỂN KHAI HỆ THỐNG	51
5.1 Công cụ và mô hình sử dụng	51
5.2 Dữ liệu và kho nhạc	52
5.3 Giao diện lập trình ứng dụng	54
5.4 Giao diện người dùng	56
CHƯƠNG 6. THỬ NGHIỆM VÀ ĐÁNH GIÁ	59
6.1 Đánh giá thực nghiệm	59
6.1.1 Phương pháp và dữ liệu đánh giá	59
6.1.2 Đánh giá chức năng gợi ý theo màu	60
6.1.3 Đánh giá chức năng gợi ý bài tương tự	62

6.1.4 Khảo sát so sánh mô hình	65
6.1.5 Phân tích độ nhạy của trọng số	67
6.1.6 Bàn luận và mối đe dọa tính hợp lệ	69
6.2 Thời gian phản hồi và triển khai	72
6.2.1 Thời gian phản hồi đo được	72
6.3 Kiểm thử chức năng hệ thống	72
CHƯƠNG 7. CÁC GIẢI PHÁP VÀ ĐÓNG GÓP NỔI BẬT	75
7.1 Quy trình gán tọa độ cảm xúc cho nhạc Việt trong điều kiện thiếu nhãn	75
7.2 Cơ chế ánh xạ màu sắc sang nhạc qua không gian Valence–Arousal	76
7.3 Thuật toán truy hồi kết hợp khớp cảm xúc và nhất quán âm thanh	76
7.4 Quy trình đánh giá nhiều tầng và khảo sát so sánh mô hình	77
7.5 Hệ thống Brightify như một phần mềm demo hoàn chỉnh	78
7.6 Tổng hợp đóng góp và đối chiếu khoảng trống	79
CHƯƠNG 8. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	80
8.1 Kết luận	80
8.2 Hạn chế	81
8.3 Hướng phát triển	82
TÀI LIỆU THAM KHẢO	89

DANH MỤC HÌNH VẼ

Hình 1.1	Sơ đồ ý tưởng tổng quát của Brightify: màu sắc và bài hát được quy về cùng không gian cảm xúc Valence–Arousal, rồi truy hồi và sắp xếp thành danh sách gợi ý	4
Hình 2.1	Phân loại hệ gợi ý: lọc cộng tác phụ thuộc hành vi người dùng nên dễ gặp cold-start; Brightify đi theo hướng dựa trên nội dung . .	7
Hình 2.2	Biểu đồ use case tổng quát của hệ thống Brightify	14
Hình 2.3	Biểu đồ hoạt động của UC02 — gợi ý theo màu (rẽ nhánh một màu / hai màu)	18
Hình 3.1	Mô hình vòng tròn cảm xúc của Russell: bốn góc phần tư (Q1 vui–sôi nổi, Q2 căng–giận, Q3 buồn–u sầu, Q4 thư thái–bình yên) và tám nhãn cảm xúc hệ thống sử dụng	24
Hình 3.2	Bản đồ nhiệt liên kết màu–cảm xúc từ khảo sát ICEAS trên khoảng ba mươi quốc gia: mỗi ô là xác suất Bayes liên kết một cảm xúc (hàng) với một màu (cột); ô càng cam/đỏ đậm thì liên kết càng mạnh (Nguồn: Jonauskaite và cộng sự, 2020 [11])	29
Hình 3.3	Mặt phẳng màu Oklab ($a-b$) và hướng tăng của hai trục cảm xúc: Arousal tăng theo độ đỏ và độ bão hòa (Whiteford), Valence tăng theo độ sáng và giảm theo độ đỏ (ICEAS)	29
Hình 3.4	Sơ đồ khối sử dụng mô hình học tự giám sát âm nhạc: từ tín hiệu âm thanh tới vector biểu diễn 1024 chiều, dùng cho đo tương đồng và làm đặc trưng cho đầu dò cảm xúc	31
Hình 3.5	Kiến trúc mô hình MuQ: phổ Mel bị che một phần được Conformer dự đoán lại các token Mel-RVQ qua mục tiêu lượng tử hóa vector dư (Nguồn: Zhu và cộng sự, 2025 [10])	33
Hình 3.6	Ba loại tín hiệu văn bản: từ điển và đầu dò ngữ cảnh <i>dự đoán</i> Valence tuyệt đối (tổ hợp ở mục 3.5), còn embedding câu <i>so sánh</i> độ tương đồng nội dung lời	35
Hình 3.7	Tổ hợp đa phương thức: âm thanh, lời và màu sắc được quy về cùng trục Valence–Arousal rồi tổ hợp để truy hồi và xếp hạng . .	36
Hình 3.8	Hiện tượng dị hướng và hiệu ứng trừ trung bình: trước khi trừ, các vector dồn vào một nón hẹp nên cosine gần như bằng nhau; sau khi trừ trung bình, chúng trải rộng và cosine khôi phục khả năng phân biệt	37

Hình 4.1	Kiến trúc ba tầng của Brightify với phụ thuộc một chiều từ trên xuống	42
Hình 4.2	Luồng dữ liệu pha ngoại tuyến: trích đặc trưng song song, tổ hợp tọa độ cảm xúc, đóng gói bản phát hành phục vụ	42
Hình 4.3	Sơ đồ triển khai: trình duyệt $\leftrightarrow$ máy chủ FastAPI (giữ đặc trưng trong RAM); bản phát hành đặc trưng do máy trạm ngoại tuyến sinh ra	43
Hình 4.4	Sơ đồ gói: phụ thuộc một chiều giữa các thành phần mã nguồn	43
Hình 4.5	Sơ đồ lớp rút gọn: MusicRecommender điều phối và ủy thác hậu xử lý cho <code>core.ranking</code>	43
Hình 4.6	Lược đồ thực thể–quan hệ rút gọn của kho đặc trưng phục vụ .	44
Hình 4.7	Trọng số tổ hợp Valence theo độ tin cậy (EWE): ba tín hiệu lời chiếm phần lớn, tín hiệu âm thanh bổ trợ	45
Hình 4.8	Luồng ánh xạ màu sắc sang tọa độ Valence–Arousal	47
Hình 4.9	Sơ đồ tuần tự UC01 — gợi ý bài tương tự	49
Hình 4.10	Sơ đồ tuần tự UC02 — gợi ý theo màu	49
Hình 5.1	Quy trình thu thập dữ liệu tự động, không dùng dữ liệu người dùng	52
Hình 5.2	Phân bố cảm xúc của kho nhạc: trục Arousal nén hơn trục Valence	54
Hình 5.3	Màn chọn màu để gợi ý danh sách phát — giao diện “classic” 2D (UC02)	57
Hình 5.4	Màn kết quả danh sách phát theo màu (ví dụ tâm trạng “Ngọc”) (UC02, UC03)	57
Hình 5.5	Màn duyệt thư viện và chọn bài hát để tìm bài tương tự (UC01, UC03)	58
Hình 5.6	Màn kết quả bài tương tự ở chế độ “đài” nối tiếp (UC01, UC03)	58
Hình 6.1	So sánh TE của Brightify với các phương pháp nền (thấp hơn là tốt hơn); Brightify tiệm cận trần lý thuyết (oracle)	61
Hình 6.2	Trái: 12 màu kéo về các vùng cảm xúc khác nhau; Phải: mỗi cải tiến nâng độ tách biệt và độ nhất quán	62
Hình 6.3	Chuyển miền các đầu dò cảm xúc sang tập PMEmo độc lập (tương quan Spearman, kèm khoảng tin cậy)	65
Hình 6.4	Độ nhảy của trọng số nhịp độ: vùng xanh là cửa sổ hợp lệ ($\text{DEAM-CV} \geq 0.647$ và $\rho(A, \text{BPM}) \geq 0.20$); giá trị phục vụ 0.35 nằm trong vùng này	68

Hình 6.5	Độ nhạy của băng thông σ (RBF màu): TE gần như phẳng trên toàn lưới quét, xác nhận hệ bền với lựa chọn σ	68
Hình 6.6	Đánh đổi NDCG $\leftrightarrow$ MoodCoherence theo trọng số V-A: giá trị phục vụ 0.16 là điểm khuỷu — gần như toàn bộ lợi ích nhất quán cảm xúc đạt được với chi phí NDCG nhỏ	69
Hình 6.7	Thời gian phản hồi tính toán lỗi theo thao tác (thang log); truy vấn đơn ở mức vài mili-giây	73
Hình 7.1	Quy trình đánh giá nhiều tầng: mỗi tầng là một cấp kiểm chứng nghiêm ngặt hơn, trên cùng là cổng không thụt lùi quyết định việc chấp nhận thay đổi	77

DANH MỤC BẢNG BIỂU

Bảng 2.1	Khảo sát khả năng truy vấn theo cảm xúc/màu của các nền tảng nhạc số (đối chiếu định tính)	7
Bảng 2.2	Các tập dữ liệu cảm xúc nền (gán nhãn người) và vai trò trong đồ án	9
Bảng 2.3	So sánh các công trình màu→nhạc tiêu biểu với hệ thống đề xuất	10
Bảng 2.4	So sánh các hướng tiếp cận hiện có và hệ thống đề xuất	11
Bảng 2.5	Trách nhiệm chính của các tác nhân	13
Bảng 2.6	Danh sách use case của hệ thống	14
Bảng 2.7	Danh sách yêu cầu chức năng của hệ thống	15
Bảng 2.8	Đặc tả use case UC01 — Gợi ý bài tương tự	16
Bảng 2.9	Đặc tả use case UC02 — Gợi ý theo màu	17
Bảng 2.10	Đặc tả use case UC03 — Xem danh sách bài gợi ý	19
Bảng 2.11	Đặc tả use case UC04 — Xem thông tin cảm xúc bài hát	19
Bảng 2.12	Đặc tả use case UC05 — Cập nhật kho nhạc	20
Bảng 2.13	Đặc tả use case UC06 — Chạy lại pipeline trích đặc trưng	21
Bảng 2.14	Danh sách yêu cầu phi chức năng	22
Bảng 3.1	So sánh các mô hình biểu diễn cảm xúc và mức phù hợp với bài toán truy hồi	26
Bảng 3.2	Ba cơ sở khoa học dùng cho ánh xạ màu sang tọa độ cảm xúc	28
Bảng 3.3	So sánh hai mô hình học tự giám sát âm nhạc MERT và MuQ	32
Bảng 3.4	Bốn tín hiệu văn bản: ba tín hiệu dự đoán Valence tuyệt đối và một tín hiệu so sánh tương đồng lời	34
Bảng 3.5	Ánh xạ giữa yêu cầu của hệ thống và nền tảng lý thuyết/công nghệ	38
Bảng 4.1	Các tín hiệu Valence và vai trò trong tổ hợp EWE (trọng số tỉ lệ với độ tin cậy đo được của từng tín hiệu)	45
Bảng 5.1	Danh sách công cụ và mô hình chính	51
Bảng 5.2	Các tệp đặc trưng tính sẵn được pha phục vụ nạp lên	54
Bảng 5.3	Các endpoint cốt lõi của giao diện lập trình ứng dụng (toàn hệ thống có khoảng 22 endpoint)	55
Bảng 6.1	Sai số nhắm đích (TE) của hệ thống so với các phương pháp nền	60

Bảng 6.2	Ablation: mỗi cải tiến đóng góp vào tách biệt và nhất quán (12 màu, $top-k = 10$)	62
Bảng 6.3	Đồng thuận hai bộ chấm độc lập trên ground truth tương đồng âm nhạc (1.048 cặp)	64
Bảng 6.4	NDCG@10 trên danh sách phát biên tập kèm phương pháp nền (đọc kèm cảnh báo Dacrema)	64
Bảng 6.5	So sánh công bằng MuQ với MERT (mỗi backbone tối ưu trọng số riêng)	66
Bảng 6.6	Khảo sát so sánh mô hình trên năm vị trí (mô hình được chọn in đậm)	66
Bảng 6.7	Độ nhảy của trọng số V-A trong gợi ý bài tương tự (52 hạt giống ground truth tương đồng âm nhạc)	69
Bảng 6.8	Thời gian phản hồi tính toán lỗi (đo trong tiến trình, không gồm mạng)	72
Bảng 6.9	Các ca kiểm thử chức năng hệ thống	73
Bảng 7.1	Đối chiếu đóng góp của đề án với khoảng trống đã xác định	79
Bảng 8.1	Đối chiếu mục tiêu đề ra (mục 1.2) với mức đạt được	80

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Thuật ngữ	Ý nghĩa
API	Giao diện lập trình ứng dụng (Application Programming Interface)
BPM	Số nhịp trên phút — thước đo nhịp độ bản nhạc (Beats Per Minute)
CDF	Hàm phân phối tích lũy (Cumulative Distribution Function)
CLAP	Mô hình tương phản ngôn ngữ–âm thanh (Contrastive Language–Audio Pretraining)
DEAM	Tập dữ liệu cảm xúc âm nhạc có nhãn người, dùng cho hồi quy Arousal (Database for Emotional Analysis of Music)
EWE	Bộ ước lượng có trọng số theo độ tin cậy (Evaluator Weighted Estimator)
FDR	Tỉ lệ phát hiện sai (False Discovery Rate)
ICC	Hệ số tương quan nội lớp, đo độ tin cậy test–retest (Intraclass Correlation Coefficient)
ICEAS	Khảo sát liên kết màu sắc–cảm xúc quốc tế (Jonauskaitė và cộng sự, 2020)
JSON	Định dạng trao đổi dữ liệu dạng văn bản (JavaScript Object Notation)
KS	Kiểm định Kolmogorov–Smirnov so sánh hai phân bố
LLM	Mô hình ngôn ngữ lớn (Large Language Model)
LOO-CV	Kiểm chứng chéo bỏ-một-ra (Leave-One-Out Cross-Validation)

Thuật ngữ	Ý nghĩa
LUFS	Đơn vị đo độ to chuẩn hóa (Loudness Units relative to Full Scale)
MER	Nhận dạng cảm xúc trong âm nhạc (Music Emotion Recognition)
MERT	Mô hình hiểu âm nhạc tự giám sát (Music undERstanding model with large-scale Training)
MMR	Độ liên quan biên cực đại (Maximal Marginal Relevance)
MuQ	Mô hình biểu diễn âm nhạc tự giám sát dùng Mel Residual Vector Quantization (Zhu và cộng sự, 2025)
NDCG	Độ lợi tích lũy chiết khấu chuẩn hóa (Normalized Discounted Cumulative Gain)
NRC-VAD	Từ điển Valence–Arousal–Dominance của NRC (Mohammad, 2018)
Oklab	Không gian màu đồng đều theo tri giác (Ottosson, 2020)
PMemo	Tập dữ liệu cảm xúc âm nhạc dùng để kiểm chuyển miền (Popular Music Emotion dataset)
RBF	Hàm cơ sở bán kính (Radial Basis Function)
REST	Phong cách kiến trúc giao diện lập trình ứng dụng trên HTTP (Representational State Transfer)
RRF	Tổ hợp hạng nghịch đảo (Reciprocal Rank Fusion)
SPA	Ứng dụng trang đơn (Single-Page Application)

Thuật ngữ	Ý nghĩa
SSL	Học tự giám sát (Self-Supervised Learning)
TE	Sai số nhắm trúng đích trong không gian V-A (Targeting Error)
V-A	Valence–Arousal — hai trục (mức tích cực và mức năng lượng) của mô hình cảm xúc vòng tròn của Russell
ViSoBERT	Mô hình ngôn ngữ tiền huấn luyện cho mạng xã hội tiếng Việt (Nguyễn và cộng sự, 2023)
XLM-R	Mô hình ngôn ngữ đa ngữ RoBERTa (XLM-RoBERTa, Conneau và cộng sự, 2020)

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1 Đặt vấn đề

Âm nhạc số đã trở thành một phần thiết yếu của đời sống, kéo theo nhu cầu khám phá bài hát mới ngày càng lớn. Trên các nền tảng phổ biến, việc khám phá nhạc chủ yếu dựa trên siêu dữ liệu như nghệ sĩ, thể loại, hoặc dựa trên lịch sử nghe của người dùng. Cách làm này hoạt động tốt khi người nghe đã biết rõ mình muốn gì, nhưng lại tỏ ra hạn chế trong một tình huống rất phổ biến: người nghe muốn tìm nhạc theo *cảm xúc* hay *không khí* mà bài hát mang lại, chẳng hạn “một bài buồn và nhẹ nhàng” hoặc “những bài cùng cảm giác với bài đang nghe”.

Tuy nhiên, ở đây có một khó khăn ít được chú ý: người dùng thông thường rất khó gọi tên chính xác cảm xúc mà mình đang muốn. Hiếm ai diễn đạt rành mạch được rằng mình muốn nhạc “vui đến mức nào, lắng đến mức nào”; ranh giới giữa các nhãn như “buồn”, “u sầu”, “trầm lắng” hay “tâm trạng” vốn rất mờ và mang tính chủ quan, và bản thân việc dùng ngôn từ để mô tả một trạng thái cảm xúc đã là điều không dễ với phần lớn người nghe. Vì vậy, một giao diện buộc người dùng phải *nói ra* cảm xúc — chọn nhãn “vui/buồn” hay gõ từ khóa tâm trạng — thường tạo nhiều ma sát và không khớp với điều họ thực sự cảm thấy.

Màu sắc mở ra một lối diễn đạt khác, nhẹ nhàng hơn nhiều. Chọn một màu là thao tác trực giác và tức thì: người dùng chỉ cần chỉ vào gam màu mình “thấy hợp” mà không phải gọi tên cảm xúc hay tìm đúng từ ngữ. Lối vào này có cơ sở khoa học vững, bởi liên kết giữa màu sắc và âm nhạc ở con người không tùy tiện mà được *trung gian hóa bởi cảm xúc* với mức tương quan cao [1]: một màu và một bản nhạc “hợp nhau” khi chúng cùng gợi lên một trạng thái cảm xúc. Nói cách khác, màu sắc là cửa ngõ trực quan và ít ma sát để khám phá nhạc theo cảm xúc, không đòi hỏi người dùng phải tự “chẩn đoán” tâm trạng của mình. Đây chính là lý do đề án chọn **gợi ý nhạc theo màu sắc** làm chức năng đầu tiên và là điểm nhấn của hệ thống.

Để màu sắc và âm nhạc có thể “gặp nhau”, cả hai cần được đặt trên cùng một thước đo cảm xúc. Tâm lý học cho thấy cảm xúc con người có thể mô tả gọn trên hai trục Valence (mức dễ chịu, từ tiêu cực đến tích cực) và Arousal (mức năng lượng, từ trầm lắng đến sôi động) trong mô hình vòng tròn cảm xúc của Russell [2]; đây là không gian chung cho phép quy cả màu sắc lẫn bài hát về cùng một hệ tọa độ. Bên cạnh việc chọn nhạc theo màu, một nhu cầu phổ biến khác là “cho tôi những bài cho cảm giác giống bài đang nghe” — một yêu cầu về sự tương đồng cảm xúc và âm thanh chứ không phải về cùng nghệ sĩ. Đề án đáp ứng nhu cầu này

bằng chức năng thứ hai là **gợi ý bài hát tương tự**, cũng quy về chính không gian cảm xúc Valence–Arousal nói trên. Việc chọn nhạc theo tâm trạng, ở cả hai chức năng, phản ánh một hành vi điều tiết cảm xúc rất phổ biến: người ta dùng âm nhạc để duy trì, khuếch đại hoặc thay đổi trạng thái cảm xúc hiện tại.

Đối với kho nhạc tiếng Việt, bài toán có thêm khó khăn riêng. Trong phạm vi khảo sát của đề án, chưa tìm thấy một tập dữ liệu cảm xúc âm nhạc tiếng Việt được con người gán nhãn và công bố công khai để huấn luyện trực tiếp, trong khi các đặc trưng âm thanh thủ công lại nắm bắt Valence khá yếu. Cụ thể hơn, khoảng trống cần lấp gồm ba phần đan xen: (i) chưa có cơ chế gán *cảm xúc* có cơ sở khoa học cho nhạc Việt khi không có nhãn người; (ii) chưa có hệ thống hợp nhất việc truy vấn theo màu sắc và theo bài hát trên cùng một biểu diễn cảm xúc; và (iii) các hệ gợi ý theo màu hiện có lại gắn với dữ liệu phương Tây và ánh xạ màu bằng quy tắc thủ công. Vì vậy, việc gán cảm xúc có cơ sở khoa học cho nhạc Việt và xây dựng cơ chế gợi ý theo cảm xúc là một hướng đáng quan tâm, không chỉ phục vụ trải nghiệm nghe nhạc mà còn có thể áp dụng cho việc tạo danh sách phát theo tâm trạng hay các giao diện chọn nhạc bằng màu sắc.

Bài toán này càng đáng chú ý trong bối cảnh kho nhạc Việt trên các nền tảng số ngày càng lớn và đa dạng, trong khi công cụ khám phá theo cảm xúc dành riêng cho nhạc Việt vẫn còn hạn chế so với kho nhạc tiếng Anh. Người nghe nhạc Việt cũng có nhu cầu “tìm nhạc theo cảm giác” không kém người nghe nhạc quốc tế, nhưng lại ít được phục vụ bởi các công cụ phân tích cảm xúc phù hợp ngôn ngữ và văn hóa của mình. Một hệ thống gợi ý theo cảm xúc cho nhạc Việt, vì thế, vừa lấp một khoảng trống công cụ, vừa là một bài toán nghiên cứu thú vị: nó buộc phải giải quyết việc gán cảm xúc trong điều kiện thiếu dữ liệu nhãn bản địa — một tình huống điển hình của các ngôn ngữ ít tài nguyên — bằng cách kết hợp khéo léo nhiều nguồn tín hiệu sẵn có thay vì trông chờ một bộ dữ liệu lý tưởng. Chính sự kết hợp giữa giá trị ứng dụng (một cách khám phá nhạc trực quan, giàu cảm xúc) và thách thức khoa học (gán cảm xúc không cần nhãn người, hợp nhất nhiều phương thức trên một trục cảm xúc) làm nên động lực của đề án.

1.2 Mục tiêu và phạm vi đề tài

Hiện nay, các hệ thống gợi ý nhạc thương mại như Spotify chủ yếu khai thác lọc cộng tác (collaborative filtering) dựa trên hành vi người dùng, do đó cần lượng dữ liệu tương tác lớn và gặp khó với các bài hoặc người dùng mới — tức bài toán *cold-start* [3]. Một số nghiên cứu về nhận dạng cảm xúc trong âm nhạc đã đạt kết quả tốt trên các tập dữ liệu tiếng Anh như DEAM [4] hay PMEmo [5], nhưng chưa có lời giải tương ứng cho nhạc Việt; còn các hệ thống gợi ý nhạc theo màu hiện có

thì gắn với dữ liệu phương Tây và thường ánh xạ màu bằng quy tắc thủ công [6], [7]. Như vậy, hạn chế chính hiện nay là: thiếu một cơ chế gợi ý nhạc Việt dựa trên cảm xúc, không phụ thuộc dữ liệu người dùng, hợp nhất truy vấn theo bài hát và theo màu trên một không gian cảm xúc học được dùng chung, và có cơ sở khoa học rõ ràng cho từng thành phần.


Trên cơ sở đó, đề án hướng tới xây dựng hệ thống Brightify với hai chức năng chính. Thứ nhất là **gợi ý nhạc theo màu sắc**: cho một (hoặc hai) màu, hệ thống trả về một danh sách bài hát có cảm xúc tương ứng với màu đó và nghe đồng nhất với nhau. Thứ hai là **gợi ý bài hát tương tự**: cho một bài hát, hệ thống trả về các bài “nghe giống nhau” về âm thanh và cùng cảm xúc.

Hai chức năng này được cụ thể hóa thành các mục tiêu có thể kiểm chứng: (i) gán được tọa độ cảm xúc Valence–Arousal cho toàn bộ kho nhạc một cách tái lập được và có nguồn gốc khoa học; (ii) ánh xạ được màu sắc về cùng không gian cảm xúc và truy hồi được danh sách phát khớp cảm xúc, vượt các phương pháp nền (baseline) hợp lý trên độ đo ngoại tuyến; (iii) bảo đảm các bài trong một kết quả gợi ý nghe đồng nhất với nhau; và (iv) đạt thời gian phản hồi đủ thấp để dùng tương tác. Mức độ đạt được của từng mục tiêu được đo định lượng ở Chương 6.

Để tránh hiểu lầm về quy mô, đề án xác định rõ phạm vi. Các nội dung *nằm trong* phạm vi gồm: hai chức năng cốt lõi nêu trên; quy trình gán tọa độ cảm xúc Valence–Arousal cho toàn bộ kho nhạc; cơ chế ánh xạ màu sắc về cùng không gian cảm xúc; và một quy trình đánh giá ngoại tuyến có kiểm định thống kê. Các nội dung *ngoài* phạm vi gồm: cá nhân hóa theo hồ sơ người dùng và học từ phản hồi (vì đề án chủ trương không dùng dữ liệu người dùng), việc triển khai ở quy mô sản phẩm thương mại, và nghiên cứu nghe có sự tham gia của người thật ở quy mô lớn. Một số chức năng phụ trợ (tìm kiếm, phát nhạc và quản lý hàng đợi, nghe crossfade, duyệt thư viện, hướng dẫn sử dụng) được hiện thực để hệ thống chạy được như một phần mềm demo hoàn chỉnh nhưng không phải trọng tâm khoa học; các yêu cầu liên quan được liệt kê trong bảng yêu cầu chức năng (mục 2.3). Phần trình bày chi tiết về giải pháp và đóng góp được dành cho Chương 7.

1.3 Định hướng giải pháp

Đề án giải quyết bài toán theo hướng *gợi ý dựa trên nội dung* (content-based) [8] — phân tích trực tiếp nội dung bài hát (âm thanh, lời) thay vì hành vi người dùng, nhờ đó tránh được bài toán cold-start — quy mọi đối tượng về cùng một không gian cảm xúc Valence–Arousal [2], kết hợp các mô hình học sâu tự giám sát ở dạng đóng băng (frozen) và đầu dò tuyến tính (linear probe), thay vì tinh chỉnh (fine-tuning) hay dùng dữ liệu người dùng. Lựa chọn này xuất phát từ ràng buộc



Hình 1.1: Sơ đồ ý tưởng tổng quát của Brightify: màu sắc và bài hát được quy về cùng không gian cảm xúc Valence–Arousal, rồi truy hồi và sắp xếp thành danh sách gợi ý

thực tế (không có dữ liệu cảm xúc nhạc Việt để huấn luyện) và từ bằng chứng cho thấy đầu dò tuyến tính trên đặc trưng đóng băng có thể tổng quát hóa tốt hơn tinh chỉnh khi dữ liệu đích lệch miền [9].

Ý tưởng cốt lõi được minh họa trong Hình 1.1: cả *màu sắc* và *bài hát* đều được đưa về cùng một mặt phẳng cảm xúc Valence–Arousal, nhờ đó hai loại truy vấn vốn rất khác nhau (một màu, hay một bài hát mẫu) được quy về cùng một thao tác là truy hồi các điểm lân cận trên mặt phẳng đó, rồi sắp xếp lại để bảo đảm vừa khớp cảm xúc vừa nghe đồng nhất.

Giải pháp của đề án gồm ba khối. Khối thứ nhất gán tọa độ cảm xúc cho từng bài hát: Valence từ tổ hợp tín hiệu lời, Arousal từ đặc trưng âm thanh của mô hình MuQ [10] kết hợp nhịp độ và độ to. Khối thứ hai ánh xạ màu sắc về cùng không gian cảm xúc dựa trên chuẩn ICEAS [11] và quan hệ màu–nhạc của Whiteford [12]. Khối thứ ba truy hồi, sắp xếp và tinh chỉnh kết quả để bảo đảm vừa khớp cảm xúc vừa nhất quán âm thanh. Việc kết hợp ba nguồn tín hiệu khác phương thức — âm thanh, lời và màu sắc — trên cùng trục cảm xúc chính là một dạng *tổ hợp đa phương thức* (multimodal fusion), thay cho việc chỉ dựa vào một kênh duy nhất.

Hai lựa chọn nền tảng trong định hướng này cần được nói rõ vì chúng chi phối toàn bộ thiết kế. Lựa chọn thứ nhất là *dùng mô hình đóng băng kèm đầu dò tuyến tính* thay vì tinh chỉnh. Khi dữ liệu đích vừa ít vừa lệch miền (nhạc Việt so với các tập huấn luyện phương Tây), tinh chỉnh toàn bộ mô hình dễ làm hỏng các đặc trưng tổng quát đã học được và quá khớp vào tập nhỏ, trong khi một đầu dò tuyến tính trên đặc trưng đóng băng giữ nguyên sức mạnh biểu diễn sẵn có và chỉ học phần ánh xạ cuối cùng, nhờ đó tổng quát hóa tốt hơn [9]. Lựa chọn thứ hai là *dồn toàn bộ tính toán nặng về pha ngoại tuyến*: mọi tọa độ cảm xúc được tính sẵn và đóng băng thành bảng tra cứu, nên khi phục vụ hệ thống chỉ thực hiện tra cứu và các phép đại số tuyến tính, không suy luận bất kỳ mô hình nào (kể cả mô hình ngôn ngữ lớn). Nhờ vậy hệ thống vừa nhanh (đáp ứng ở mức mili-giây), vừa tắt định và tái lập được — những tính chất quan trọng để bảo vệ tính khoa học của đề án. Cần

nói rõ phạm vi của khẳng định này: mô hình ngôn ngữ lớn *không* tham gia vào đường phục vụ, mà chỉ đóng vai trò một bộ tham chiếu độc lập ở khâu đánh giá (Chương 6). Hai lựa chọn này biến các ràng buộc (thiếu nhãn, không dữ liệu người dùng) thành nguyên tắc thiết kế nhất quán, và là sợi chỉ xuyên suốt các chương sau.

1.4 Đóng góp của đề án

Trên cơ sở định hướng đó, đề án đạt được năm đóng góp chính, được phân tích chi tiết trong Chương 7 và chỉ tóm lược ở đây để người đọc nắm được bức tranh tổng thể. Thứ nhất, một quy trình gắn cảm xúc cho nhạc Việt hoàn toàn có nguồn gốc khoa học và *tái lập được*, hoạt động trong điều kiện không có nhãn người — không tinh chỉnh mô hình và không suy luận mô hình nào khi phục vụ (nhãn được tính sẵn, đóng băng thành bảng tra cứu). Thứ hai, một cơ chế gợi ý theo màu dựa trên cảm xúc, đưa màu và nhạc về cùng một không gian Valence–Arousal. Thứ ba, một thuật toán truy hồi kết hợp khớp cảm xúc với bảo đảm nhất quán âm thanh, khắc phục hiện tượng thiên lệch dị hướng của biểu diễn học sâu. Thứ tư, một quy trình đánh giá nhiều tầng kèm khảo sát so sánh mô hình, trong đó mỗi thành phần học máy được kiểm chứng là lựa chọn tốt theo độ đo cuối trong phạm vi các ứng viên đã khảo sát. Thứ năm, một hệ thống demo hoàn chỉnh có thời gian phản hồi ở mức vài mili-giây, minh họa hai chức năng cốt lõi như một phần mềm chạy được hoàn chỉnh ở mức nguyên mẫu nghiên cứu.

1.5 Bố cục đề án

Phần còn lại của báo cáo được tổ chức như sau. Chương 2 khảo sát hiện trạng các hệ thống gợi ý nhạc và các nghiên cứu liên quan đến cảm xúc trong âm nhạc và màu sắc, từ đó rút ra các yêu cầu chức năng và phi chức năng cho hệ thống. Chương 3 trình bày các nền tảng lý thuyết và công nghệ được sử dụng, bao gồm mô hình cảm xúc Valence–Arousal, các mô hình biểu diễn âm nhạc và ngôn ngữ, các từ điển và tập dữ liệu cảm xúc, cùng lý do lựa chọn từng thành phần. Chương 4 trình bày kiến trúc và thiết kế chi tiết của hai chức năng cốt lõi; Chương 5 trình bày quá trình xây dựng và triển khai hệ thống; Chương 6 trình bày phần thử nghiệm và đánh giá thực nghiệm. Chương 7 phân tích sâu các giải pháp và đóng góp nổi bật mà đề án đạt được. Cuối cùng, Chương 8 tổng kết kết quả, nêu các hạn chế còn tồn tại và đề xuất hướng phát triển.

CHƯƠNG 2. KHẢO SÁT VÀ PHÂN TÍCH YÊU CẦU


Chương 1 đã giới thiệu bài toán gợi ý nhạc Việt theo cảm xúc và theo màu sắc. Chương này khảo sát hiện trạng các hệ thống và nghiên cứu liên quan, rút ra khoảng trống mà đề án nhắm tới, sau đó phân tích yêu cầu của hệ thống Brightify dưới dạng các tác nhân, các use case chính kèm đặc tả chi tiết, và các yêu cầu chức năng cũng như phi chức năng.

2.1 Khảo sát hiện trạng

Khảo sát được tiến hành trên ba luồng hỗ trợ cho nhau: các hệ thống gợi ý nhạc đang vận hành, các nghiên cứu nhận dạng cảm xúc trong âm nhạc, và các nghiên cứu liên kết màu sắc với âm nhạc. Mỗi luồng làm rõ một mặt của bài toán và cùng nhau chỉ ra khoảng trống mà đề án nhắm tới.

2.1.1 Các hệ thống gợi ý nhạc đang vận hành

Các nền tảng nhạc số phổ biến như Spotify, Apple Music hay các dịch vụ trong nước chủ yếu dựa trên lọc cộng tác (collaborative filtering) và siêu dữ liệu (nghệ sĩ, thể loại, lịch sử nghe). Nhìn rộng hơn, các hệ gợi ý thường được phân thành ba nhóm [8]: *lọc cộng tác* học từ hành vi người dùng, *gợi ý dựa trên nội dung* (content-based) phân tích trực tiếp đặc trưng của vật phẩm, và hệ *lai* (hybrid) kết hợp cả hai [13] (Hình 2.1). Ưu điểm của hướng lọc cộng tác là cá nhân hóa tốt khi có nhiều dữ liệu tương tác: hệ thống học từ hành vi của hàng triệu người dùng để dự đoán sở thích. Tuy nhiên hướng này có ba nhược điểm cố hữu với bài toán của đề án. Thứ nhất, nó *phụ thuộc dữ liệu người dùng*, vốn nhạy cảm về quyền riêng tư và không phải lúc nào cũng sẵn có. Thứ hai, nó gặp vấn đề *cold-start* [3] với bài hát hoặc người dùng mới chưa có lịch sử tương tác. Thứ ba, và quan trọng nhất, nó *không cho phép truy vấn trực tiếp theo cảm xúc hay theo màu sắc*: người nghe không thể nói “cho tôi nhạc mang sắc xanh trầm” mà chỉ có thể chờ hệ thống suy ra sở thích từ hành vi quá khứ. Đây chính là khoảng trống về trải nghiệm mà đề án muốn lấp; Brightify chọn hướng *dựa trên nội dung* để vừa cho phép truy vấn theo cảm xúc/màu, vừa tránh phụ thuộc dữ liệu hành vi và bài toán cold-start. Bảng 2.1 đối chiếu các nền tảng nhạc số phổ biến với Brightify theo khả năng truy vấn cảm xúc/màu và mức phụ thuộc dữ liệu người dùng.



Hình 2.1: Phân loại hệ gợi ý: lọc cộng tác phụ thuộc hành vi người dùng nên dễ gặp cold-start; Brightify đi theo hướng dựa trên nội dung

Bảng 2.1: Khảo sát khả năng truy vấn theo cảm xúc/màu của các nền tảng nhạc số (đối chiếu định tính)

Nền tảng	Cơ chế gợi ý chính	Truy vấn cảm xúc	Truy vấn màu	Phụ thuộc dữ liệu người dùng
Spotify, Apple Music	Lọc cộng tác + biên tập + đặc trưng âm thanh	Danh sách phát tâm trạng biên tập	Không	Cao
YouTube Music	Lọc cộng tác + lịch sử xem	Hạn chế	Không	Cao
Zing MP3, NhạcCuaTui	Lọc cộng tác + bảng xếp hạng + biên tập	Hạn chế	Không	Cao
Brightify	Dựa trên nội dung trên trục V-A	Có (theo cảm xúc)	Có	Không

Bài toán cold-start thực ra có ba dạng [3]: *người dùng mới* (chưa có lịch sử để suy sở thích), *vật phẩm mới* (bài hát mới chưa ai nghe nên lọc cộng tác không có tín hiệu tương tác), và *hệ thống mới* (toàn bộ nền tảng chưa tích lũy dữ liệu hành vi). Lọc cộng tác bất lực với cả ba dạng vì nó hoàn toàn dựa trên ma trận tương tác người dùng–vật phẩm. Ngược lại, gợi ý dựa trên nội dung miễn nhiệm với cold-start *vật phẩm* và *hệ thống*, vì nó chấm điểm dựa trên đặc trưng nội tại của bài hát (âm thanh, lời, cảm xúc) chứ không cần bất kỳ lịch sử nghe nào — một bài vừa được thêm vào kho có thể được gợi ý ngay sau khi đặc trưng của nó được trích. Đây là lý do nền tảng để đề án chọn hướng nội dung: nó phù hợp với bối cảnh không có dữ liệu người dùng và một kho nhạc tự thu thập có thể liên tục mở rộng.

Cần khách quan nhìn nhận rằng hướng dựa trên nội dung cũng có những đánh đổi riêng. Vì chỉ dựa vào đặc trưng nội tại của bài hát, nó dễ *quá chuyên biệt* (over-specialization): kết quả có xu hướng giống bài gốc và ít bất ngờ thú vị (serendipity) hơn so với lọc cộng tác, vốn khai thác được các liên kết kiểu “người thích A cũng thích B” bất kể A và B có giống nhau về nội dung hay không. Ngoài ra, chất lượng gợi ý phụ thuộc trực tiếp vào chất lượng đặc trưng trích được: nếu biểu diễn âm thanh hay tín hiệu cảm xúc nghèo nàn thì kết quả cũng kém theo. Đồ án chấp nhận các đánh đổi này vì chúng phù hợp với mục tiêu (cho phép truy vấn theo cảm xúc và màu, không cần dữ liệu người dùng), và bù lại bằng cách đầu tư mạnh vào chất lượng đặc trưng — mô hình tự giám sát mạnh cho âm thanh, tổ hợp nhiều tín hiệu cho cảm xúc — đúng phần mà hướng nội dung có thể kiểm soát được. Sự đánh đổi giữa các hướng tiếp cận được tóm tắt ở Bảng 2.4 phía dưới.

2.1.2 Nghiên cứu nhận dạng cảm xúc trong âm nhạc

Bài toán nhận dạng cảm xúc trong âm nhạc (Music Emotion Recognition, MER) [14] đã được nghiên cứu nhiều trên các tập dữ liệu tiếng Anh được con người gán nhãn như DEAM [4] và PMemo [5], thường biểu diễn cảm xúc trên không gian Valence–Arousal [2]. Các nghiên cứu này cho thấy Arousal (mức năng lượng) dễ dự đoán từ đặc trưng âm thanh hơn Valence (mức tích cực), vì Valence gắn nhiều với nội dung ngữ nghĩa của lời hơn là với âm sắc. Khảo sát xuyên văn hóa gần đây cho thấy cấu trúc Valence–Arousal khá ổn định giữa các nền văn hóa, dù các nhãn cảm xúc cụ thể vẫn phân kỳ theo ngôn ngữ [15] — điều này vừa ủng hộ việc dùng V-A làm trục chung, vừa cho thấy cần một xử lý riêng cho tiếng Việt. Về phương pháp, các nghiên cứu MER ban đầu dùng đặc trưng âm thanh thủ công (MFCC, chroma, tempo, đặc trưng phổ) kết hợp hồi quy hoặc phân loại; gần đây chuyển sang đặc trưng học sâu, đặc biệt là các mô hình học tự giám sát trên lượng lớn nhạc không nhãn (xem Chương 3). Một phát hiện nhất quán xuyên các nghiên cứu là *Valence khó dự đoán từ âm thanh hơn Arousal*: Arousal gắn chặt với các thuộc tính âm thanh đo được (nhịp độ, độ to, năng lượng phổ) nên dễ hồi quy, trong khi Valence phụ thuộc nhiều vào ngữ nghĩa và bối cảnh văn hóa của lời, vốn không hiện diện đầy đủ trong tín hiệu âm thanh. Quan sát này định hướng trực tiếp thiết kế của đồ án: tách hai trục và suy Valence chủ yếu từ lời, Arousal chủ yếu từ âm thanh (mục 4.2.1).

Về mặt phương pháp, lĩnh vực MER đã trải qua một sự dịch chuyển đáng chú ý. Thế hệ đầu dựa vào *đặc trưng âm thanh thủ công* (MFCC mô tả âm sắc, chroma mô tả hòa âm, cùng các thống kê về nhịp độ, độ to và năng lượng phổ) đưa vào các mô hình hồi quy hoặc phân loại cổ điển; cách này minh bạch nhưng bị giới hạn bởi chất lượng của đặc trưng được thiết kế tay. Thế hệ tiếp theo dùng mạng học

sâu huấn luyện đầu cuối, đạt độ chính xác cao hơn nhưng đòi hỏi lượng lớn dữ liệu gán nhãn — điều khó đáp ứng với MER, nơi nhãn cảm xúc do con người chấm rất tốn kém. Gần đây nhất, hướng *học tự giám sát* tiền huấn luyện trên lượng lớn nhạc không nhãn rồi gán một đầu dò nhẹ phía trên đã trở thành cách tiếp cận chủ đạo, vì nó kế thừa được sức mạnh biểu diễn của học sâu mà không cần nhiều nhãn. Đồ án đi theo đúng hướng hiện đại này: dùng một mô hình tự giám sát đóng băng làm bộ trích đặc trưng và chỉ huấn luyện một đầu dò tuyến tính (chi tiết ở Chương 3), một lựa chọn đặc biệt phù hợp khi dữ liệu nhãn khan hiếm như với nhạc Việt.

Đáng chú ý, trong phạm vi khảo sát của đồ án, chưa tìm thấy tập dữ liệu cảm xúc âm nhạc *tiếng Việt* được con người gán nhãn và công bố công khai; các tài nguyên cảm xúc tiếng Việt hiện có chủ yếu là văn bản mạng xã hội, không phải nhạc. Đây là khoảng trống về dữ liệu buộc đồ án phải tìm cách gán cảm xúc mà không dựa vào nhãn người bản địa. Bảng 2.2 tóm tắt các tập dữ liệu cảm xúc nền mà đồ án dùng để hiệu chỉnh và kiểm chứng, đồng thời cho thấy rõ khoảng trống dữ liệu tiếng Việt.

Bảng 2.2: Các tập dữ liệu cảm xúc nền (gán nhãn người) và vai trò trong đồ án

Tập dữ liệu	Loại dữ liệu	Cỡ	Nhãn	Vai trò trong đồ án
DEAM [4]	Nhạc (Tây)	1.802 bài	V-A liên tục	Huấn luyện đầu dò Arousal
PMEmo [5]	Nhạc, đoạn chorus (Tây)	794 bài	V-A động	Kiểm chứng chuyển miền (domain transfer)
EmoBank [16]	Văn bản (Anh)	≈10.000 câu	V-A-D	Huấn luyện đầu dò Valence liên ngữ
Nhạc Việt gán nhãn	Nhạc (Việt)	<i>không tồn tại</i>	—	Khoảng trống ⇒ EWE không nhãn

2.1.3 Liên kết màu sắc và âm nhạc

Hướng liên kết màu–âm nhạc không phải ý tưởng hoàn toàn mới. Quan hệ màu–âm nhạc ở con người đã được chứng minh là *trung gian hóa bởi cảm xúc* với mức

tương quan rất cao [1], [12], dựa trên các chuẩn liên kết màu–cảm xúc xuyên văn hóa [11]; rộng hơn, đây là một trường hợp của *tương ứng đa giác quan* (crossmodal correspondence) giữa thị giác và thính giác [17]; đã có tập dữ liệu gắn màu, cảm xúc và nhạc trên cùng mô hình V-A phục vụ truy hồi theo cảm xúc [6]; và đã có hệ thống gợi ý nhạc từ màu [7]. Cơ chế đằng sau liên kết màu–nhạc đáng được nhấn mạnh: nghiên cứu của Palmer và cộng sự [1] cho thấy khi người nghe được yêu cầu chọn màu “hợp” với một đoạn nhạc, lựa chọn của họ tương quan rất cao với *cảm xúc* mà cả màu lẫn nhạc gợi lên — nghĩa là cảm xúc là biến trung gian, không phải một liên kết màu–nhạc trực tiếp. Whiteford và cộng sự [12] mở rộng quan sát này thành quan hệ định lượng giữa thuộc tính màu (độ sáng, độ bão hòa) và thuộc tính nhạc (nhịp độ, năng lượng). Đây chính là cơ sở để đồ án không ghép màu với nhạc trực tiếp mà ghép *qua* không gian cảm xúc Valence–Arousal. Tuy nhiên, các công trình ứng dụng trước đây gắn với dữ liệu phương Tây và thường ánh xạ màu sang thuộc tính nhạc bằng *quy tắc thủ công*, chưa dùng một không gian cảm xúc *học được* dùng chung cho cả hai chức năng, và chưa nhắm tới nhạc Việt. Bảng 2.3 đối chiếu các công trình màu–nhạc tiêu biểu với hệ thống đề xuất theo bốn tiêu chí kỹ thuật.

Bảng 2.3: So sánh các công trình màu→nhạc tiêu biểu với hệ thống đề xuất

Công trình	Không gian màu	Cách ánh xạ màu→nhạc	V-A dùng chung
MOODO [6]	RGB/HSV	Gán nhãn người trên tập riêng	Một phần
Kittimathaveenan [7]	RGB	Quy tắc thủ công	Không
Brightify (đề xuất)	Oklab	Hồi quy về chuẩn ICEAS + Whiteford	Có

Bảng 2.4 tổng hợp ở mức cao hơn, so sánh ba hướng tiếp cận lớn với hệ thống đề xuất. Khoảng trống mà đồ án nhắm tới không phải là “ý tưởng gợi ý theo màu” (vốn đã có tiền lệ), mà là một hệ thống gợi ý nhạc *Việt* dựa trên cảm xúc, không phụ thuộc dữ liệu người dùng, hợp nhất truy vấn theo bài hát và theo màu trên một không gian cảm xúc *học được* dùng chung, và có cơ sở khoa học rõ ràng cho từng thành phần.

Bảng 2.4: So sánh các hướng tiếp cận hiện có và hệ thống đề xuất

Tiêu chí	Lọc cộng tác (Spotify, v.v.)	Nghiên cứu MER	Brightify (đề xuất)
Cần dữ liệu người dùng	Có	Không	Không
Gợi ý theo cảm xúc	Gián tiếp	Có (phân tích)	Có
Gợi ý theo màu	Không	Không	Có
Hỗ trợ nhạc Việt	Một phần	Hạn chế	Trọng tâm

2.1.4 Bối cảnh và thách thức dữ liệu nhạc Việt

Ba luồng khảo sát trên hội tụ về một thách thức chung khi áp dụng cho nhạc Việt: *sự khan hiếm dữ liệu cảm xúc bản địa*. Thị trường nhạc số Việt Nam sôi động với nhiều nền tảng (các dịch vụ trong nước và quốc tế), nhưng dữ liệu cảm xúc gắn với nhạc Việt hầu như không được công bố công khai dưới dạng có thể huấn luyện. Các tài nguyên cảm xúc tiếng Việt sẵn có (như tập cảm xúc văn bản mạng xã hội) thuộc miền văn bản, không phải miền âm nhạc, và cũng không gắn theo trục Valence–Arousal liên tục. Hệ quả là không thể huấn luyện trực tiếp một mô hình cảm xúc nhạc Việt theo cách giám sát thông thường.

Thách thức này định hình ba quyết định thiết kế cốt lõi của đồ án. Thứ nhất, vì không có nhãn người bản địa, hệ thống phải gán cảm xúc bằng cách *chuyển giao* từ các nguồn có nhãn (đầu dò tuyến tính trên đặc trưng đóng băng, tổ hợp nhiều tín hiệu) thay vì học giám sát end-to-end. Thứ hai, vì không thu thập dữ liệu hành vi người dùng (do ràng buộc riêng tư và phạm vi), hệ thống không thể dựa vào lọc cộng tác mà phải dựa hoàn toàn vào nội dung. Thứ ba, vì dữ liệu phải tự thu thập, quy trình thu thập (mô tả ở mục 5.2) phải tự động và lặp lại được. Những ràng buộc này không phải hạn chế tình thế mà được biến thành nguyên tắc thiết kế nhất quán xuyên suốt đồ án.

2.1.5 Đánh giá hệ gợi ý khi không có người dùng

Vì đồ án chủ trương không thu thập dữ liệu người dùng, một câu hỏi phương pháp luận đặt ra ngay từ khâu khảo sát là: *làm thế nào đánh giá một hệ gợi ý khi không có người dùng để đo lường?* Tài liệu về đánh giá hệ gợi ý cung cấp hai nhóm độ đo ngoại tuyến. Nhóm thứ nhất đo độ chính xác xếp hạng so với một tập liên quan (ground truth), tiêu biểu là độ lợi tích lũy chiết khấu chuẩn hóa NDCG

[18], vốn thưởng cho việc đặt các vật phẩm liên quan lên đầu danh sách. Nhóm thứ hai đo các tính chất *nội tại* của danh sách kết quả mà không cần nhãn liên quan tuyệt đối, chẳng hạn mức danh sách phản ánh đúng phân bố sở thích (calibrated recommendations) [19], hay độ nhất quán và độ đa dạng nội bộ của kết quả.

Tuy nhiên, đánh giá ngoại tuyến có hai cạm bẫy đã được ghi nhận rõ. Thứ nhất là *khoảng cách offline-online*: theo Dacrema và cộng sự [20], tương quan giữa các độ đo ngoại tuyến và mức hài lòng thực tế của người dùng chỉ vào khoảng $r \approx 0.28$, nên một cải thiện ngoại tuyến không tự động kéo theo cải thiện trải nghiệm. Thứ hai là vấn đề *phương pháp nền yếu*: nhiều công bố báo cáo tiến bộ chỉ vì so với phương pháp nền được cấu hình kém, và Dacrema và cộng sự cho thấy không ít phương pháp “tân tiến” không vượt nổi các phương pháp nền đơn giản nếu các phương pháp nền đó được tinh chỉnh tử tế. Hai bài học này định hình trực tiếp quy trình đánh giá của đồ án (Chương 6): luôn đối chiếu với phương pháp nền mạnh (kể cả phương pháp nền theo độ phổ biến), bổ sung các kiểm chứng *độc lập với nhãn* để giảm phụ thuộc vào một độ đo tự tham chiếu, và nêu thẳng rằng mọi kết quả là độ đo ngoại tuyến chứ chưa phải bằng chứng từ người nghe thật. Như vậy, ràng buộc “không có người dùng” không loại bỏ khả năng đánh giá, mà chuyển trọng tâm sang một quy trình ngoại tuyến nhiều tầng, có kiểm định thống kê và tam giác hóa bằng nhiều nguồn độc lập.

2.2 Tác nhân và tổng quan chức năng

2.2.1 Các tác nhân của hệ thống

Khác với một ứng dụng nghe nhạc thương mại thông thường, Brightify gồm hai pha rõ rệt: pha *phục vụ* (serving) tương tác với người nghe theo thời gian thực, và pha *ngoại tuyến* (offline) chuẩn bị toàn bộ đặc trưng cho kho nhạc. Vì vậy mô hình tác nhân của hệ thống gồm bốn tác nhân, trong đó có cả tác nhân chính (con người) và tác nhân phụ (hệ thống/dữ liệu). Thứ nhất, (i) **người nghe / người dùng** là tác nhân chính của pha phục vụ: họ dùng giao diện để chọn màu hoặc chọn bài hát, xem và phát danh sách bài hát được gợi ý, và xem thông tin cảm xúc của bài hát, và không cần đăng nhập. Thứ hai, (ii) **quản trị dữ liệu / người vận hành hệ thống** cũng là tác nhân chính, nhưng làm việc với pha ngoại tuyến: họ chịu trách nhiệm cập nhật kho nhạc (thêm bài mới, lọc trùng/cover) và kích hoạt việc chạy lại quy trình trích đặc trưng ngoại tuyến. Bên cạnh hai tác nhân người, hệ thống có hai tác nhân phụ: (iii) **kho nhạc / dataset** là tập dữ liệu nhạc Việt gồm tệp âm thanh, siêu dữ liệu và lời bài hát, cung cấp dữ liệu đầu vào cho các use case phục vụ và là đối tượng được cập nhật bởi người vận hành; và (iv) **hệ thống xử lý đặc trưng offline** tự động trích embedding âm thanh (MuQ), tính tín hiệu cảm xúc từ lời, nhịp độ, độ to và sinh các ma trận biểu diễn, được người vận hành kích hoạt và ghi kết quả trở

lại kho đặc trưng để pha phục vụ nạp lên.

Việc tách hai tác nhân phụ (kho nhạc và hệ thống xử lý đặc trưng offline) là một lựa chọn thiết kế có chủ đích: nó phản ánh đúng kiến trúc hai pha của hệ thống (Chương 4), trong đó toàn bộ tính toán nặng được dồn về pha ngoại tuyến để pha phục vụ chỉ còn các phép tra cứu và nhân ma trận. Bảng 2.5 tóm tắt trách nhiệm chính của từng tác nhân.


Bảng 2.5: Trách nhiệm chính của các tác nhân

Tác nhân	Loại	Trách nhiệm chính
Người nghe	Chính (người)	Chọn màu/bài, xem và phát danh sách phát, xem cảm xúc bài hát
Người vận hành	Chính (người)	Cập nhật kho nhạc, kích hoạt pipeline ngoại tuyến
Kho nhạc / dataset	Phụ (dữ liệu)	Cung cấp âm thanh, siêu dữ liệu, lời; là đối tượng cập nhật
Hệ thống xử lý offline	Phụ (hệ thống)	Trích đặc trưng, tính tọa độ cảm xúc, sinh ma trận biểu diễn

2.2.2 Biểu đồ use case tổng quát

Hình 2.2 trình bày biểu đồ use case tổng quát của hệ thống. Người nghe thao tác với bốn use case của pha phục vụ; người vận hành thao tác với hai use case của pha ngoại tuyến; hai tác nhân phụ (kho nhạc và hệ thống xử lý đặc trưng offline) tham gia cung cấp/nhận dữ liệu cho các use case tương ứng.

Bảng 2.6 liệt kê các use case và tác nhân liên quan. Sáu use case chia thành hai nhóm: nhóm phục vụ người nghe (UC01–UC04) và nhóm vận hành dữ liệu (UC05–UC06). Ngoài ra hệ thống còn một số chức năng phụ trợ (tìm kiếm bài hát; phát nhạc và quản lý hàng đợi; nghe crossfade và đài vô tận; duyệt thư viện; xem hướng dẫn và đổi góc nhìn giao diện) — không phải trọng tâm khoa học nên không đặc tả use case chi tiết, mà chỉ thể hiện qua các yêu cầu chức năng tương ứng ở Bảng 2.7.



Hình 2.2: Biểu đồ use case tổng quát của hệ thống Brightify

Bảng 2.6: Danh sách use case của hệ thống

Mã	Use case	Tác nhân
UC01	Chọn bài hát để gợi ý bài tương tự	Người nghe (chính); kho nhạc (phụ)
UC02	Chọn màu để gợi ý danh sách phát	Người nghe (chính); kho nhạc (phụ)
UC03	Xem danh sách bài gợi ý	Người nghe
UC04	Xem thông tin cảm xúc của bài hát	Người nghe
UC05	Cập nhật kho nhạc	Người vận hành (chính); kho nhạc (phụ)
UC06	Chạy lại pipeline trích đặc trưng	Người vận hành (chính); hệ thống xử lý đặc trưng offline (phụ)

2.3 Yêu cầu chức năng

Từ các tác nhân và use case ở trên, đồ án rút ra các yêu cầu chức năng (functional requirements) cụ thể mà hệ thống phải đáp ứng, được liệt kê trong Bảng 2.7 kèm mức độ ưu tiên và use case liên quan. Các yêu cầu được phân thành ba nhóm: nhóm gợi ý cốt lõi (FR01–FR03) là trọng tâm khoa học của đồ án; nhóm tinh chỉnh chất lượng kết quả (FR04–FR06) bảo đảm danh sách trả về thực sự dùng được; và nhóm hỗ trợ trải nghiệm và vận hành (FR07–FR10).

Bảng 2.7: Danh sách yêu cầu chức năng của hệ thống

Mã	Yêu cầu chức năng	Use case	Ưu tiên
FR01	Gợi ý các bài hát tương tự một bài cho trước (âm thanh + cảm xúc + lời)	UC01	Cao
FR02	Gợi ý danh sách phát từ một màu sắc người dùng chọn	UC02	Cao
FR03	Tạo “hành trình cảm xúc” từ hai màu theo nguyên lý đồng cảm	UC02	Cao
FR04	Loại bỏ bản cover/trùng khớp kết quả gợi ý tương tự	UC01	Trung bình
FR05	Đa dạng hóa kết quả theo nghệ sĩ (tránh lặp nghệ sĩ)	UC01, UC02	Trung bình
FR06	Hỗ trợ chế độ “đài” vô tận, không lặp bài đã phát	UC03	Trung bình
FR07	Hiển thị thông tin cảm xúc của bài hát (V-A, nhãn tâm trạng, lời)	UC04	Cao
FR08	Duyệt, lọc và sắp xếp kho nhạc	UC03	Trung bình
FR09	Tìm kiếm bài hát theo tên, nghệ sĩ, lời hoặc “cảm giác”	—	Thấp
FR10	Cập nhật kho nhạc và chạy lại pipeline trích đặc trưng	UC05, UC06	Trung bình

Trong các yêu cầu trên, FR01 và FR02 là hai chức năng cốt lõi đã nêu ở Chương 1; FR03 mở rộng FR02 cho trường hợp hai màu. FR04–FR06 không phải “tính năng phụ” mà là điều kiện để kết quả gợi ý có chất lượng: nếu không loại cover thì danh

sách tương tự sẽ trả về chính bài nguồn dưới dạng bản phối khác, còn nếu không đa dạng nghệ sĩ thì danh sách phát dễ bị một nghệ sĩ chiếm trọn. FR07 hiện thực hóa tính “giải thích được” của hệ thống. FR08–FR10 giúp hệ thống vận hành được như một phần mềm demo hoàn chỉnh.

2.4 Đặc tả chi tiết use case

Phần này đặc tả các use case quan trọng theo bốn yếu tố: tiền điều kiện, luồng sự kiện chính, luồng thay thế/ngoại lệ và hậu điều kiện. Đặc tả của sáu use case nghiệp vụ chính lần lượt được trình bày trong Bảng 2.8 (UC01), Bảng 2.9 (UC02), Bảng 2.10 (UC03), Bảng 2.11 (UC04), Bảng 2.12 (UC05) và Bảng 2.13 (UC06). Các con số kỹ thuật (cấu trúc dữ liệu trả về, mã lỗi) được trình bày trong Chương 5, còn thời gian phản hồi đo được trình bày trong Chương 6.


Bảng 2.8: Đặc tả use case UC01 — Gợi ý bài tương tự

Mã / Tên	UC01 — Chọn bài hát để gợi ý bài tương tự
Tác nhân	Người nghe (chính); kho nhạc và đặc trưng đã tính sẵn (phụ)
Mô tả	Từ một bài hát đang nghe hoặc được chọn, hệ thống trả về danh sách các bài “nghe giống” về âm thanh và gần về cảm xúc.
Tiền điều kiện	Kho nhạc và các đặc trưng (embedding âm thanh MuQ, tọa độ cảm xúc, embedding lời) đã được nạp; bài hát nguồn tồn tại trong kho.
Luồng sự kiện chính	1. Người nghe chọn một bài hát (từ thư viện, kết quả tìm kiếm hoặc bài đang phát). 2. Hệ thống tính điểm tương đồng giữa bài nguồn và mọi bài khác bằng tổ hợp ba tín hiệu (âm thanh, cảm xúc, lời). 3. Hệ thống loại các bản trùng/cover của bài nguồn và đa dạng hóa theo nghệ sĩ. 4. Hệ thống trả về danh sách <i>top-k</i> bài tương tự kèm điểm tương đồng. 5. Người nghe xem danh sách (chuyển sang UC03) và có thể phát.

Mã / Tên	UC01 — Chọn bài hát để gợi ý bài tương tự
Luồng thay thế / ngoại lệ	2a. Bài nguồn không có đặc trưng âm thanh: hệ thống lùi về dùng tín hiệu cảm xúc/lời còn lại. 3a. Người nghe yêu cầu thêm kết quả (chế độ “đài” vô tận): hệ thống nối tiếp danh sách và loại các bài đã phát qua tham số loại trừ. 1a. Không xác định được bài nguồn: hệ thống báo lỗi “không tìm thấy bài hát”.
Hậu điều kiện	Một danh sách bài tương tự (không trùng bài nguồn, đã đa dạng nghệ sĩ) được hiển thị; trạng thái hàng đợi phát được cập nhật nếu người nghe chọn phát.

Bảng 2.9: Đặc tả use case UC02 — Gợi ý theo màu

Mã / Tên	UC02 — Chọn màu để gợi ý danh sách phát
Tác nhân	Người nghe (chính); kho nhạc và đặc trưng đã tính sẵn (phụ)
Mô tả	Người nghe chọn một màu (hoặc hai màu để tạo “hành trình cảm xúc”); hệ thống trả về danh sách bài hát có cảm xúc tương ứng và nghe đồng nhất.
Tiền điều kiện	Các tọa độ cảm xúc của kho nhạc và bảng ánh xạ màu sang Valence–Arousal đã sẵn sàng.
Luồng sự kiện chính	1. Người nghe chọn một màu trong bảng 12 màu cơ bản. 2. Hệ thống ánh xạ màu sang tọa độ cảm xúc (Valence–Arousal). 3. Hệ thống chấm điểm độ gần cảm xúc trong không gian phân vị của kho nhạc, ưu tiên cụm có độ nhất quán âm thanh cao. 4. Hệ thống đa dạng hóa và sắp xếp kết quả thành chuỗi chuyển cảm xúc mượt. 5. Hệ thống trả về danh sách danh sách phát kèm thông tin ánh xạ màu→cảm xúc.



Hình 2.3: Biểu đồ hoạt động của UC02 — gợi ý theo màu (rẽ nhánh một màu / hai màu)

Mã / Tên	UC02 — Chọn màu để gợi ý danh sách phát
Luồng thay thế / ngoại lệ	1a. Người nghe chọn <i>hai</i> màu: hệ thống tạo hành trình từ tâm trạng màu A sang màu B theo nguyên lý đồng cảm (iso-principle). 1b. Chọn từ ba màu trở lên: hệ thống chỉ giữ hai màu đầu để tránh “nhiều tâm trạng”. 2a. Mã màu không hợp lệ (không phải dạng #RRGGBB): hệ thống từ chối yêu cầu và báo lỗi đầu vào.
Hậu điều kiện	Một danh sách phát khớp cảm xúc với màu đã chọn, có độ nhất quán âm thanh, được hiển thị cho người nghe.

Để minh họa rõ hai luồng (một màu và hai màu) của UC02, Hình 2.3 trình bày biểu đồ hoạt động tương ứng. Điểm rẽ nhánh nằm ở số màu người dùng chọn: với một màu, hệ thống đi theo nhánh truy hồi và tinh chỉnh thông thường; với hai màu, hệ thống bổ sung bước sinh hành trình cảm xúc theo nguyên lý đồng cảm trước khi trả về.

Bảng 2.10: Đặc tả use case UC03 — Xem danh sách bài gợi ý

Mã / Tên	UC03 — Xem danh sách bài gợi ý
Tác nhân	Người nghe
Mô tả	Hiển thị danh sách kết quả của UC01 hoặc UC02 để người nghe xem, phát và sắp xếp lại.
Tiền điều kiện	Một use case gợi ý (UC01/UC02) đã trả về kết quả.
Luồng sự kiện chính	- Hệ thống hiển thị từng bài kèm ảnh bìa (nhuộm màu theo tâm trạng), tên bài, nghệ sĩ. - Người nghe có thể phát một bài, phát toàn bộ danh sách, hoặc kéo—thả để sắp xếp lại. - Khi gần hết danh sách ở chế độ đài, hệ thống tự nổi thêm bài (gọi lại UC01/UC02 với danh sách loại trừ).
Luồng thay thế / ngoại lệ	- Danh sách rỗng: hệ thống hiển thị thông báo không có kết quả phù hợp. - Tệp âm thanh của bài không tồn tại: nút phát bị vô hiệu và hiển thị trạng thái không phát được.
Hậu điều kiện	Người nghe thấy được danh sách gợi ý và có thể tương tác phát nhạc; hàng đợi phát phản ánh thao tác của người nghe.

Bảng 2.11: Đặc tả use case UC04 — Xem thông tin cảm xúc bài hát

Mã / Tên	UC04 — Xem thông tin cảm xúc của bài hát
Tác nhân	Người nghe
Mô tả	Người nghe xem thông tin cảm xúc của một bài hát: tọa độ Valence–Arousal, nhãn tâm trạng và lời bài hát.
Tiền điều kiện	Bài hát đã được gán tọa độ cảm xúc ở pha ngoại tuyến.
Luồng sự kiện chính	- Người nghe mở một bài hát. - Hệ thống thể hiện tâm trạng của bài qua màu nền (suy ra từ Valence–Arousal) và một nhãn tâm trạng ngắn. - Hệ thống cung cấp tọa độ Valence–Arousal, nhãn tâm trạng và lời bài hát qua giao diện lập trình ứng dụng (mục 5.3).

Mã / Tên	UC04 — Xem thông tin cảm xúc của bài hát
Luồng thay thế / ngoại lệ	3a. Bài không có lời: trường lời trả về rỗng và giao diện hiển thị “chưa có lời”. 3b. Bài thiếu một số đặc trưng âm thanh: các trường tương ứng trả về rỗng thay vì gây lỗi.
Hậu điều kiện	Thông tin cảm xúc và lời của bài hát được hiển thị/được cung cấp cho người nghe.

Bảng 2.12: Đặc tả use case UC05 — Cập nhật kho nhạc

Mã / Tên	UC05 — Cập nhật kho nhạc
Tác nhân	Người vận hành / quản trị dữ liệu (chính); kho nhạc (phụ)
Mô tả	Người vận hành thu thập bài hát mới, lọc theo ngôn ngữ, tải tệp âm thanh và lời, lọc trùng/cover, rồi cập nhật vào kho nhạc.
Tiền điều kiện	Có quyền vận hành; có danh sách nghệ sĩ hạt giống (seed) và khóa truy cập các nguồn dữ liệu.
Luồng sự kiện chính	1. Người vận hành chạy quy trình thu thập (khám phá nghệ sĩ, lấy danh sách bài). 2. Hệ thống lọc bài tiếng Việt, tải tệp âm thanh và lời bài hát. 3. Hệ thống phát hiện và lập danh sách bản trùng/cover. 4. Kho nhạc được cập nhật với các bài hợp lệ và bảng loại trừ cover.
Luồng thay thế / ngoại lệ	2a. Không tải được tệp âm thanh sau các mức dự phòng: bài bị bỏ qua và ghi nhật ký. 2b. Không tìm được lời: bài vẫn được giữ, đánh dấu thiếu lời để pha ngoại tuyến xử lý dự phòng.
Hậu điều kiện	Kho nhạc có thêm bài mới đã lọc trùng/cover; trạng thái này là đầu vào cho UC06.

Bảng 2.13: Đặc tả use case UC06 — Chạy lại pipeline trích đặc trưng

Mã / Tên	UC06 — Chạy lại pipeline trích đặc trưng
Tác nhân	Người vận hành (chính); hệ thống xử lý đặc trưng offline (phụ)
Mô tả	Người vận hành kích hoạt pha ngoại tuyến để trích embedding âm thanh, tính tọa độ cảm xúc và sinh các ma trận biểu diễn cho kho nhạc.
Tiền điều kiện	Kho nhạc đã cập nhật (UC05); các mô hình đóng băng và đầu dò tuyến tính đã sẵn sàng.
Luồng sự kiện chính	1. Người vận hành chạy lần lượt các bước: trích embedding âm thanh MuQ, mã hóa lời, trích nhịp độ sạch, phát hiện cover. 2. Hệ thống tính tọa độ Valence–Arousal cho từng bài và lưu ra tệp đặc trưng. 3. Hệ thống đóng gói một bản phát hành phục vụ và kiểm tra đồng bộ kích thước các tệp đặc trưng.
Luồng thay thế / ngoại lệ	1a. Quá trình trích bị gián đoạn: hệ thống hỗ trợ chạy tiếp từ điểm dừng (checkpoint). 3a. Số dòng đặc trưng không khớp số bài: bước đóng gói báo lỗi và dừng để tránh phục vụ dữ liệu lệch.
Hậu điều kiện	Bộ đặc trưng mới (embedding âm thanh, tọa độ cảm xúc, embedding lời, chỉ mục cover) sẵn sàng để pha phục vụ nạp lên.

2.5 Yêu cầu phi chức năng

Ngoài các yêu cầu chức năng, hệ thống phải đáp ứng một tập yêu cầu phi chức năng (non-functional requirements) mang tính ràng buộc xuyên suốt thiết kế, tổng hợp trong Bảng 2.14. Khác với nhiều ứng dụng thông thường nơi yêu cầu phi chức năng chủ yếu là hiệu năng và bảo mật, ở đồ án này nhóm yêu cầu *tính đúng đắn khoa học* và *khả năng kiểm chứng* được đặt lên hàng đầu, vì sản phẩm cốt lõi là một quy trình khoa học chứ không chỉ là phần mềm.

Bảng 2.14: Danh sách yêu cầu phi chức năng

Mã	Nhóm	Yêu cầu	Cách kiểm chứng
NFR01	Đúng dẫn khoa học	Mọi tín hiệu/trọng số có nguồn từ tài liệu công bố hoặc tối ưu trên dữ liệu công khai	Truy nguồn trích dẫn; tái lập nhân
NFR02	Ràng buộc dữ liệu/mô hình	Không dùng dữ liệu người dùng; chỉ mô hình đóng băng + đầu dò tuyến tính	Rà soát mã nguồn; không có bước fine-tune
NFR03	Hiệu năng	Truy vấn lúc phục vụ ở mức vài mili-giây	Đo trực tiếp (mục 6.2.1)
NFR04	Tính tất định	Kết quả lặp lại được (chọn tham lam, tie-break ổn định đa nền tảng)	Chạy lại cho cùng kết quả
NFR05	Khả năng kiểm chứng	Mọi độ đo có quy trình đánh giá tái lập được	Bộ công cụ eval chạy lại được
NFR06	Bảo trì / nâng cấp	Thay một thành phần phải vượt cổng không thụt lùi (no-regression gate) trên độ đo cuối	So sánh trước/sau khi thay
NFR07	Vững trước lỗi biên	Đầu vào sai/thiếu được xử lý tương minh, không gây lỗi máy chủ	Kiểm thử hợp đồng API (mục 6.3)
NFR08	Khả năng mở rộng	Thêm bài mới không phá vỡ pipeline; phủ lỗi thiếu có cơ chế dự phòng	Cờ <code>has_lyrics</code> + lùi về đặc trưng âm thanh

Trong các yêu cầu trên, NFR06 — *cổng không thụt lùi* (no-regression gate) — là một yêu cầu đặc thù và quan trọng của đề án, nên cần làm rõ. Mỗi khi một thành phần học máy được cân nhắc thay thế (ví dụ đổi mô hình embedding lời, đổi trực biểu diễn âm thanh), thành phần mới chỉ được chấp nhận nếu nó *không làm xấu* độ

đo cuối của hệ thống so với cấu hình hiện hành, sau khi đã được tinh chỉnh siêu tham số riêng. Ràng buộc này biến quá trình phát triển thành một chuỗi thay đổi được kiểm soát: không có cải tiến nào được đưa vào chỉ vì “trông có vẻ tốt hơn trên giấy”. Cơ chế này được vận dụng trực tiếp trong khảo sát so sánh mô hình ở Chương 6 và được phân tích như một đóng góp phương pháp luận ở Chương 7.

Chương này đã khảo sát hiện trạng, xác lập mô hình tác nhân, các use case chính kèm đặc tả chi tiết, cùng các yêu cầu chức năng và phi chức năng. Các nền tảng lý thuyết và công nghệ cần thiết để đáp ứng những yêu cầu này được trình bày trong chương tiếp theo.


CHƯƠNG 3. NỀN TẢNG LÝ THUYẾT VÀ CÔNG NGHỆ SỬ DỤNG

Chương 2 đã xác lập các yêu cầu cho một hệ thống gợi ý nhạc Việt dựa trên cảm xúc, không dùng dữ liệu người dùng và có cơ sở khoa học. Chương này trình bày các nền tảng lý thuyết và công nghệ được lựa chọn để đáp ứng các yêu cầu đó. Với mỗi thành phần, báo cáo nêu rõ nó giải quyết yêu cầu nào, các lựa chọn thay thế có thể dùng, và lý do của lựa chọn cuối cùng.

3.1 Mô hình cảm xúc Valence–Arousal

Để cả bài hát và màu sắc có thể được so khớp trên cùng một thước đo, đồ án cần một biểu diễn cảm xúc thống nhất. Mô hình vòng tròn cảm xúc của Russell [2] mô tả cảm xúc bằng hai trục trực giao: *Valence* (mức độ dễ chịu, từ tiêu cực đến tích cực) và *Arousal* (mức độ kích thích/năng lượng, từ trầm lắng đến sôi động); trục Arousal tương hợp với mô hình tâm trạng *năng lượng–căng thẳng* của Thayer [21], vốn nhấn mạnh chiều năng lượng của cảm xúc. Mỗi trạng thái cảm xúc trở thành một điểm trên mặt phẳng hai chiều này, và các nhãn cảm xúc rời rạc quen thuộc tương ứng với các vùng (góc phần tư) của mặt phẳng. Hình 3.1 minh họa bốn góc phần tư cùng tám nhãn cảm xúc mà hệ thống sử dụng.

Đây là mô hình được dùng phổ biến nhất trong nhận dạng cảm xúc âm nhạc và tâm lý học màu sắc, đồng thời là khung lý thuyết cho phép màu và nhạc gặp nhau, do liên kết màu–nhạc được trung gian hóa bởi cảm xúc [1]. So với các mô hình cảm xúc rời rạc (vui, buồn, giận...), mô hình hai trục liên tục cho phép tính khoảng cách và xếp hạng, nên phù hợp với bài toán truy hồi: “gần nhau về cảm xúc” trở



Hình 3.1: Mô hình vòng tròn cảm xúc của Russell: bốn góc phần tư (Q1 vui–sôi nổi, Q2 căng–giận, Q3 buồn–u sầu, Q4 thư thái–bình yên) và tám nhãn cảm xúc hệ thống sử dụng

thành “gần nhau trên mặt phẳng V-A”. Mô hình hai trục có một hạn chế đã biết là gộp một số cảm xúc cùng vùng (ví dụ giận dữ và sợ hãi đều ở vùng Valence thấp–Arousal cao), điều mà các mô hình ba chiều (thêm trục Dominance) [22] hay các thang đo cảm xúc chuyên biệt cho âm nhạc như GEMS [23] xử lý tốt hơn; tuy nhiên với bài toán truy hồi và xếp hạng theo tâm trạng, sự phân biệt tinh tế này không thiết yếu, nên mô hình hai trục vẫn là lựa chọn phù hợp và phổ biến nhất. Vì vậy, toàn bộ hệ thống quy về không gian Valence–Arousal.

Có hai trường phái lớn trong biểu diễn cảm xúc. Trường phái *rời rạc* (categorical) coi cảm xúc là một tập hữu hạn các trạng thái cơ bản (vui, buồn, giận, sợ...), tiêu biểu là sáu cảm xúc cơ bản của Ekman [24]. Trường phái *liên tục* (dimensional) như mô hình của Russell coi cảm xúc là điểm trong một không gian ít chiều liên tục. Với bài toán gợi ý, biểu diễn liên tục có hai lợi thế quyết định: nó cho phép định nghĩa *khoảng cách* giữa hai trạng thái cảm xúc (để truy hồi “gần nhau”), và cho phép *nội suy* một đường chuyển cảm xúc mượt giữa hai điểm (phục vụ hành trình hai màu). Một biểu diễn rời rạc không có hai tính chất này: hai nhãn “buồn” và “u sầu” hoặc giống hệt hoặc khác hẳn, không có mức độ ở giữa. Trong hệ thống, các nhãn tâm trạng hiển thị cho người dùng (như ở Hình 3.1) được suy ra từ tọa độ V-A bằng cách xác định góc phần tư và vùng chứa điểm đó — tức là nhãn rời rạc chỉ là một lớp trình bày trên nền biểu diễn liên tục, chứ không phải đơn vị tính toán.

Để làm rõ vì sao đồ án chọn mô hình hai trục của Russell thay vì các khung cảm xúc khác, Bảng 3.1 đối chiếu bốn lựa chọn tiêu biểu theo tiêu chí quan trọng nhất với bài toán gợi ý: liệu mô hình có cho phép định nghĩa *khoảng cách* và *nội suy* giữa các trạng thái hay không. Mô hình của Russell và mô hình PAD ba chiều [22] đều là không gian liên tục có metric, nhưng trục Không chế (Dominance) thứ ba của PAD rất khó suy ra một cách đáng tin từ âm thanh hay lời bài hát và thường cho dữ liệu thừa, nên lợi ích tách biệt được những cặp cảm xúc cùng vùng (giận dữ và sợ hãi) không bù lại chi phí ước lượng thêm một trục. Thang đo GEMS [23] được thiết kế riêng cho cảm xúc *do âm nhạc gợi lên* và tinh tế hơn về mặt mô tả, nhưng chín nhân tố của nó không tạo thành một không gian metric thuần nhất để tính khoảng cách màu–nhạc, đồng thời không có sẵn quy trình ánh xạ màu sang chín nhân tố này. Các mô hình rời rạc kiểu sáu cảm xúc cơ bản của Ekman [24] trực giác và dễ gán nhãn nhưng thiếu hẳn hai tính chất cốt lõi mà truy hồi cần. Vì hai chức năng của đồ án đều quy về thao tác “tìm điểm lân cận trên mặt phẳng cảm xúc”, một không gian liên tục hai chiều vừa đủ giàu để phân biệt tâm trạng vừa đủ gọn để ước lượng đáng tin là lựa chọn cân bằng nhất.

Bảng 3.1: So sánh các mô hình biểu diễn cảm xúc và mức phù hợp với bài toán truy hồi

Mô hình	Dạng	Ưu điểm	Hạn chế cho truy hồi
Vòng tròn Russell (V-A) [2]	Liên tục, 2 chiều	Cho khoảng cách & nội suy; phổ biến nhất trong MER và tâm lý học màu	Gộp một số cảm xúc cùng vùng (giận/sợ)
PAD [22]	Liên tục, 3 chiều	Thêm trục Không chế, tách được giận/sợ	Trục thứ ba khó suy từ âm thanh/lời; dữ liệu thưa
GEMS [23]	9 nhân tố nhạc	Thiết kế riêng cho cảm xúc do nhạc gợi	Không phải không gian metric; khó hợp nhất với màu
Cảm xúc cơ bản Ekman [24]	Rời rạc	Trực giác, dễ gán nhãn	Không có khoảng cách/nội suy giữa các nhãn

Một điểm cần nhấn mạnh là tính *trực giao* được giả định giữa hai trục: Valence và Arousal độc lập với nhau, nên một bài có thể vui–trầm lắng (Valence cao, Arousal thấp, như một bản acoustic nhẹ nhàng) hoặc buồn–dữ dội (Valence thấp, Arousal cao, như một bản rock bi tráng). Chính tính trực giao này cho phép bốn góc phần tư mô tả những kết hợp cảm xúc mà một thang đo một chiều (chỉ “tích cực–tiêu cực”) không thể nắm bắt. Trong dữ liệu nhạc Việt thực tế của đề án, hai trục có tương quan dương nhẹ (mục 6.1.2); đây là một thuộc tính của kho nhạc chứ không phải phản bác giả định lý thuyết, và nó có hệ quả thực tiễn là các vùng lệch trục (vui–trầm, buồn–dữ dội) thưa dữ liệu hơn.

Để chuyển từ tọa độ liên tục sang nhãn tâm trạng hiển thị cho người dùng, hệ thống xác định góc phần tư từ vị trí của điểm so với trung điểm 0.5 trên mỗi trục, theo Phương trình (3.1), rồi gán nhãn cảm xúc theo vùng tương ứng (chẳng hạn Valence cao–Arousal cao thuộc góc “vui vẻ/phấn khích”). Cần nhấn mạnh rằng đây thuần túy là một bước *trình bày*: mọi phép truy hồi và xếp hạng vẫn thực hiện

trên tọa độ liên tục, còn nhãn rời rạc chỉ sinh ra ở bước cuối để hiển thị.

$$Q(v, a) = \begin{cases} Q_1 \text{ (vui-sôi nổi)} & v \geq 0.5, a \geq 0.5 \\ Q_2 \text{ (căng-giận)} & v < 0.5, a \geq 0.5 \\ Q_3 \text{ (buồn-u sầu)} & v < 0.5, a < 0.5 \\ Q_4 \text{ (thư thái-bình yên)} & v \geq 0.5, a < 0.5 \end{cases} \quad (3.1)$$

3.2 Cơ sở liên kết màu sắc với cảm xúc

Để ánh xạ màu về tọa độ cảm xúc, đồ án sử dụng ba cơ sở. Thứ nhất, để xử lý màu theo cảm nhận thị giác đồng đều, màu được chuyển sang không gian Oklab [25] thay vì RGB thô. Không gian RGB không đồng đều về tri giác: cùng một khoảng cách số trong RGB có thể ứng với mức khác biệt cảm nhận rất khác nhau ở các vùng màu khác nhau. Oklab được thiết kế để khoảng cách Euclid xấp xỉ khác biệt cảm nhận, với trục L (độ sáng) và hai trục màu a (lục-đỏ), b (lam-vàng). Từ tọa độ Oklab, đồ án suy ra hai đại lượng tri giác phục vụ ánh xạ cảm xúc: *độ đỏ* (redness) tính từ góc màu h và *độ bão hòa* (saturation), theo Phương trình (3.2).

$$\text{redness} = \frac{1 + \cos h}{2}, \quad h = \text{atan2}(b, a) \quad (3.2)$$

Thứ hai, trục Valence của màu được hồi quy về các chuẩn liên kết màu-cảm xúc của con người trong khảo sát ICEAS [11], một khảo sát quy mô lớn trên nhiều quốc gia (Hình 3.2). Thứ ba, trục Arousal của màu được suy ra theo quan hệ màu-âm nhạc của Whiteford [12]: nhạc nhanh, sôi động gắn với màu sáng và bão hòa hơn. Đặc biệt, độ đỏ và độ bão hòa được đặt trên trục Arousal, phù hợp với phát hiện rằng độ bão hòa là yếu tố chính chi phối Arousal của màu [26]. Hình 3.3 minh họa hướng tăng của hai trục cảm xúc trong mặt phẳng màu. Lựa chọn dùng Whiteford thay vì chỉ dùng quan hệ màu đơn thuần xuất phát từ việc cần đúng cấu trúc màu-âm nhạc, vì hệ thống ánh xạ màu sang nhạc chứ không phải mô tả cảm nhận màu độc lập; công thức Arousal cụ thể được trình bày ở mục 4.2.2.


Việc chọn không gian màu không phải là chi tiết kỹ thuật nhỏ. RGB là không gian thiết bị, không đồng đều về tri giác và trộn lẫn độ sáng với màu sắc. CIELAB cải thiện tính đồng đều nhưng vẫn có hiện tượng không đồng đều ở vùng xanh lam. Oklab [25] là một cải tiến gần đây được thiết kế riêng để khoảng cách Euclid khớp tốt hơn với khác biệt cảm nhận, đồng thời tách bạch độ sáng (L) khỏi sắc độ (a, b) — điều quan trọng vì hai trục cảm xúc của màu phụ thuộc vào các thành phần tri giác khác nhau (Valence gắn nhiều với độ sáng, Arousal gắn nhiều với độ bão hòa).

hòa). Về phía cảm xúc, khảo sát ICEAS [11] thu thập liên kết màu–cảm xúc trên hàng nghìn người ở khoảng ba mươi quốc gia, cung cấp một chuẩn định lượng đáng tin cho trục Valence của màu. Riêng trục Arousal, ngoài Whiteford, phát hiện của Valdez và Mehrabian [26] trên khoảng bảy mươi sáu màu Munsell cho thấy *độ bão hòa* là yếu tố chi phối Arousal mạnh hơn cả độ sáng — đây là cơ sở để công thức Arousal đặt trọng số đáng kể cho độ bão hòa.


Việc đặt màu và nhạc lên cùng một trục cảm xúc không phải là một quy ước tùy tiện mà có cơ sở trong hiện tượng *tương ứng đa giác quan* (crossmodal correspondences): con người, một cách nhất quán và xuyên văn hóa, liên kết các thuộc tính của những giác quan khác nhau — chẳng hạn âm vực cao với màu sáng, nhịp nhanh và âm lượng lớn với màu rực rỡ — và phần lớn các liên kết này được *trung gian hóa bởi cảm xúc* chứ không phải bởi tương đồng vật lý trực tiếp [1], [17]. Nói cách khác, một màu và một bản nhạc “hợp nhau” khi chúng gọi lên cùng một trạng thái cảm xúc; do đó cảm xúc là cầu nối tự nhiên, và việc quy cả hai về tọa độ Valence–Arousal chỉ là hình thức hóa lại cầu nối sẵn có đó. Đây cũng là lý do đồ án không ghép màu với nhạc bằng quy tắc thủ công (ví dụ “màu xanh dương luôn ứng với nhạc buồn”) mà ghép gián tiếp qua một không gian cảm xúc có cơ sở định lượng. Bảng 3.2 tóm tắt ba cơ sở khoa học được dùng cho ánh xạ này và vai trò riêng của từng cơ sở.

Bảng 3.2: Ba cơ sở khoa học dùng cho ánh xạ màu sang tọa độ cảm xúc

Cơ sở	Vai trò trong ánh xạ	Nguồn
Không gian Oklab	Xử lý màu đồng đều về tri giác; tách độ sáng (L) khỏi sắc độ (a, b) để hai trục cảm xúc dựa trên các thành phần khác nhau	[25]
Chuẩn ICEAS	Hồi quy trục Valence của màu theo liên kết màu–cảm xúc do con người chấm (gần 30 quốc gia)	[11]
Quan hệ Whiteford	Suy trục Arousal theo quan hệ màu–âm nhạc (màu sáng, bão hòa hơn ứng với nhạc nhanh hơn)	[12]
Phát hiện Valdez–Mehrabian	Củng cố vai trò của độ bão hòa là yếu tố chi phối Arousal của màu	[26]



Hình 3.2: Bản đồ nhiệt liên kết màu–cảm xúc từ khảo sát ICEAS trên khoảng ba mươi quốc gia: mỗi ô là xác suất Bayes liên kết một cảm xúc (hàng) với một màu (cột); ô càng cam/đỏ đậm thì liên kết càng mạnh (Nguồn: Jonauskaitė và cộng sự, 2020 [11])



Hình 3.3: Mặt phẳng màu Oklab (a – b) và hướng tăng của hai trục cảm xúc: Arousal tăng theo độ đỏ và độ bão hòa (Whiteford), Valence tăng theo độ sáng và giảm theo độ đỏ (ICEAS)

Việc tách bạch độ sáng khỏi sắc độ trong Oklab có một hệ quả thiết kế quan trọng: hai trục cảm xúc của màu dựa trên những thành phần tri giác *khác nhau* và do đó tương đối độc lập. Trục Valence chủ yếu gắn với độ sáng L (màu sáng hơn dễ chịu hơn) và mức độ đỏ, trong khi trục Arousal chủ yếu gắn với độ bão hòa và độ đỏ (màu rực rỡ kích thích hơn). Nếu dùng RGB thô — nơi độ sáng bị trộn lẫn vào cả ba kênh — thì một thay đổi nhằm điều chỉnh Valence sẽ vô tình kéo theo Arousal, làm hai trục dính vào nhau. Oklab gỡ được sự dính này, cho phép hồi quy mỗi trục cảm xúc trên đúng các thành phần tri giác chi phối nó. Một trường hợp

cần xử lý riêng là các màu *vô sắc* (trắng, xám, đen) có độ bão hòa gần không: với chúng, độ đỏ và sắc độ không còn ý nghĩa, nên Valence và Arousal được suy chủ yếu từ độ sáng (màu càng sáng càng dễ chịu, càng tối càng trầm lắng). Cách phân nhánh này bảo đảm ánh xạ màu vẫn hợp lý ở các đầu mút của dải màu.

3.3 Biểu diễn âm nhạc bằng học tự giám sát


Để đo độ “nghe giống nhau” và để suy ra Arousal từ âm thanh, đồ án cần một biểu diễn âm nhạc mạnh. Các đặc trưng âm thanh thủ công (như MFCC, chroma) nắm bắt cảm xúc yếu, nên đồ án dùng mô hình học tự giám sát (Self-Supervised Learning, SSL). Học tự giám sát huấn luyện mô hình trên lượng lớn nhạc *không nhãn* bằng các bài toán tự sinh (dự đoán đoạn bị che, lượng tử hóa đặc trưng), nhờ đó thu được biểu diễn tổng quát mà không cần nhãn cảm xúc. Hai ứng viên hàng đầu là MERT [27], dùng cơ chế thầy–trò với mục tiêu âm học và âm nhạc, và MuQ [10], dùng lượng tử hóa vector dư trên phổ Mel; cả hai đều được đánh giá trên bộ chuẩn MARBLE [28].

Cơ chế của học tự giám sát có thể hình dung như sau: mô hình được cho “nghe” một đoạn nhạc đã bị che hoặc làm nhiễu một phần, rồi phải dự đoán phần bị thiếu dựa trên ngữ cảnh xung quanh. Để làm tốt việc này, mô hình buộc phải học các quy luật nội tại của âm nhạc — hòa âm, nhịp điệu, âm sắc, cấu trúc — mà không cần bất kỳ nhãn nào do con người gán. Sau khi tiền huấn luyện trên hàng nghìn giờ nhạc, mỗi lớp biến đổi (transformer) của mô hình mã hóa thông tin ở một mức trừu tượng khác nhau; đồ án gộp trung bình (mean-pooling) đầu ra theo trục thời gian thành một vector 1024 chiều duy nhất cho mỗi bài, đủ cô đọng để so khớp nhanh nhưng vẫn giàu thông tin. Chính vì biểu diễn này được học từ quy luật âm nhạc *tổng quát* chứ không phải từ một tác vụ cảm xúc cụ thể, nó chuyển giao tốt sang nhạc Việt dù mô hình chưa từng được huấn luyện riêng cho nhạc Việt — một tính chất then chốt với bài toán thiếu dữ liệu bản địa.

Hình 3.4 mô tả cách một mô hình SSL âm nhạc được sử dụng trong đồ án. Tín hiệu âm thanh đi qua khối tiền xử lý, qua nhiều lớp biến đổi (transformer) đã được *đóng băng*, rồi được gộp trung bình thành một vector biểu diễn 1024 chiều. Vector này phục vụ ba vai trò: (i) đo tương đồng giữa hai bài bằng cosine theo Phương trình (3.3); (ii) bảo đảm nhất quán âm thanh cho gợi ý theo màu; và (iii) làm đặc trưng đầu vào cho đầu dò tuyến tính suy ra cảm xúc (mục 3.4).

$$\cos(\mathbf{x}, \mathbf{y}) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|} \quad (3.3)$$

Hai mô hình khác nhau ở *bài toán tự giám sát* (pretext task). MERT học bằng



Hình 3.4: Sơ đồ khối sử dụng mô hình học tự giám sát âm nhạc: từ tín hiệu âm thanh tới vector biểu diễn 1024 chiều, dùng cho đo tương đồng và làm đặc trưng cho đầu dò cảm xúc

cách dự đoán các nhãn giả sinh từ một “thầy âm học” (gom cụm đặc trưng âm thanh) và một “thầy âm nhạc” (biểu diễn dựa trên cao độ), nhờ đó nắm được cả kết cấu âm sắc lẫn thông tin hòa âm. MuQ thay thế nhãn giả bằng mục tiêu lượng tử hóa vector dư trên phổ Mel (Mel Residual Vector Quantization), cho mục tiêu học ổn định hơn (Hình 3.5). Bộ chuẩn MARBLE [28] đánh giá các mô hình này trên nhiều tác vụ hiểu nhạc (gắn thẻ, nhận dạng nhạc cụ, phát hiện cảm xúc...). Một điểm cốt lõi trong thiết kế của đề án là dùng các mô hình này ở dạng *đóng băng*: trọng số của mô hình không được cập nhật, chỉ một lớp tuyến tính phía trên được huấn luyện. Cách này phù hợp với bằng chứng rằng đầu dò tuyến tính trên đặc trưng đóng băng tổng quát hóa tốt hơn tinh chỉnh khi dữ liệu đích lệch miền [9], và đặc biệt cần thiết khi dữ liệu nhãn cảm xúc nhạc Việt khan hiếm.

Lý do dùng học tự giám sát thay vì đặc trưng âm thanh thủ công (MFCC, chroma, các bộ mô tả phổ) nằm ở chỗ các đặc trưng thủ công được thiết kế để mô tả tín hiệu chứ không để nắm bắt cảm xúc hay phong cách, nên thường yếu khi dùng làm đầu vào cho nhận dạng cảm xúc âm nhạc [14]. Học tự giám sát, ngược lại, học một biểu diễn tổng quát từ hàng nghìn giờ nhạc bằng các bài toán tự sinh (ví dụ che một phần tín hiệu rồi yêu cầu mô hình khôi phục), nhờ đó vector thu được mã hóa được cả âm sắc, hòa âm lẫn cấu trúc — những yếu tố mà cảm xúc và độ “nghe giống” phụ thuộc vào — mà không cần một nhãn cảm xúc nào trong quá trình tiền huấn luyện. Đây chính là tính chất quyết định với bài toán nhạc Việt thiếu nhãn.

Bảng 3.3 đối chiếu hai ứng viên theo các tiêu chí then chốt. Khác biệt cốt lõi nằm ở *bài toán tự giám sát*: MERT phải dựa vào hai “thầy” ngoài (một thầy âm học gom cụm đặc trưng, một thầy âm nhạc dựa trên cao độ) để sinh nhãn giả, trong khi MuQ tự sinh mục tiêu bằng lượng tử hóa vector dư trên phổ Mel, cho quá trình học ổn định hơn và không phụ thuộc chất lượng của thầy ngoài. Trên bộ chuẩn MARBLE [28], MuQ ngang hoặc nhỉnh hơn MERT ở nhiều tác vụ hiểu nhạc; tuy nhiên đề án không lấy thứ hạng trên bộ chuẩn làm căn cứ chấp nhận mà kiểm lại

bằng độ đo cuối của chính hệ thống (mục 6.1.4).

Bảng 3.3: So sánh hai mô hình học tự giám sát âm nhạc MERT và MuQ


Tiêu chí	MERT [27]	MuQ [10]
Bài toán tự giám sát	Dự đoán nhãn giả từ thầy âm học + thầy âm nhạc (cao độ)	Lượng tử hóa vector dư trên phổ Mel (Mel-RVQ)
Tính chất mục tiêu học	Cần thầy ngoài; nhiều nhãn giả	Tự sinh mục tiêu, học ổn định hơn
Đánh giá trên MARBLE	Mạnh trên nhiều tác vụ hiểu nhạc	Ngang hoặc hơn MERT [28]
Vai trò trong đề án	Backbone tiền nhiệm (để so sánh)	Backbone được chọn cho cả ba vai trò
Phán quyết theo độ đo cuối	—	Ngang/hơn; thắng chuyển giao GPT (mục 6.1.4)

Đề án lựa chọn MuQ làm trục biểu diễn âm thanh sau một so sánh công bằng cho thấy MuQ *ngang hoặc hơn* MERT — hòa trên các độ đo trực tiếp và vượt có ý nghĩa thống kê ở phép chuyển giao sang một bộ chấm (judge) độc lập (chi tiết ở mục 6.1.4). Biểu diễn của MuQ được dùng cho cả ba vai trò nêu trên, bảo đảm một trục biểu diễn nhất quán cho toàn hệ thống.

3.4 Biểu diễn lời và cảm xúc văn bản tiếng Việt

Valence (mức vui–buồn) của một bài hát nằm chủ yếu ở nội dung lời, nên đề án kết hợp nhiều tín hiệu văn bản độc lập. Điều quan trọng cần phân biệt là ba *loại* mô hình văn bản phục vụ hai mục đích khác nhau, như minh họa trong Hình 3.6: nhóm dự đoán một *giá trị tuyệt đối* (Valence) gồm từ điển và đầu dò trên mô hình ngữ cảnh, còn nhóm *so sánh* hai đoạn lời là mô hình embedding câu.

Tín hiệu từ điển dùng từ điển NRC-VAD [29] ở bản dịch tiếng Việt, được đổi chiều và bổ sung bằng từ điển cảm xúc bản địa VnEmoLex [30] nhằm giảm sai sót dịch máy. Tín hiệu chuyển hóa ngữ cảnh tiếng Việt dùng mô hình ViSoBERT [31], vốn được tiền huấn luyện cho văn bản mạng xã hội tiếng Việt nên hợp với văn phong lời nhạc; mô hình được gắn một đầu dò tuyến tính huấn luyện trên tập cảm xúc UIT-VSMEC [32]. Tín hiệu liên ngữ dùng mô hình đa ngữ XLM-R [33] với đầu dò huấn luyện trên tập EmoBank tiếng Anh [16], nhằm tận dụng nguồn nhãn



Hình 3.5: Kiến trúc mô hình MuQ: phổ Mel bị che một phần được Conformer dự đoán lại các token Mel-RVQ qua mục tiêu lượng tử hóa vector dư (Nguồn: Zhu và cộng sự, 2025 [10])

Valence liên tục do con người chấm mà tiếng Việt không có. Các mô hình thay thế như PhoBERT [34] đã được cân nhắc; lý do giữ ViSoBERT được trình bày ở Chương 7.


Lý do dùng *ba* tín hiệu lỗi thay vì một là chúng có các kiểu sai khác nhau và bổ trợ cho nhau. Từ điển nhanh và minh bạch nhưng không hiểu ngữ cảnh: nó dễ chấm sai khi gặp phủ định (“không buồn”) hay đảo nghĩa, nên đề án bổ sung xử lý phủ định và liên từ đối lập cho tín hiệu này. Đầu dò trên mô hình ngữ cảnh (ViSoBERT) hiểu ngữ cảnh và văn phong nhưng phụ thuộc miền tiền huấn luyện — chính vì văn phong lời nhạc gần với văn bản mạng xã hội mà ViSoBERT được tiền huấn luyện, mô hình này hợp hơn các mô hình huấn luyện trên văn bản trang trọng. Đầu dò liên ngữ (XLM-R trên EmoBank) cho phép *chuyển* nguồn nhãn Valence liên tục do con người chấm từ tiếng Anh sang tiếng Việt — nguồn nhãn mà tiếng Việt không có. Khi tổ hợp, những lỗi độc lập của ba tín hiệu có xu hướng triệt tiêu lẫn nhau, và bộ tổ hợp EWE (mục 3.5) tự giảm trọng số cho tín hiệu kém nhất quán với phần còn lại. Bảng 3.4 tóm tắt bốn tín hiệu văn bản kèm mô hình, vai trò và nguồn nhãn của từng tín hiệu.

Bảng 3.4: Bốn tín hiệu văn bản: ba tín hiệu dự đoán Valence tuyệt đối và một tín hiệu so sánh tương đồng lời

Tín hiệu	Mô hình / tài nguyên	Vai trò	Nguồn nhân
Từ điển	NRC-VAD-VN + VnEmoLex	Valence tuyệt đối	Từ điển VAD [29], [30]
Ngữ cảnh VN	ViSoBERT (đóng băng) + đầu dò	Valence tuyệt đối	UIT-VSMEC [31], [32]
Liên ngữ	XLM-R + đầu dò	Valence tuyệt đối	EmoBank (tiếng Anh) [16], [33]
Tương đồng lời	multilingual-e5-large	So sánh nội dung lời (co-sine)	— [35]

Việc chọn tập huấn luyện cho đầu dò ngữ cảnh tiếng Việt cũng là một quyết định có chủ đích về *khớp miền*. Đồ án chọn tập cảm xúc UIT-VSMEC [32] (cảm xúc trong văn bản mạng xã hội tiếng Việt) thay vì các tập phân tích quan điểm phổ biến hơn như UIT-VSFC [36] (phản hồi sinh viên), vì văn phong và sắc thái cảm xúc của lời nhạc gần với ngôn ngữ mạng xã hội hơn là với văn bản phản hồi trang trọng; một đầu dò huấn luyện trên miền quá xa dễ khiến toàn bộ kho nhạc bị đẩy về một vùng cảm xúc hẹp. Đây là một ví dụ cho nguyên tắc xuyên suốt: với học chuyển giao trên đặc trưng đóng băng, *miền của dữ liệu nhân phải khớp với miền áp dụng* thì tín hiệu mới đáng tin.

Ngôn ngữ tiếng Việt còn đặt ra những thách thức riêng cho phân tích cảm xúc ở mức từ vựng, củng cố thêm lý do không thể chỉ dựa vào từ điển. Phủ định trong tiếng Việt có thể đứng cách xa từ mang cảm xúc (“chẳng còn thấy vui”); các từ tăng cường (“rất”, “quá”, “vô cùng”) và giảm nhẹ (“hơi”, “khá”) làm thay đổi cường độ cảm xúc; hiện tượng láy (“buồn buồn”) làm dịu sắc thái; và nhiều câu hát mang nghĩa bóng hoặc mỉa mai mà tra từ điển không thể nắm bắt. Đầu dò ngữ cảnh (ViSoBERT) bù đắp phần lớn các trường hợp này nhờ học được biểu diễn phụ thuộc ngữ cảnh, còn đầu dò liên ngữ (XLM-R) mang thêm tri thức cảm xúc từ nguồn nhân tiếng Anh phong phú. Chính sự bổ trợ giữa ba loại tín hiệu — từ điển minh bạch nhưng cứng nhắc, mô hình ngữ cảnh linh hoạt nhưng phụ thuộc miền, mô hình liên ngữ giàu nhân nhưng cần chuyển ngữ — là lý do tổ hợp nhiều tín hiệu



Hình 3.6: Ba loại tín hiệu văn bản: từ điển và đầu dò ngữ cảnh *dự đoán* Valence tuyệt đối (tổ hợp ở mục 3.5), còn embedding câu *so sánh* độ tương đồng nội dung lời

cho kết quả ổn định hơn bất kỳ tín hiệu đơn lẻ nào.

Các đầu dò cảm xúc nói trên đều là *hồi quy tuyến tính có ràng buộc* (ridge) trên đặc trưng đóng băng, theo Phương trình (3.4): mô hình lớn chỉ đóng vai trò trích đặc trưng $\phi(x)$, còn việc ánh xạ sang giá trị cảm xúc do một lớp tuyến tính đảm nhiệm. Cách này giữ số tham số huấn luyện rất nhỏ, tránh quá khớp khi dữ liệu đích ít và lệch miền.


$$\hat{y} = \mathbf{w}^\top \phi(x) + b, \quad \mathbf{w} = \arg \min_{\mathbf{w}} \sum_{i=1}^n (y_i - \mathbf{w}^\top \phi(x_i))^2 + \lambda \|\mathbf{w}\|^2 \quad (3.4)$$

Đối với chức năng gợi ý bài tương tự, để đo độ tương đồng nội dung lời, đồ án dùng một mô hình embedding câu (sentence embedding) theo kiến trúc Sentence-BERT [37]. Mô hình embedding câu khác về mục đích so với các đầu dò trên: nó tạo vector để *so sánh* hai đoạn lời bằng cosine, trong khi các đầu dò cảm xúc *dự đoán* một giá trị tuyệt đối. Việc lựa chọn cụ thể giữa một mô hình tiếng Việt chuyên biệt [38] và một mô hình đa ngữ mạnh hơn [35] được kiểm chứng bằng thực nghiệm và trình bày ở Chương 6.

3.5 Phương pháp tổ hợp, hậu xử lý và sắp xếp

Hệ thống kết hợp nhiều nguồn tín hiệu khác phương thức (âm thanh, lời, màu sắc) nên về bản chất là một bài toán *tổ hợp đa phương thức* (multimodal fusion) [39]; Hình 3.7 minh họa cách ba phương thức được quy về cùng trục Valence–Arousal. Phần này trình bày các phương pháp tổ hợp, hậu xử lý và sắp xếp tương ứng.

Để tổ hợp nhiều tín hiệu Valence mà không tự đặt trọng số, đồ án dùng bộ ước lượng có trọng số theo độ tin cậy EWE (Evaluator Weighted Estimator) [40]. Ý



Hình 3.7: Tổ hợp đa phương thức: âm thanh, lời và màu sắc được quy về cùng trục Valence–Arousal rồi tổ hợp để truy hồi và xếp hạng

tưởng của EWE là: mỗi tín hiệu được cân theo mức tương quan của nó với *đồng thuận chung* của các tín hiệu, nên những tín hiệu nhất quán với phần còn lại được tin hơn (Phương trình (3.5)). Cách này không cần nhãn đích nên tránh được tính vòng tròn (không “học” để khớp một bộ nhãn có sẵn), đồng thời tự giảm trọng số cho tín hiệu nhiễu.

$$\hat{v} = \frac{\sum_k w_k v_k}{\sum_k w_k}, \quad w_k \propto \text{corr}\left(v_k, \frac{1}{K-1} \sum_{j \neq k} v_j\right) \quad (3.5)$$


Khi đo tương đồng trên biểu diễn học sâu, các cosine thô bị thiên lệch dị hướng (anisotropy): mọi vector dồn về một nón hẹp khiến cosine giữa hai vector bất kỳ đều cao và gần như mất khả năng phân biệt [41]. Hình 3.8 minh họa hiện tượng này. Đồ án khắc phục bằng cách trừ trung bình (mean-centering) theo các kết quả đã công bố [42]: trừ đi vector trung bình của toàn kho trước khi tính cosine (Phương trình (3.6)), nhờ đó khôi phục dải động của độ tương đồng.

$$\tilde{\mathbf{x}} = \mathbf{x} - \boldsymbol{\mu}, \quad \boldsymbol{\mu} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \quad (3.6)$$

Để đa dạng hóa kết quả và tránh lặp nghệ sĩ, đồ án dùng độ liên quan biên cực đại MMR [43]: ở mỗi bước, hệ thống chọn ứng viên cân bằng giữa *độ liên quan* với truy vấn và *độ khác biệt* so với các bài đã chọn, theo Phương trình (3.7).

$$\text{next} = \arg \max_{i \in R \setminus S} \left[\lambda \text{rel}(i) - (1 - \lambda) \max_{j \in S} \text{sim}(i, j) \right] \quad (3.7)$$

Cuối cùng, để sắp xếp danh sách gợi ý theo màu thành một chuỗi chuyển cảm xúc mượt, đồ án áp dụng nguyên lý đồng cảm (iso-principle) trong trị liệu âm nhạc [44], [45]: chuỗi bài được sắp để tâm trạng thay đổi dần dần dọc theo một đường



Hình 3.8: Hiện tượng dị hướng và hiệu ứng trừ trung bình: trước khi trừ, các vector dồn vào một nón hẹp nên cosine gần như bằng nhau; sau khi trừ trung bình, chúng trải rộng và cosine khôi phục khả năng phân biệt

nổi hai điểm cảm xúc, thay vì nhảy đột ngột. Nguyên lý này có gốc rễ trong trị liệu âm nhạc, nơi người trị liệu dẫn dắt tâm trạng người nghe từ trạng thái hiện tại tới trạng thái đích bằng các bước chuyển nhỏ; áp dụng vào danh sách phát hai màu, hệ thống tạo một “hành trình” từ tâm trạng của màu A sang màu B.

Cần làm rõ thêm về hai phương pháp ít quen thuộc. EWE [40] bắt nguồn từ bài toán nhận dạng cảm xúc trong tiếng nói, nơi nhiều người chấm cùng một mẫu và độ tin cậy của mỗi người chấm được ước lượng lặp bằng mức tương quan của họ với trung bình của những người còn lại; ở đây “người chấm” được thay bằng “tín hiệu cảm xúc”. Hiện tượng dị hướng của biểu diễn học sâu [41] đã được quan sát rộng rãi ở các mô hình ngôn ngữ: các vector ngữ cảnh chiếm một hình nón hẹp trong không gian, làm cosine giữa hai vector bất kỳ đều dương và cao. Phương pháp trừ thành phần trội chung (*all-but-the-top*) [42] cho thấy chỉ cần loại bỏ trung bình và một vài thành phần chính là khôi phục được khả năng phân biệt; đồ án dùng phiên bản đơn giản nhất là trừ trung bình, vừa đủ để cải thiện rõ rệt độ nhất quán âm thanh (mục 6.1.2).

Ràng buộc “không tinh chỉnh, chỉ đầu dò tuyến tính” được củng cố bởi bằng chứng rằng đầu dò tuyến tính trên đặc trưng đóng băng có thể tổng quát hóa tốt hơn tinh chỉnh khi dữ liệu đích lệch miền [9], vốn đúng với trường hợp chuyển từ dữ liệu tiếng Anh sang nhạc Việt.

Về *cấp độ* tổ hợp, trong tổ hợp đa phương thức thường phân biệt tổ hợp sớm (*early fusion* — nối các vector đặc trưng thô rồi học chung) và tổ hợp muộn (*late fusion* — xử lý từng phương thức riêng rồi hợp nhất ở mức quyết định) [39]. Đồ án chọn một dạng tổ hợp muộn đặc thù: mỗi phương thức (âm thanh, lời, màu) trước hết được quy về cùng một trục cảm xúc *Valence–Arousal* có ý nghĩa diễn giải được,

rồi mới hợp nhất. Lựa chọn này có ba lợi ích so với việc nối thẳng các embedding khác chiều và khác thang. Thứ nhất, nó cho phép *diễn giải*: vì điểm hợp nhất nằm trên trục cảm xúc, hệ thống có thể giải thích “vì sao” một bài được gợi ý (qua đối tượng *why* ở Chương 5). Thứ hai, nó tránh để một phương thức có số chiều lớn lấn át khi đo khoảng cách. Thứ ba, nó tách bạch hai loại tín hiệu khác bản chất — giá trị cảm xúc *tuyệt đối* (V-A) và độ *tương đồng* (cosine embedding) — để mỗi loại được dùng đúng vai trò trong hàm điểm tổ hợp (Chương 4).

3.6 Công cụ và nền tảng triển khai

Phần xử lý dữ liệu, trích đặc trưng và các đầu dò được hiện thực bằng Python với các thư viện học máy phổ biến (NumPy, scikit-learn), các mô hình được tải từ kho mô hình mở. Tầng phục vụ dùng FastAPI vì hỗ trợ tốt kiểu dữ liệu và sinh tài liệu API tự động. Giao diện người dùng được xây dựng dưới dạng ứng dụng trang đơn (Single-Page Application, SPA) bằng React, cho phép tương tác mượt và dựng các hiệu ứng trực quan hóa cảm xúc. Lựa chọn FastAPI cho tầng phục vụ xuất phát từ việc nó hỗ trợ kiểu dữ liệu chặt (giúp xác thực đầu vào ở biên, đáp ứng yêu cầu xử lý lỗi tường minh) và sinh tài liệu API tự động, đồng thời tích hợp tốt với hệ sinh thái Python nơi các đặc trưng đã được tính. Toàn bộ phép so khớp ở pha phục vụ được vector hóa bằng NumPy: thay vì lặp trên từng bài, hệ thống thực hiện một phép nhân ma trận duy nhất giữa vector truy vấn và ma trận đặc trưng của cả kho — đây là chìa khóa cho thời gian phản hồi mili-giây. Phần liệt kê chi tiết công cụ kèm phiên bản được trình bày ở mục 5.1 của Chương 5.

3.7 Ánh xạ yêu cầu sang nền tảng

Để thấy rõ mỗi nền tảng phục vụ yêu cầu nào, Bảng 3.5 đối chiếu các yêu cầu (Chương 2) với thành phần lý thuyết/công nghệ đáp ứng. Bảng này cũng cho thấy mọi thành phần đều có nguồn gốc khoa học rõ ràng, đáp ứng yêu cầu NFR01.

Bảng 3.5: Ánh xạ giữa yêu cầu của hệ thống và nền tảng lý thuyết/công nghệ

Yêu cầu	Nền tảng đáp ứng
Biểu diễn cảm xúc thống nhất (FR01–FR03, FR07)	Mô hình V-A của Russell (mục 3.1)
Gợi ý theo màu (FR02, FR03)	Oklab + ICEAS + Whiteford (mục 3.2)
Đo “nghe giống” & suy Arousal (FR01)	SSL âm nhạc MuQ (mục 3.3)

Yêu cầu	Nền tảng đáp ứng
Suy Valence từ lời (FR07)	Từ điển + đầu dò ViSoBERT/XLM-R (mục 3.4)
Tổ hợp tín hiệu không tự đặt trọng số (NFR01)	EWE (mục 3.5)
Kết quả nhất quán âm thanh (FR02)	Trừ trung bình khử dị hướng (mục 3.5)
Đa dạng hóa & hành trình mượt (FR03, FR05)	MMR + iso-principle (mục 3.5)

3.8 Phát biểu bài toán hình thức

Trên cơ sở các nền tảng đã trình bày, có thể phát biểu hình thức hai bài toán mà hệ thống giải quyết. Gọi $\mathcal{S} = \{s_1, \dots, s_N\}$ là kho nhạc với $N = 5138$ bài. Pha ngoại tuyến gán cho mỗi bài s_i một bộ ba biểu diễn: tọa độ cảm xúc $\mathbf{p}_i \in [0, 1]^2$ (Valence–Arousal), vector embedding âm thanh $\mathbf{m}_i \in \mathbb{R}^{1024}$ (MuQ), và vector embedding lời $\mathbf{l}_i \in \mathbb{R}^{1024}$ (e5-large).

Bài toán 1 (gợi ý bài tương tự). Cho một bài nguồn s_q , tìm tập k bài $\mathcal{R} \subseteq \mathcal{S} \setminus \{s_q\}$ cực đại hóa tổng điểm tương đồng tổ hợp theo Phương trình (3.8):

$$\mathcal{R} = \arg \operatorname{top-k}_{i: s_i \notin \operatorname{cover}(s_q)} \left[0.76 \cos(\mathbf{m}_q, \mathbf{m}_i) + 0.16 \operatorname{sim}(\mathbf{p}_q, \mathbf{p}_i) + 0.08 \cos(\mathbf{l}_q, \mathbf{l}_i) \right] \quad (3.8)$$

sau đó áp đa dạng hóa MMR trên biểu diễn lời (e5-large) (gián tiếp giảm trùng nghệ sĩ; giới hạn cứng số bài mỗi nghệ sĩ là tùy chọn, mặc định tắt).

Bài toán 2 (gợi ý theo màu). Cho một (hoặc hai) màu, ánh xạ thành điểm đích $\mathbf{q}$ trong không gian phân vị V-A của kho nhạc, rồi tìm tập k bài vừa cực đại hóa độ gần cảm xúc (RBF) vừa cực đại hóa độ nhất quán âm thanh theo Phương trình (3.9):

$$\mathcal{R} = \arg \operatorname{top-k}_i \left[\alpha \operatorname{RBF}(\mathbf{q}, \mathbf{p}_i) + (1 - \alpha) \operatorname{coh}(\mathbf{m}_i, \mathcal{R}) \right], \quad \alpha = 0.55 \quad (3.9)$$

trong đó coh là độ nhất quán âm thanh đo trên biểu diễn MuQ đã trừ trung bình, và kết quả được sắp theo nguyên lý đồng cảm khi có hai màu. Điểm chung của hai bài toán là cùng làm việc trên các biểu diễn $(\mathbf{p}, \mathbf{m}, \mathbf{l})$ đã tính sẵn, nên mọi truy vấn quy về các phép đại số tuyến tính — nền tảng cho hiệu năng phục vụ ở mức mili-giây (Chương 6).

Chương này đã trình bày các nền tảng lý thuyết và công nghệ làm cơ sở cho hệ

thống, từ mô hình cảm xúc, cơ sở màu sắc, các mô hình biểu diễn âm nhạc và văn bản, đến các phương pháp tổ hợp và sắp xếp, kèm các công thức hình thức hóa cho từng phương pháp. Cách các thành phần này được thiết kế, hiện thực và đánh giá cụ thể cho hai chức năng cốt lõi được trình bày trong chương tiếp theo.

CHƯƠNG 4. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

Chương 3 đã trình bày các nền tảng lý thuyết và công nghệ. Chương này trình bày cách các nền tảng đó được tổ chức thành kiến trúc hệ thống và thiết kế chi tiết cho hai chức năng cốt lõi: gán tọa độ cảm xúc Valence–Arousal cho bài hát, ánh xạ màu sắc sang cùng không gian cảm xúc, và thuật toán truy hồi–chấm điểm–sắp xếp.

4.1 Thiết kế kiến trúc


4.1.1 Kiến trúc tổng thể

Hệ thống được tổ chức theo hai pha tách biệt nhằm đáp ứng yêu cầu phản hồi nhanh: pha ngoại tuyến (offline) và pha phục vụ (serving). Pha ngoại tuyến chịu trách nhiệm trích xuất mọi đặc trưng nặng: embedding âm thanh từ mô hình MuQ, các tín hiệu Valence từ lời, nhịp độ và độ to, rồi tính sẵn tọa độ cảm xúc và các ma trận biểu diễn cho toàn bộ kho nhạc. Pha phục vụ chỉ thực hiện các phép nhân ma trận và xếp hạng trên các đặc trưng đã tính sẵn, nên truy vấn của người dùng được trả về nhanh. Kiến trúc gồm ba tầng theo thứ tự phụ thuộc một chiều (Hình 4.1): tầng dữ liệu và đặc trưng ở dưới cùng, tầng động cơ gợi ý ở giữa, và tầng giao diện ứng dụng trang đơn ở trên cùng. Tầng trên chỉ gọi xuống tầng dưới qua một giao diện lập trình ứng dụng, không có phụ thuộc ngược.


Việc tách hai pha mang lại nhiều lợi ích cụ thể. Về *hiệu năng*, mọi chi phí tính toán đắt (chạy mô hình học sâu để trích embedding, tính tín hiệu cảm xúc) chỉ phải trả một lần ở pha ngoại tuyến; pha phục vụ chỉ còn các phép đại số tuyến tính nên đáp ứng truy vấn trong vài mili-giây (mục 6.2.1). Về *tính tất định*, vì nhãn cảm xúc đã được đóng băng thành bảng tra cứu và không có mô hình nào được suy luận lúc phục vụ, cùng một truy vấn luôn cho cùng kết quả — đáp ứng yêu cầu NFR04. Về *khả năng triển khai*, máy chủ phục vụ không cần GPU hay bộ nhớ lớn để chạy mô hình, chỉ cần đủ RAM giữ các ma trận đặc trưng, nên có thể triển khai trên hạ tầng khiêm tốn. Về *khả năng bảo trì*, ranh giới rõ ràng giữa ba tầng cho phép thay thế một thành phần (ví dụ đổi mô hình embedding âm thanh) mà không ảnh hưởng tầng giao diện, miễn là định dạng tệp đặc trưng được giữ nguyên.

4.1.2 Pha ngoại tuyến và luồng dữ liệu

Pha ngoại tuyến là một chuỗi xử lý biến kho nhạc thô thành bộ đặc trưng phục vụ. Hình 4.2 mô tả luồng dữ liệu: từ tệp âm thanh và lời, hệ thống trích song song embedding MuQ, các tín hiệu Valence từ lời, nhịp độ sạch và độ to; các tín hiệu này được tổ hợp thành tọa độ Valence–Arousal; cuối cùng mọi ma trận biểu diễn



Hình 4.1: Kiến trúc ba tầng của Brightify với phụ thuộc một chiều từ trên xuống




Hình 4.2: Luồng dữ liệu pha ngoại tuyến: trích đặc trưng song song, tổ hợp tọa độ cảm xúc, đóng gói bản phát hành phục vụ

được đóng gói thành một bản phát hành phục vụ.


4.1.3 Pha phục vụ và triển khai

Ở pha phục vụ, động cơ gợi ý nạp toàn bộ đặc trưng vào bộ nhớ một lần lúc khởi động, sau đó mỗi truy vấn chỉ là các phép nhân ma trận. Hình 4.3 mô tả sơ đồ triển khai: trình duyệt chạy ứng dụng trang đơn, gọi máy chủ FastAPI qua REST; máy chủ giữ các ma trận đặc trưng trong bộ nhớ; tệp âm thanh được phục vụ tĩnh (hoặc chuyển hướng qua mạng phân phối nội dung). Bản phát hành đặc trưng do một máy trạm chạy pha ngoại tuyến sinh ra và nạp lên máy chủ.


Về tổ chức mã nguồn, hệ thống được chia thành các gói theo trách nhiệm (Hình 4.4): gói `core` chứa động cơ gợi ý và ánh xạ màu; gói `con core . ranking` chứa các bước truy hồi, nhất quán, đa dạng và hành trình; gói `api` cung cấp các endpoint; gói `frontend` là ứng dụng trang đơn; gói `data` lưu các tệp đặc trưng; và gói `tools` chứa các script ngoại tuyến và đánh giá.



Hình 4.3: Sơ đồ triển khai: trình duyệt ↔ máy chủ FastAPI (giữ đặc trưng trong RAM); bản phát hành đặc trưng do máy trạm ngoại tuyến sinh ra




Hình 4.4: Sơ đồ gói: phụ thuộc một chiều giữa các thành phần mã nguồn



Hình 4.5: Sơ đồ lớp rút gọn: MusicRecommender điều phối và ủy thác hậu xử lý cho core.ranking

4.1.4 Thiết kế lớp động cơ gợi ý

Trung tâm của tầng động cơ là lớp MusicRecommender, giữ trạng thái kho nhạc và các ma trận đặc trưng, đồng thời cung cấp hai phương thức gợi ý chính. Lớp này ủy thác các bước hậu xử lý cho các hàm trong gói core.ranking (Hình 4.5). Cách tách này giữ cho MusicRecommender chỉ điều phối, còn từng bước (truy hồi, nhất quán, đa dạng, hành trình) là các hàm thuần có thể kiểm thử độc lập.



Hình 4.6: Lược đồ thực thể–quan hệ rút gọn của kho đặc trưng phục vụ


4.1.5 Mô hình dữ liệu kho đặc trưng

Dữ liệu phục vụ được tổ chức quanh thực thể trung tâm là *Bài hát*, mỗi bài liên kết với các đặc trưng đã tính sẵn (Hình 4.6). Quan hệ cover là quan hệ nhiều–nhiều giữa các bài (1124 bài gom thành 979 cặp). Các đặc trưng nặng (embedding âm thanh, embedding lời) được lưu thành ma trận căn theo thứ tự bài, còn tọa độ cảm xúc và nhịp độ lưu theo khóa định danh bài.

4.2 Thiết kế chi tiết hai chức năng cốt lõi

4.2.1 Gán tọa độ cảm xúc cho bài hát

Mỗi bài hát được gán một cặp Valence và Arousal, dùng chung cho cả hai chức năng. Valence được tính bằng tổ hợp EWE (Evaluator Weighted Estimator) [40] của bốn tín hiệu, trong đó trọng số tỉ lệ với độ tin cậy đo được của từng tín hiệu (Bảng 4.1). Độ tin cậy của mỗi tín hiệu được đo bằng tương quan Spearman giữa tín hiệu đó với *đồng thuận* của các tín hiệu còn lại; trọng số được ước lượng theo lỗi lặp (Grimm và Kroschel) *một lần* ở pha ngoại tuyến — **không khớp với bất kỳ nhãn hay bộ tham chiếu ngoài nào** — rồi *đóng băng*. Chính vì không có đích ngoài nên cách tổ hợp này *phi vòng tròn* (không “tự chấm điểm cho chính mình”) và đường phục vụ hoàn toàn không gọi mô hình ngôn ngữ lớn. Có thể thấy ba tín hiệu lời chiếm phần lớn trọng số, còn tín hiệu âm thanh chỉ đóng vai trò bổ trợ, phản ánh đúng việc Valence nằm chủ yếu ở nội dung lời. Hình 4.7 trực quan hóa các trọng số này.



Hình 4.7: Trọng số tổ hợp Valence theo độ tin cậy (EWE): ba tín hiệu lời chiếm phần lớn, tín hiệu âm thanh bổ trợ

Bảng 4.1: Các tín hiệu Valence và vai trò trong tổ hợp EWE (trọng số tỉ lệ với độ tin cậy đo được của từng tín hiệu)

Tín hiệu Valence	Vai trò trong tổ hợp EWE	Nguồn
vn_lex (từ điển)	Lời — trọng số lớn (0.35)	NRC-VAD-VN [29] + VnEmoLex [30]
emobank	Lời (liên ngữ) — trọng số lớn (0.34)	XLM-R [33] + EmoBank [16]
vn_sent	Lời (ngữ cảnh VN) — trọng số vừa (0.22)	ViSoBERT [31] + UIT-VSMEC [32]
muq (âm thanh)	Bổ trợ — trọng số nhỏ nhất (0.09)	MuQ [10]

Arousal được tính từ một tổ hợp ba đặc trưng âm thanh: đặc trưng MuQ chiếm 0.574, nhịp độ (số nhịp trên phút) chiếm 0.35 và độ to chiếm 0.076. Phần trọng số giữa MuQ và độ to được hồi quy trên tập DEAM do con người gán nhãn [4], còn trọng số nhịp độ được *nâng có chủ đích* (tinh chỉnh trên DEAM) vì biểu diễn MuQ nắm bắt độ to tốt nhưng nắm bắt nhịp độ yếu. Khi kiểm chứng chéo trên DEAM, tổ hợp này đạt hệ số tương quan 0.69, cao hơn mức 0.647 của biểu diễn MERT trước đó, và tương quan giữa Arousal với nhịp độ đo được đạt 0.47. Thuật toán 1 tóm tắt toàn bộ quy trình gán nhãn.

Algorithm 1: Gán tọa độ cảm xúc Valence–Arousal cho mỗi bài hát

Input: Lời ℓ , embedding MuQ $\mathbf{m}$, nhịp độ t , độ to ρ của bài hát

Output: Cặp (v, a) trong $[0, 1]^2$

$v_{\text{lex}} \leftarrow$ điểm từ điển NRC-VAD-VN/VnEmoLex trên ℓ

$v_{\text{sent}} \leftarrow$ đầu dò ViSoBERT(ℓ); $v_{\text{emo}} \leftarrow$ đầu dò XLM-R(ℓ); $v_{\text{muq}} \leftarrow$ đầu dò MuQ($\mathbf{m}$)

$v \leftarrow \text{EWE}(v_{\text{lex}}, v_{\text{sent}}, v_{\text{emo}}, v_{\text{muq}})$ // trọng số = độ tin cậy, Pt. (3.5)

$a_{\text{muq}} \leftarrow$ đầu dò Arousal MuQ($\mathbf{m}$)

$a \leftarrow$ chuẩn-hóa-hạng $(0.574 \text{rank}(a_{\text{muq}}) + 0.35 \text{rank}(t) + 0.076 \text{rank}(\rho))$

// MuQ/độ-to fit DEAM; nhịp độ chỉnh tay

return chuẩn hóa (v, a) về $[0, 1]^2$


Bộ nhãn V-A này được kiểm hai tính chất. *Tái lập:* chạy lại toàn bộ quy trình từ các tín hiệu nền bằng `tools/build_labels_repro.py` cho ra đúng bộ nhãn đang phục vụ (tương quan Spearman $\rho = 1.00$ trên cả Valence và Arousal). *Hội tụ độc lập:* đối chiếu với một bộ tham chiếu V-A sinh riêng bằng mô hình GPT-4o-mini chỉ đọc lời bài hát (độ tin cậy test–retest ICC = 0.99), bộ nhãn đạt tương quan $\rho = 0.63$ cho Valence và $\rho = 0.41$ cho Arousal trên toàn bộ 5.138 bài — mức đồng thuận có ý nghĩa với một bộ đánh giá hoàn toàn độc lập, trong đó Arousal thấp hơn là hợp lý vì nó được suy từ âm thanh còn GPT chỉ đọc lời.

4.2.2 Ánh xạ màu sắc sang tọa độ cảm xúc

Màu được chuyển sang không gian Oklab [25], sau đó Valence của màu được suy ra bằng hồi quy ridge khớp với chuẩn ICEAS [11], đạt hệ số tương quan 0.969 so với chuẩn này. Arousal của màu được tính theo công thức suy từ quan hệ màu–âm nhạc của Whiteford [12] trong Phương trình (4.1), trong đó độ đỏ và độ bão hòa làm tăng Arousal, còn độ sáng điều chỉnh mức nền. Hình 4.8 tóm tắt luồng ánh xạ này. Cần lưu ý rằng ánh xạ màu–cảm xúc này dựa trên các chuẩn quốc tế (ICEAS, Whiteford) và *chưa được hiệu chỉnh bằng khảo sát người nghe Việt Nam*; do đó nó được xem là một ánh xạ *mang tính thử nghiệm*, với hạn chế về tính đặc thù văn hóa được phân tích ở mục 6.1.6.

$$A = 0.373 \cdot \text{redness} + 0.356 \cdot \text{saturation} + 0.271 \cdot \text{lightness} - 0.10 \quad (4.1)$$

Tính đúng đắn của công thức Arousal được kiểm chứng độc lập bằng nhịp độ thật của các bài được truy hồi: tương quan giữa độ sáng của màu với nhịp độ đạt 0.41 và giữa độ bão hòa với nhịp độ đạt 0.66, đúng theo hướng màu sáng và bão hòa hơn ứng với nhạc nhanh hơn.



Hình 4.8: Luồng ánh xạ màu sắc sang tọa độ Valence–Arousal

4.2.3 Truy hồi, chấm điểm và sắp xếp

Với chức năng gợi ý theo màu, hệ thống chấm điểm độ gần cảm xúc bằng một hàm Gaussian RBF dị hướng (Phương trình (4.2)) với độ rộng trên trục Valence là $\sigma_V = 0.20$ và trên trục Arousal là $\sigma_A = 0.14$, do phân bố Arousal của kho nhạc nén hơn. Việc so khớp được thực hiện trong không gian phân vị (CDF) của kho nhạc (Phương trình (4.3)) để các màu khác nhau thực sự kéo về các vùng cảm xúc khác nhau.

$$s(\mathbf{q}, \mathbf{p}) = \exp\left(-\frac{(q_V - p_V)^2}{2\sigma_V^2} - \frac{(q_A - p_A)^2}{2\sigma_A^2}\right) \quad (4.2)$$

$$\mathbf{q} = (F_V(c_V), F_A(c_A)), \quad F_X(x) = \frac{1}{N} |\{i : X_i \leq x\}| \quad (4.3)$$

trong đó $\mathbf{q}$ là đích phân vị của màu (qua hàm phân phối tích lũy thực nghiệm F của kho nhạc) và $\mathbf{p}$ là phân vị V-A của một bài. Để các bài trong cùng một màu nghe đồng nhất, hệ thống lấy dư một tập ứng viên rồi chọn cụm có độ nhất quán âm thanh cao nhất, đo bằng cosine trên biểu diễn MuQ đã được trừ trung bình để khử dị hướng [41], [42]. Trọng số giữa độ khớp cảm xúc và độ nhất quán âm thanh được đặt ở mức 0.55. Việc đa dạng hóa theo nghệ sĩ *không* dùng một bước MMR riêng mà được thực hiện ngay trong quá trình chọn cụm: mỗi khi một bài được chọn, các bài còn lại cùng nghệ sĩ bị phạt giảm điểm. Cuối cùng, danh sách được sắp xếp thành chuỗi chuyển cảm xúc mượt theo nguyên lý đồng cảm [45]. Thuật toán 2 trình bày toàn bộ quy trình.

Algorithm 2: Gợi ý danh sách phát theo màu

Input: Một hoặc hai mã màu, số kết quả k

Output: Danh sách k bài khớp cảm xúc và nhất quán âm thanh

Ánh xạ mỗi màu sang điểm V-A (Hình 4.8)

if hai màu **then**

 Sinh chuỗi điểm đích theo nguyên lý đồng cảm giữa hai màu
 (iso-principle)

else

 Quy màu về đích phân vị q trong không gian CDF (Pt. (4.3))

Chấm điểm mọi bài bằng RBF dị hướng (Pt. (4.2)); lấy dư tập ứng viên C


Chọn tham lam cụm con của C có độ nhất quán âm thanh cao nhất

(cosine MuQ đã trừ trung bình, trọng số 0.55), đồng thời phạt giảm điểm
các bài trùng nghệ sĩ ngay trong khi chọn để đa dạng hóa


return danh sách đã sắp theo trật tự cảm xúc mượt

Với chức năng gợi ý bài tương tự, điểm tương đồng giữa hai bài là tổ hợp tuyến tính của ba thành phần như trong Phương trình (4.4): tương đồng âm thanh trên biểu diễn MuQ chiếm trọng số 0.76, độ gần cảm xúc chiếm 0.16 và tương đồng nội dung lời chiếm 0.08. Các bản cover và trùng được loại bằng một danh sách dựng sẵn; sau đó kết quả được đa dạng hóa bằng MMR [43] trên biểu diễn lời (e5-large) (hệ số $\lambda = 0.7$, cân bằng độ liên quan với bài nguồn và độ khác biệt giữa các kết quả). Vì các bài cùng một nghệ sĩ thường nằm sát nhau trong không gian biểu diễn, bước MMR này cũng *gián tiếp* giảm hiện tượng một nghệ sĩ chiếm nhiều vị trí. Ngoài ra hệ thống hỗ trợ một tùy chọn vận hành giới hạn cứng số bài tối đa mỗi nghệ sĩ, nhưng tùy chọn này *mặc định tắt* (Thuật toán 3).

$$\text{score} = 0.76 \cdot \cos(\text{MuQ}) + 0.16 \cdot \text{sim}(\text{V-A}) + 0.08 \cdot \cos(\text{lyrics}) \quad (4.4)$$



Hình 4.9: Sơ đồ tuần tự UC01 — gợi ý bài tương tự



Hình 4.10: Sơ đồ tuần tự UC02 — gợi ý theo màu

Algorithm 3: Gợi ý bài hát tương tự

Input: Chỉ số bài nguồn s , số kết quả k , tập loại trừ E (chế độ đài)

Output: Danh sách k bài tương tự

foreach bài $i \neq s, i \notin E$ **do**

 Tính $\text{score}(s, i)$ theo Pt. (4.4)

Loại các bản cover/trùng của s theo chỉ mục cover dựng sẵn

Đa dạng hóa bằng MMR trên biểu diễn lời (e5-large), $\lambda = 0.7$ (Pt. (3.7))

 — gián tiếp giảm trùng nghệ sĩ

(Tùy chọn, mặc định tắt) giới hạn cứng số bài tối đa mỗi nghệ sĩ

return k bài điểm cao nhất

Hai sơ đồ tuần tự trong Hình 4.9 và Hình 4.10 mô tả tương tác giữa các thành phần khi thực thi hai chức năng cốt lõi.

4.2.4 Ví dụ minh họa

Để làm rõ cách hai chức năng vận hành, mục này trình bày hai ví dụ với số liệu thật từ hệ thống. Xét truy vấn gợi ý theo **màu lam** (#0067A5). Hệ thống ánh xạ màu này sang tọa độ cảm xúc $(V, A) = (0.565, 0.358)$: Valence trên mức trung bình và Arousal dưới mức trung bình, tức rơi vào góc phần tư “thư thái / bình yên” (Q4). Tọa độ này được quy về đích phân vị trong phân bố kho nhạc, rồi hàm RBF dị hướng chấm điểm mọi bài theo độ gần với đích; hệ thống lấy dư một tập ứng viên, chọn cụm có độ nhất quán âm thanh cao nhất trên biểu diễn MuQ đã trừ trung bình, và đa dạng hóa theo nghệ sĩ. Kết quả là một danh sách phát gồm các bài nhẹ nhàng, năng lượng thấp, nghe đồng nhất với nhau. Ngược lại, nếu người dùng chọn **màu vàng** (#F3C300) với $(V, A) = (0.767, 0.696)$ — Valence và Arousal đều cao, thuộc góc “vui vẻ / phấn khích” (Q1) — hệ thống trả về các bài sôi động, vui tươi. Sự tương phản rõ rệt giữa hai danh sách phát này chính là biểu hiện trực quan của độ tách biệt giữa các màu mà mục 6.1.2 đo định lượng.

Với chức năng gợi ý bài tương tự, giả sử bài nguồn là một bản ballad có tọa độ cảm xúc gần $(V, A) = (0.54, 0.46)$. Hệ thống tính điểm tổ hợp (Phương trình (4.4)) giữa bài nguồn và mọi bài khác: trọng số lớn nhất dành cho tương đồng âm thanh trên MuQ (nên kết quả “nghe giống” về hòa âm, nhịp điệu), bổ sung bởi độ gần cảm xúc và tương đồng lời. Trước khi trả về, các bản cover/trùng của bài nguồn bị loại theo chỉ mục dựng sẵn (tránh trả về chính bài nguồn dưới một bản phối khác), và bước đa dạng hóa MMR trên biểu diễn lời (e5-large) giúp danh sách không bị một nghệ sĩ chiếm trọn (vì các bài cùng nghệ sĩ nằm gần nhau trong không gian biểu diễn nên bị MMR trải ra). Nếu người nghe tiếp tục yêu cầu (chế độ “đài”), tập loại trừ E được nối thêm các bài đã phát để danh sách không lặp lại.

Các thiết kế chi tiết trên là cơ sở cho quá trình xây dựng và triển khai được trình bày ở Chương 5.

CHƯƠNG 5. XÂY DỰNG VÀ TRIỂN KHAI HỆ THỐNG

Dựa trên thiết kế ở Chương 4, chương này trình bày quá trình xây dựng và triển khai hệ thống: công cụ và mô hình sử dụng, dữ liệu và kho nhạc cùng data pipeline thu thập–xử lý tự động có checkpoint, giao diện lập trình ứng dụng và giao diện người dùng kèm player có crossfade.

5.1 Công cụ và mô hình sử dụng

Bảng 5.1 liệt kê các công cụ và mô hình chính được sử dụng. Toàn bộ mô hình học máy được dùng ở dạng đóng băng; phần huấn luyện duy nhất là các đầu dò tuyến tính (hồi quy ridge) trên các tập dữ liệu công khai. Phần phục vụ được hiện thực bằng FastAPI; giao diện là một ứng dụng trang đơn React. Tầng dữ liệu dùng PostgreSQL 17 kèm pgvector và pg_trgm (truy cập qua SQLAlchemy 2.0, lược đồ quản lý bằng Alembic) để lưu siêu dữ liệu, hạt giống và dữ liệu phụ cho crossfade, cùng tìm kiếm mờ tiếng Việt. Tuy nhiên cần nói rõ: *đường phục vụ truy vấn là file-based* — các đặc trưng tính sẵn được nạp từ tệp `.npy/.json` vào bộ nhớ, nên cơ sở dữ liệu *không* nằm trên đường truy vấn nóng (chỉ nạp một lần lúc khởi động, có cơ chế lùi an toàn nếu thiếu). Toàn hệ thống được đóng gói bằng Docker; pha thu thập dữ liệu ngoại tuyến dùng ytmusicapi, yt-dlp và LRCLIB.

Bảng 5.1: Danh sách công cụ và mô hình chính

Mục đích	Công cụ / mô hình	Nguồn
Ngôn ngữ và xử lý dữ liệu	Python, NumPy, scikit-learn	—
Biểu diễn âm nhạc	MuQ	[10]
Cảm xúc lời (ngữ cảnh VN)	ViSoBERT	[31]
Cảm xúc lời (liên ngữ)	XLM-R	[33]
Tương đồng lời	multilingual-e5-large	[35]
Từ điển Valence	NRC-VAD, VnEmoLex	[29], [30]
Phục vụ (API)	FastAPI (Python)	—
Giao diện	Ứng dụng trang đơn React	—


Mục đích	Công cụ / mô hình	Nguồn
Tàng dữ liệu & tìm kiếm	PostgreSQL 17 + pgvector + pg_trgm	—
ORM & di trú lược đồ	SQLAlchemy 2.0, Alembic	—
Đóng gói & triển khai	Docker (compose)	—
Thu thập dữ liệu	ytmusicapi, yt-dlp, LRCLIB	—

5.2 Dữ liệu và kho nhạc

Kho nhạc phục vụ gồm **5.138 bài hát nhạc Việt**, mỗi bài có tệp âm thanh, siêu dữ liệu (tên bài, nghệ sĩ, album) và lời bài hát. Đây là số bài thực tế mà động cơ gợi ý nạp lên và là cỡ tập đánh giá trong các thực nghiệm ở mục 6.1.

Nguồn dữ liệu. Dữ liệu được thu thập và xử lý tự động qua một *quy trình bảy pha có điểm kiểm tra* (checkpoint) — thu thập, lọc, tải, lấy lời, trích đặc trưng, xử lý nhãn, nạp kho — cho phép chạy lại từng pha độc lập và tiếp tục khi gián đoạn mà không làm lại từ đầu, hoàn toàn không sử dụng dữ liệu người dùng (Hình 5.1): (i) khám phá nghệ sĩ Việt từ siêu dữ liệu Spotify, khởi đầu từ 353 nghệ sĩ hạt giống; (ii) lấy danh sách bài hát, siêu dữ liệu và lời từ YouTube Music; (iii) tải tệp âm thanh bằng yt-dlp theo bốn mức dự phòng (ưu tiên bản nhạc khớp thời lượng) kèm cắt khoảng lặng đầu/cuối; (iv) bổ sung lời bài hát từ dịch vụ LRCLIB. Như vậy Spotify chỉ phục vụ khám phá/định danh nghệ sĩ, còn âm thanh và lời lấy từ YouTube Music và LRCLIB.

Tiền xử lý âm thanh. Trước khi trích embedding, mỗi tệp âm thanh được cắt khoảng lặng ở đầu và cuối để tránh nhiễu cho biểu diễn; việc tải ưu tiên bản nhạc có thời lượng khớp với siêu dữ liệu nhằm loại các bản remix hoặc bản kéo dài bất thường. Nhịp độ được trích bằng phương pháp dò phách (downbeat) của thư viện librosa thay vì dùng giá trị nhịp độ thô, vì giá trị thô dễ bị nhân đôi hoặc chia đôi (nhầm 60 BPM thành 120 BPM); nhịp độ “sạch” này quan trọng vì nó là một trong



Hình 5.1: Quy trình thu thập dữ liệu tự động, không dùng dữ liệu người dùng


ba thành phần của trục Arousal (mục 4.2.1). Các đặc trưng âm thanh từ mô hình Essentia ở tần số lấy mẫu cao bị suy biến nên không được dùng; chỉ giữ lại các đặc trưng tín hiệu số đáng tin như nhịp độ và độ to.

Lời bài hát và xử lý bài thiếu lời. Trên kho hiện tại, **toàn bộ 5.138/5.138 bài (100%) đều có lời** (cờ `has_lyrics`). Hệ thống vẫn có cơ chế dự phòng cho trường hợp thiếu lời: khi một bài không có lời, tín hiệu Valence từ lời không khả dụng nên tọa độ cảm xúc được suy từ các đặc trưng âm thanh (`valence/arousal/energy`) thay thế. Vì kho hiện tại phủ lời 100%, cơ chế này không phải kích hoạt trong thực tế nhưng vẫn bảo đảm hệ thống không gây khi mở rộng kho. Về nguồn lời, phần lớn lấy từ YouTube Music và LRCLIB, một phần (khoảng một phần tư) lấy qua khớp tìm kiếm gần đúng nên có thể lệch bản hoặc khớp nhầm ở số ít trường hợp — đây là một hạn chế chất lượng dữ liệu cần lưu ý, tuy ảnh hưởng được giảm nhẹ vì Valence là tổ hợp nhiều tín hiệu thay vì phụ thuộc một nguồn lời duy nhất. Kho cũng không chứa bài *không lời* (cờ `instrumental` đều bằng 0), nên trường hợp nhạc thuần khí cụ chưa phát sinh.

Xử lý bài trùng và cover. Các phiên bản trùng/cover được phát hiện ở pha ngoại tuyến và lưu thành một chỉ mục dựng sẵn (`cover_index.json`). Việc phát hiện lấy *lời làm tín hiệu chính* (độ tương đồng cosine của lời rất cao tương ứng cùng nội dung) kết hợp khớp tiêu đề đã chuẩn hóa (bắt được cả phiên bản song ngữ cùng bài). Kết quả hiện tại: **1.124 bài** có quan hệ cover, gom thành **979 cặp**. Khi gợi ý bài tương tự, các cover của bài nguồn bị loại để không lãng phí vị trí và tránh trả về “cùng một bài”.

Phạm vi sử dụng và bản quyền dữ liệu. Toàn bộ dữ liệu được thu thập từ các nguồn công khai và *chỉ dùng cho mục đích nghiên cứu, học thuật, phi thương mại*; hệ thống không thu thập hay sử dụng bất kỳ dữ liệu người dùng nào. Các tệp âm thanh (khoảng 17 GB) được lưu cục bộ thuần túy để phục vụ thực nghiệm ngoại tuyến và demo trong khuôn khổ đồ án, không phân phối lại. Vì âm thanh và lời bài hát thuộc bản quyền của các chủ sở hữu tương ứng, một bản triển khai công khai hay thương mại sẽ cần giấy phép phù hợp — chẳng hạn tích hợp qua một dịch vụ kho nhạc/đối tác phát trực tuyến có bản quyền, hoặc thay bằng kho nhạc có giấy phép mở (Creative Commons). Trong phạm vi nghiên cứu, hệ thống được giới hạn ở quy mô demo cục bộ và mọi kết quả đánh giá đều là độ đo ngoại tuyến.

Phân bố cảm xúc của kho nhạc. Hình 5.2a biểu diễn phân bố Valence–Arousal của toàn bộ 5.138 bài, còn Hình 5.2b cho thấy phân bố của từng trục. Có thể thấy trục Arousal nén hơn trục Valence (độ lệch chuẩn ≈ 0.13 so với ≈ 0.18); đây chính là lý do hàm RBF dùng độ rộng nhỏ hơn trên trục Arousal ($\sigma_A = 0.14 < \sigma_V = 0.20$).



Hình 5.2: Phân bố cảm xúc của kho nhạc: trục Arousal nén hơn trục Valence

Vùng năng lượng cao (Arousal lớn) thưa hơn, một hạn chế được nêu lại ở Chương 8.

Lưu trữ đặc trưng. Các đặc trưng nặng được tính sẵn và lưu ra tệp để pha phục vụ nạp vào bộ nhớ (Bảng 5.2). Đặc trưng MuQ được lưu ở `muq_embeddings.npy` dưới dạng ma trận 5138×1024 (số thực 32-bit, đã chuẩn hóa L2) kèm tệp siêu dữ liệu căn theo thứ tự kho nhạc; mô hình thực thể–quan hệ của kho đặc trưng đã được trình bày ở Hình 4.6.

Bảng 5.2: Các tệp đặc trưng tính sẵn được pha phục vụ nạp lên

Đặc trưng	Tệp lưu trữ	Kích thước
Embedding âm thanh MuQ	<code>muq_embeddings.npy</code>	5138×1024
Embedding nội dung lời	<code>lyrics_e5large.npy</code>	5138×1024
Tọa độ cảm xúc (V-A)	<code>emotion_labels_v6i.json</code>	5138 mục
Nhịp độ sạch (BPM)	<code>clean_bpm.json</code>	theo bài
Chỉ mục cover/trùng	<code>cover_index.json</code>	1124 bài

5.3 Giao diện lập trình ứng dụng

Tầng phục vụ được hiện thực bằng FastAPI và cung cấp một tập endpoint cho ứng dụng trang đơn (Bảng 5.3). Các phản hồi dùng một phong bì JSON nhất quán với trường `success` và phần dữ liệu (`results/songs/song`), kèm message khi cần.

Bảng 5.3: Các endpoint cốt lõi của giao diện lập trình ứng dụng (toàn hệ thống có khoảng 22 endpoint)

Phương thức	Đường dẫn	Chức năng
POST	/api/recommend/color	Gợi ý danh sách phát theo 1–2 màu (UC02)
GET	/api/song/{id}/similar	Gợi ý bài tương tự (UC01)
GET	/api/song/{id}	Chi tiết + thông tin cảm xúc của bài (UC04)
GET	/api/songs	Duyệt/lọc/sắp xếp kho nhạc (UC03)
GET	/api/search	Tìm kiếm theo tên/nghe sĩ/lời/cảm giác
GET	/api/audio/stream/{id}	Phát tệp âm thanh (hoặc chuyển hướng CDN)

Mỗi bài trong kết quả gồm: chỉ số (`song_index`), định danh (`track_id`), tên bài, nghệ sĩ, mã màu tâm trạng (`color_hex`), các giá trị Valence/Arousal/Energy và nhãn góc phần tư cảm xúc (`mood_quadrant`). Với gợi ý theo màu, mỗi bài kèm một đối tượng giải thích `why` gồm: câu giải thích tiếng Việt (`reason`), tín hiệu mạnh nhất (`top_signal`), điểm khớp cảm xúc (`mood_match`) và tọa độ V-A của bài (`song_va`) so với của màu (`color_va`). Với gợi ý bài tương tự, mỗi bài kèm điểm `similarity_score` cùng cờ và đường dẫn phát âm thanh. Quan hệ màu→cảm xúc tổng quát được trả riêng ở khối siêu dữ liệu `query.bridge` (và `query.journey` khi chọn hai màu), *không* nằm trong từng `why`.

Xử lý lỗi ở biên. Hệ thống xác thực đầu vào và xử lý các trường hợp biên một cách tường minh: mã màu không hợp lệ (không đúng dạng `#RRGGBB`) bị từ chối bằng lỗi xác thực đầu vào; bài hát không tồn tại trả về mã 404; bài thiếu lời thì trường `lyrics` trả về rỗng (không phải lỗi); bài thiếu một đặc trưng âm thanh thì trường tương ứng trả về rỗng thay vì gây lỗi; định danh sai định dạng khi phát trả về mã 400 và tệp âm thanh không có trả về 404. Các endpoint gợi ý có giới hạn tần suất để tránh quá tải.

5.4 Giao diện người dùng


Giao diện là một ứng dụng trang đơn React, cung cấp **hai giao diện (skin) dùng chung một logic gợi ý**: (i) giao diện “đắm chìm” 3D mô phỏng hệ mặt trời, trong đó mỗi màu là một hành tinh và hành trình hai màu là một chuyến bay; và (ii) giao diện “classic” 2D theo phong cách trình phát nhạc quen thuộc. Người dùng đổi qua lại giữa hai giao diện và lựa chọn được lưu cục bộ.

Các màn hình chính gồm: màn chọn màu (bảng 12 màu/hành tinh), màn kết quả danh sách phát theo màu, màn duyệt và chọn bài hát, màn kết quả bài tương tự (chế độ “đài”), bảng lời bài hát, thanh phát nhạc, ô tìm kiếm và lớp hướng dẫn sử dụng. Tâm trạng (Valence–Arousal) của mỗi bài được thể hiện trực quan qua màu nền ảnh bìa và một nhãn tâm trạng ngắn hiện khi đổi bài. Hai giao diện này không phải hai ứng dụng tách biệt mà là hai “lớp da” (skin) khác nhau trên cùng một logic gợi ý và cùng một tầng dữ liệu: mọi lời gọi API, mọi kết quả và cách xử lý đều dùng chung, chỉ khác ở cách trình bày. Giao diện 3D phù hợp với trải nghiệm khám phá giàu cảm xúc (mỗi màu là một hành tinh, hành trình hai màu là một chuyến bay), trong khi giao diện 2D quen thuộc với người dùng đã quen các trình phát nhạc thông thường. Việc chia sẻ logic giữa hai giao diện vừa giảm trùng lặp mã nguồn vừa bảo đảm hành vi gợi ý nhất quán bất kể người dùng chọn giao diện nào.


Ngoài ra, trình phát hỗ trợ chuyển bài mượt (crossfade) dựa trên các điểm cue và độ to (LUFS) đã tính sẵn: hệ thống bắt đầu làm mờ bài đang phát và đưa bài kế tiếp vào tại các điểm chuyển hợp lý, đồng thời cân bằng độ to giữa hai bài để tránh chênh lệch âm lượng đột ngột. Đây là tính năng phát nhạc bổ trợ, không nằm trong hai chức năng cốt lõi của đồ án.

Cần nêu rõ một điểm trung thực về mức hoàn thiện: dữ liệu cảm xúc đã được tính và *cung cấp đầy đủ qua API* (tọa độ V-A, nhãn tâm trạng, đối tượng *why*, cầu nối màu→cảm xúc), nhưng một *màn chi tiết hiển thị tọa độ Valence–Arousal dạng số* và một *bảng giải thích “vì sao bài được gợi ý”* chưa được dựng thành màn riêng trong giao diện hiện tại; chúng được xem là hướng hoàn thiện trình bày ở Chương 8. Các màn hình chính (ảnh chụp từ bản triển khai thực tế, giao diện “classic” 2D) được minh họa lần lượt như sau: với chức năng gợi ý theo màu là màn chọn màu (Hình 5.3) và màn kết quả danh sách phát theo màu với ảnh bìa nhuộm theo tâm trạng (Hình 5.4); với chức năng gợi ý bài tương tự là màn duyệt/chọn bài hát (Hình 5.5) và màn kết quả bài tương tự ở chế độ “đài” nối tiếp (Hình 5.6).


Hệ thống sau khi xây dựng được thử nghiệm và đánh giá ở Chương 6.




Hình 5.3: Màn chọn màu để gợi ý danh sách phát — giao diện “classic” 2D (UC02)



Hình 5.4: Màn kết quả danh sách phát theo màu (ví dụ tâm trạng “Ngọc”) (UC02, UC03)



Hình 5.5: Màn duyệt thư viện và chọn bài hát để tìm bài tương tự (UC01, UC03)



Hình 5.6: Màn kết quả bài tương tự ở chế độ “đài” nối tiếp (UC01, UC03)

CHƯƠNG 6. THỬ NGHIỆM VÀ ĐÁNH GIÁ

Chương này trình bày quá trình thử nghiệm và đánh giá hệ thống đã xây dựng ở Chương 5: phương pháp và dữ liệu đánh giá, kết quả cho hai chức năng cốt lõi, khảo sát so sánh mô hình, phân tích độ nhạy của trọng số, thời gian phản hồi đo được và kiểm thử chức năng hệ thống.

6.1 Đánh giá thực nghiệm

Do không có dữ liệu người dùng, hệ thống được đánh giá bằng nhiều tầng độ đo ngoại tuyến không vòng tròn, bổ sung bằng các kiểm chứng độc lập (nhịp độ thật, chuyển miền sang tập khác). Nguyên tắc xuyên suốt là độ đo cuối quyết định việc chấp nhận một thành phần, và mọi thay đổi phải vượt một cổng kiểm định không thụt lùi.

6.1.1 Phương pháp và dữ liệu đánh giá

Tập đánh giá là toàn bộ **5.138 bài hát** của kho nhạc. Chức năng gợi ý theo màu được đánh giá trên **12 màu cơ bản** (theo Berlin & Kay [46], cũng là 12 màu mà ICEAS [11] khảo sát) với mỗi truy vấn lấy $top-k = 10$.

Vì không có tập nhạc Việt được con người gán nhãn màu–cảm xúc, **ground truth cho gợi ý theo màu không phải nhãn người** mà được tạo theo phương pháp hiệu chỉnh phân bố kho nhạc [19]: mỗi màu được ánh xạ thành một tọa độ Valence–Arousal, rồi quy về *đích phân vị* tương ứng trong phân bố tích lũy (CDF) của kho nhạc. Độ đo chính là *sai số nhắm trúng đích* (targeting error, TE) theo Phương trình (6.1): khoảng cách Euclid trong không gian phân vị giữa đích phân vị của màu truy vấn và phân vị V-A của các bài được gợi ý, lấy trung bình trên các bài rồi trung bình trên 12 màu.

$$TE = \frac{1}{|C|} \sum_{c \in C} \frac{1}{k} \sum_{s \in top-k(c)} \|q_c - p_s\|_2 \quad (6.1)$$

trong đó C là tập 12 màu, q_c là đích phân vị của màu c và p_s là phân vị V-A của bài s . Đây là một độ đo ngoại tuyến và *tự tham chiếu* (đo trên chính nhãn V-A dùng để khớp); hạn chế này được nêu rõ ở cuối mục. Để tránh kết luận chỉ dựa vào một độ đo tự tham chiếu, TE được bổ sung bằng các kiểm chứng độc lập với nhãn (nhịp độ thật, chuẩn ICEAS, chuyển miền PMEmo) trình bày bên dưới. Các số liệu trong mục này được sinh bởi bộ công cụ đánh giá ngoại tuyến (`tools/color_eval_rigor.py`, `tools/color_ablation.py`) và có thể chạy lại để tái lập.


Phương pháp so sánh và lựa chọn mô hình. Với mỗi vị trí có thể thay mô hình (trực biểu diễn âm thanh, embedding lời, các đầu dò cảm xúc, mô hình màu–cảm xúc), việc lựa chọn không dựa vào thứ hạng trên các bộ chuẩn quốc tế — vì “tốt trên giấy” không bảo đảm tốt cho nhiệm vụ và dữ liệu cụ thể của hệ thống — mà tuân theo năm nguyên tắc. Thứ nhất, (i) phán quyết bằng *độ đo cuối* gắn với chính nhiệm vụ: NDCG trên ground truth tương đồng âm nhạc cho gợi ý bài tương tự, TE cùng các kiểm chứng độc lập cho gợi ý theo màu, và R^2 kiểm chứng chéo trên DEAM cho các đầu dò cảm xúc. Thứ hai, (ii) *so sánh có kiểm soát*: chỉ thay đúng thành phần cần so, giữ nguyên mọi phần còn lại. Thứ ba, (iii) *tinh chỉnh lại siêu tham số riêng* cho từng ứng viên trước khi so, vì kế thừa thiết lập của mô hình cũ có thể khiến một mô hình thực sự tốt hơn lại bị đánh giá là kém. Thứ tư, (iv) bảo đảm tính vững và chống hiện tượng “tối ưu hóa chính độ đo” bằng kiểm chứng chéo k -fold (tinh chỉnh trên fold huấn luyện, chấm trên fold tách riêng), khoảng tin cậy bootstrap và kiểm định ý nghĩa (Wilcoxon kèm hiệu chỉnh FDR), kèm *tam giác hóa* bằng một tín hiệu độc lập (chuyển miền sang tập khác hoặc một bộ chấm độc lập). Cuối cùng, (v) chỉ chấp nhận thay thế khi ứng viên *thắng hoặc hòa* trên độ đo cuối và vượt *cổng không thụt lùi*, ưu tiên mô hình gọn/nhẹ hơn khi hòa. Kết quả áp dụng quy trình này cho toàn bộ các thành phần được trình bày ở mục 6.1.4.

6.1.2 Đánh giá chức năng gợi ý theo màu

Bảng chứng *chính* cho chức năng này là các kiểm chứng độc lập với nhãn (khớp chuẩn người ICEAS và nhịp độ thật, trình bày bên dưới); sai số nhắm đích (TE) — vì tự tham chiếu — chỉ đóng vai trò một *điều kiện cần*. Cấu hình hiện tại đạt **TE** = 0.0242 với khoảng tin cậy bootstrap 95% là [0.0219, 0.0263]. Bảng 6.1 và Hình 6.1 so sánh với năm phương pháp nền. Hệ thống vượt cả bốn phương pháp nền thực (ngẫu nhiên, theo độ phổ biến, chỉ Valence, chỉ Arousal): kiểm định Wilcoxon kèm hiệu chỉnh tỉ lệ phát hiện sai Benjamini–Hochberg [47] cho **4/4 bác bỏ giả thuyết không với p hiệu chỉnh** = 0.00031. Hệ thống không vượt phương pháp nền “lân cận V-A tham lam” — đây là một *trần lý thuyết* (oracle) cố tình loại bỏ đa dạng nên không phải đối thủ công bằng; việc kết quả *tiệm cận* trần này cho thấy cơ chế đa dạng hóa chỉ làm tăng TE rất ít.

Bảng 6.1: Sai số nhắm đích (TE) của hệ thống so với các phương pháp nền


Phương pháp	TE	Ghi chú
Ngẫu nhiên	0.561	phương pháp nền
Theo độ phổ biến	0.513	phương pháp nền



Hình 6.1: So sánh TE của Brightify với các phương pháp nền (thấp hơn là tốt hơn); Brightify tiệm cận trần lý thuyết (oracle)

Phương pháp	TE	Ghi chú
Chỉ Valence	0.438	loại bỏ một trục
Chỉ Arousal	0.292	loại bỏ một trục
Lân cận V-A tham lam (oracle)	0.021	trần lý thuyết, không đa dạng
Brightify (V-A RBF)	0.0242	CI95 [0.0219, 0.0263]

Các kiểm chứng độc lập đều theo đúng hướng kỳ vọng. Valence của màu khớp chuẩn ICEAS với hệ số tương quan 0.969 (khoảng tin cậy Fisher-z [0.889, 0.991]); do chỉ có $n = 12$ màu nên khoảng tin cậy rộng, và kiểm chứng giữ-một-ra (LOO-CV) cho $r \approx 0.87$. Công thức Arousal của Whiteford được kiểm bằng nhịp độ thật: $\rho(\text{độ sáng, BPM}) = 0.41$ và $\rho(\text{độ bão hòa, BPM}) = 0.66$. Hình 6.2a cho thấy 12 màu được ánh xạ vào các vùng cảm xúc khác nhau trên mặt phẳng V-A. Bảng 6.2 và Hình 6.2b cho thấy đóng góp của hai cải tiến chính: so khớp trong không gian phân vị nâng **độ tách biệt giữa các màu từ 0.13 lên 0.31**, còn việc trừ trung bình khi đo nhất quán âm thanh nâng **độ nhất quán từ khoảng 0.02 lên 0.23**. Với hành trình hai màu, kiểm định Kolmogorov–Smirnov so với phân bố đều cho $KS = 0.21$ (đạt) và độ chênh nhịp độ giữa các bước giảm từ 31 xuống 2.7 BPM.



Hình 6.2: Trái: 12 màu kéo về các vùng cảm xúc khác nhau; Phải: mỗi cải tiến nâng độ tách biệt và độ nhất quán

Bảng 6.2: Ablation: mỗi cải tiến đóng góp vào tách biệt và nhất quán (12 màu, $top-k = 10$)

Cấu hình (cộng dồn)	Tách biệt	Nhất quán	TE
So khớp phân vị (cơ sở)	0.129	0.015	0.0217
+ Đích theo CDF	0.225	0.026	0.0229
+ Nhất quán âm thanh (trừ trung bình)	0.224	0.113	0.0213
+ Arousal Whiteford	0.314	0.228	0.0242

Các kết quả này có một số hạn chế cần nêu thẳng: (i) TE là độ đo *tự tham chiếu* (offline), chưa có nghiên cứu nghe thực tế của người dùng; (ii) ánh xạ màu–cảm xúc là *ngoại suy*: liên kết màu–cảm xúc tuy có khuôn mẫu phổ quát nhưng vẫn mang tính đặc thù văn hóa [48], trong khi Việt Nam không nằm trong 30 quốc gia của khảo sát ICEAS; trục Valence–Arousal được ghi nhận ổn định xuyên văn hóa [15] song chưa có chuẩn màu–cảm xúc bản địa cho Việt Nam; (iii) màu ấm và bão hòa (nâu, hồng) được đọc là “năng lượng cao” — điều này *trung thành* với quan hệ màu–âm nhạc của Whiteford dù có thể nghịch trực giác.

6.1.3 Đánh giá chức năng gợi ý bài tương tự

Chức năng này được đánh giá trên các độ đo nội tại (80 bài hạt giống) và trên độ lợi NDCG [19] đối chiếu với các danh sách phát biên tập, theo tinh thần dùng phương pháp nền mạnh trong đánh giá hệ gợi ý [20]. Độ nhất quán tâm trạng (MoodCoherence) đo mức các bài kết quả cụm chặt trong không gian V-A, định

nghĩa theo Phương trình (6.2); độ nhất quán nhịp độ (TempoCoherence) định nghĩa tương tự trên nhịp độ.

$$\text{MoodCoherence} = 1 - \frac{2}{k(k-1)} \sum_{i < j} \|\mathbf{p}_i - \mathbf{p}_j\|_2 \quad (6.2)$$

Về độ đo nội tại (80 bài hát giống, $\text{top-}k = 10$), MoodCoherence đạt ≈ 0.94 và TempoCoherence đạt ≈ 0.84 — các bài kết quả cụm chặt cả về cảm xúc lẫn nhịp độ.

Ground truth tương đồng âm nhạc (độ đo chính). Để đánh giá đúng mức “nghe giống nhau”, đồ án xây dựng một tập ground truth *tương đồng âm nhạc* gồm 52 bài hát giống, mỗi cặp được chấm theo thang liên quan 0–3. Với mỗi bài hát giống (lấy phân tầng theo cảm xúc để phủ đều các vùng Valence–Arousal), tập ứng viên được gộp theo lối TREC: hợp của nhóm bài hệ thống xếp hạng cao nhất và một nhóm bài lấy ngẫu nhiên làm đối chứng, tổng cộng 1.048 cặp. Bộ chấm được hướng dẫn chỉ xét *chất nhạc* (thể loại, nhịp–tiết tấu, mức năng lượng, độ “nhảy”, giọng trưởng/thứ, không khí tổng thể), coi lời là gợi ý phụ và *bỏ qua nghệ sĩ lẫn độ phổ biến*; nhờ vậy hạn chế được thiên lệch theo cùng nghệ sĩ, và phía hệ thống cũng đa dạng hóa nghệ sĩ kèm lọc bản cover nên tỉ lệ kết quả cùng nghệ sĩ ở mức thấp (≈ 0.05). Một lo ngại với ground truth do mô hình sinh là nó có thể là tạo tác của *một* bộ chấm duy nhất; vì vậy toàn bộ 1.048 cặp được chấm lại độc lập bằng *hai mô hình của hai nhà cung cấp khác nhau* (qwen3:8b cục bộ và GPT-4o-mini). Hai bộ chấm đồng thuận gần như tuyệt đối (Bảng 6.3): Spearman $\rho = 0.946$, đồng thuận nhị phân 0.99 và Cohen $\kappa = 0.958$ — cho thấy ground truth không phải hiện tượng riêng của một bộ chấm duy nhất. Trên tập này, hệ thống đạt NDCG@10 kiểm-chứng-chéo ≈ 0.73 (chi tiết khảo sát backbone ở mục 6.1.4). Việc dùng mô hình ngôn ngữ làm bộ chấm là một lựa chọn *thay thế* cho gán nhãn người trong điều kiện không tồn tại tập tương đồng nhạc Việt do người chấm; cách làm này theo tiền lệ gần đây trong đánh giá tương đồng âm nhạc và đã được giảm rủi ro bằng đồng thuận hai nhà cung cấp ở trên, song một nghiên cứu nghe với người thật vẫn là kiểm chứng cần thiết (Chương 8). Ngoài ra, dù tiếp cận theo nội dung giúp giảm phụ thuộc dữ liệu người dùng, hệ thống không hoàn toàn miễn nhiễm *cold-start*: một bài hoặc nghệ sĩ mới chưa có đặc trưng ngoại tuyến sẽ chưa được gợi ý cho tới khi chạy lại pha trích đặc trưng.

NDCG trên danh sách phát biên tập (độ đo phụ, đọc kèm phương pháp nền). Trên 872 truy vấn từ danh sách phát biên tập, đo bằng độ lợi tích lũy chiết khấu chuẩn hóa NDCG [18] (Phương trình (6.3)), hệ sản phẩm đạt NDCG@10 ≈ 0.066 (tái lập bằng `tools/eval_editorial_ndcg.py`). Tuy nhiên độ đo

này *không phù hợp* làm thước đo chính cho gợi ý bài tương tự: một phương pháp nền *theo độ phổ biến* (chọn 10 bài theo tần suất nghệ sĩ) đạt 0.091 — *cao hơn* hệ sản phẩm — trong khi phương pháp nền ngẫu nhiên chỉ đạt 0.036 (Bảng 6.4). Đây không phải do hệ kém: danh sách phát biên tập *thưởng* cho độ phổ biến và đồng-xuất-hiện, đồng thời *phạt* chính cơ chế đa dạng nghệ sĩ (MMR) và lọc bản cover mà hệ cố ý áp dụng — đúng như cảnh báo về việc dùng độ đo đại diện yếu trong đánh giá hệ gợi ý [20]. Do đó đề án dùng ground truth tương đồng âm nhạc cùng các độ đo nội tại làm thước đo chính, còn NDCG biên tập chỉ để tham khảo xu hướng.

$$\text{NDCG}@k = \frac{\text{DCG}@k}{\text{IDCG}@k}, \quad \text{DCG}@k = \sum_{i=1}^k \frac{rel_i}{\log_2(i+1)} \quad (6.3)$$


Bảng 6.3: Đồng thuận hai bộ chấm độc lập trên ground truth tương đồng âm nhạc (1.048 cặp)

Chỉ số đồng thuận qwen3:8b ↔ GPT-4o-mini	Giá trị
Spearman ρ (thang liên quan 0–3)	0.946
Đồng thuận nhị phân (liên quan ≥ 2)	0.99
Cohen κ	0.958

Bảng 6.4: NDCG@10 trên danh sách phát biên tập kèm phương pháp nền (đọc kèm cảnh báo Dacrema)

Phương pháp	NDCG@10	× ngẫu nhiên
Theo độ phổ biến (phương pháp nền)	0.091	2.5×
Sản phẩm (Brightify)	0.066	1.8×
Ngẫu nhiên (phương pháp nền)	0.036	1.0×

Khả năng chuyển miền của các đầu dò cảm xúc được kiểm trên tập PMemo [5] (Hình 6.3), đạt tương quan 0.69 cho Valence và 0.65 cho Arousal, cho thấy đầu dò nắm bắt cảm xúc thật chứ không phải hiện tượng riêng của tập huấn luyện; một kiểm chứng arousal độc lập bằng đặc trưng âm thanh khác (CLAP [49]) cho tương quan 0.46.



Hình 6.3: Chuyển miền các đầu dò cảm xúc sang tập PMemo độc lập (tương quan Spearman, kèm khoảng tin cậy)

6.1.4 Khảo sát so sánh mô hình

Để kiểm tra mỗi thành phần học máy có phải là lựa chọn tốt theo độ đo cuối hay không (trong phạm vi các ứng viên đã khảo sát), đồ án tiến hành một khảo sát so sánh trên **năm vị trí có thể thay mô hình**, với tổng cộng hơn mười mô hình tiên tiến được tải về và chạy thực tế; mỗi ứng viên được tinh chỉnh siêu tham số riêng trước khi so và được phán quyết bằng độ đo cuối theo phương pháp ở mục 6.1.1. Bảng 6.6 tóm tắt toàn bộ khảo sát, còn Bảng 6.5 trình bày sâu một head-to-head công bằng tiêu biểu (MuQ so với MERT). Điểm đáng chú ý xuyên suốt là phần lớn các mô hình “mạnh trên giấy” theo bộ chuẩn quốc tế lại *không* vượt được độ đo cuối của hệ thống: MuQ-MuLan tối ưu cho việc ghép văn bản–nhạc nên cho sai số màu và độ nhất quán kém hơn MuQ; multilingual-e5-large [35] thắng các mô hình embedding lời còn lại (kể cả mô hình tiếng Việt tiên nhiệm) về độ nhất quán nội tại ở mọi trọng số; PhoBERT-large chỉ ngang ViSoBERT (ViSoBERT gọn hơn và hợp văn phong lời nhạc hơn); mDeBERTa-v3 kém XLM-R ở vai trò đầu dò liên ngữ; và với trục Arousal của màu, mô hình màu–nhạc của Whiteford được chọn thay cho Valdez–Mehrabian và bản hồi quy theo chuẩn ICEAS vì hai bản sau khớp arousal *màu khi nhìn* (coi màu tối là kích thích) — cấu trúc sai cho một hệ gợi ý nhạc. Kết quả này củng cố nguyên tắc đánh giá bằng độ đo cuối thay vì thứ hạng trên bộ chuẩn. Ngoài các thành phần phục vụ, hệ thống còn dùng CLAP làm một kiểm chứng arousal độc lập (mục 6.1.3) và đã thử nhưng *loại* bộ đặc trưng Essentia do đặc trưng suy biến ở tần số lấy mẫu 44.1 kHz. Chi tiết phân tích khảo sát này được trình bày ở Chương 7.

Lựa chọn trục biểu diễn âm thanh (MuQ so với MERT). Việc chọn MuQ thay cho MERT được kiểm bằng một so sánh *công bằng*: chuyển backbone thật

và *tối ưu lại trọng số tổ hợp riêng cho từng backbone* bằng kiểm chứng chéo 5-fold trên ground truth tương đồng âm nhạc (Bảng 6.5). Trên các độ đo trực tiếp, hai backbone gần như *ngang nhau* (NDCG kiểm-chứng-chéo 0.735 so với 0.734; NDCG chỉ-âm-thanh 0.748 so với 0.742 — chênh lệch không có ý nghĩa thống kê), và sai số màu TE coi như hòa. Khác biệt có ý nghĩa nằm ở *phép chuyển giao sang một bộ chấm độc lập* (GPT-4o-mini): ở đó MuQ vượt MERT 0.806 so với 0.771 (khoảng tin cậy bootstrap cặp $[+0.014, +0.056]$, có ý nghĩa thống kê). Cùng với việc MuQ thắng ở đầu dò Arousal trên DEAM (0.69 so với 0.647, mục 4.2.1), kết quả cho thấy MuQ *ngang hoặc hơn* MERT ở mọi mặt và việc chọn MuQ là hợp lý. Lưu ý phương pháp: trọng số tổ hợp tối ưu theo kiểm chứng chéo hội tụ về gần như chỉ-âm-thanh; trọng số sản phẩm 0.76/0.16/0.08 đánh đổi rất ít NDCG để tăng độ nhất quán cảm xúc.

Bảng 6.5: So sánh công bằng MuQ với MERT (mỗi backbone tối ưu trọng số riêng)

Phép đo	MuQ	MERT
NDCG@10 kiểm-chứng-chéo (GT tương đồng âm nhạc)	0.735	0.734
NDCG@10 chỉ-âm-thanh (cô lập backbone)	0.748	0.742
NDCG@10 chuyển sang bộ chấm độc lập (GPT)	0.806	0.771
Tương quan Arousal kiểm-chứng-chéo trên DEAM	0.69	0.647

Bảng 6.6: Khảo sát so sánh mô hình trên năm vị trí (mô hình được chọn in đậm)


Vị trí	Được chọn	Ứng viên đã so sánh	Phán quyết trên độ đo cuối
Biểu diễn âm thanh	MuQ	MERT, MuQ-MuLan	MuQ $\geq$ MERT (Bảng 6.5); MuLan kém sai số màu và nhất quán vì tối ưu ghép văn bản-nhạc

Vị trí	Được chọn	Ứng viên đã so sánh	Phán quyết trên độ đo cuối
Embedding lời	multilingual-e5-large	VN-SBERT (tiền nhiệm), BGE-M3, PhoBERT-large, mDeBERTa	Thắng độ nhất quán nội tại ở 200 hạt giống, mọi trọng số
Cảm xúc lời (VN)	ViSoBERT	PhoBERT-large, wonrax-sentiment, ViDeBERTa	PhoBERT-large chỉ ngang (sau khi bật tách từ); ViSoBERT gọn và hợp văn phong lời hơn
Cảm xúc liên ngữ	XLM-R	mDeBERTa-v3	mDeBERTa + gộp trung bình vẫn kém CCC
Màu → Arousal	Whiteford 2018	Valdez–Mehrabian, hồi quy ICEAS	Whiteford đúng cấu trúc màu–nhạc (kiểm bằng BPM thật); hai bản kia khớp arousal màu khi nhìn nên màu tối hóa “năng lượng cao” sai


6.1.5 Phân tích độ nhạy của trọng số

Một phần trọng số trong hệ thống không được khớp trực tiếp từ dữ liệu người gán mà được *đặt theo nguyên tắc* (trọng số nhịp độ trong Arousal, bằng thông σ của RBF màu) hoặc *đánh đổi có chủ đích* giữa hai mục tiêu (trọng số V-A trong tổ hợp gợi ý bài tương tự). Để chứng minh các giá trị đang phục vụ không phải lựa chọn tùy tiện, đồ án thực hiện một phân tích độ nhạy: quét quanh mỗi giá trị và quan sát độ đo cuối thay đổi ra sao. Phân tích này *không* thay đổi gì trong hệ đang chạy — nó chỉ đo trên bộ nhớ và có thể tái lập bằng `tools/tune_muq_arousal.py` và `tools/sensitivity_analysis.py`.

Trọng số nhịp độ (Arousal). Đây là một *đánh đổi*, không phải điểm phẳng: tăng trọng số nhịp độ giúp Arousal bám nhịp độ thật tốt hơn nhưng làm giảm độ chính xác kiểm-chứng-chéo trên DEAM (Hình 6.4). Giá trị phục vụ 0.35 nằm trong vùng hợp lệ: nó đạt $\rho(\text{Arousal}, \text{BPM}) = 0.47$ (vượt xa mục tiêu 0.20) trong khi vẫn giữ $\text{DEAM-CV} = 0.69$, cao hơn cổng không-thụt-lùi 0.647. Tăng lên 0.45 sẽ phá cổng này (DEAM-CV tụt còn 0.61), nên cửa sổ hợp lệ là khoảng $[0.25, 0.40]$ và 0.35



Hình 6.4: Độ nhạy của trọng số nhịp độ: vùng xanh là cửa sổ hợp lệ ($\text{DEAM-CV} \geq 0.647$ và $\rho(A, \text{BPM}) \geq 0.20$); giá trị phục vụ 0.35 nằm trong vùng này




Hình 6.5: Độ nhạy của bảng thông σ (RBF màu): TE gần như phẳng trên toàn lưới quét, xác nhận hệ bền với lựa chọn σ

được chọn để bám nhịp độ mạnh nhất trong cửa sổ đó.

Bảng thông σ của RBF màu. Ngược lại, kết quả gợi ý theo màu *rất bền* với lựa chọn σ : khi quét σ_V trong $[0.12, 0.28]$ và σ_A trong $[0.08, 0.20]$, sai số nhắm đích (TE) chỉ dao động chưa tới 0.003 (Hình 6.5). Điều này cho thấy giá trị phục vụ ($\sigma_V = 0.20$, $\sigma_A = 0.14$) — được đặt theo tỉ lệ độ tin cậy của hai trục (arousal đáng tin hơn nên σ hẹp hơn) — không phải tham số mong manh; kết luận không phụ thuộc vào con số chính xác.

Trọng số V-A trong gợi ý bài tương tự. Đây là một đánh đổi được công bố thẳng. Khi tăng trọng số V-A từ 0, NDCG@10 (trên ground truth tương đồng âm nhạc) đạt cao nhất ở mức gần *chỉ-âm-thanh* rồi giảm dần, trong khi độ nhất quán cảm xúc (MoodCoherence) tăng mạnh (Hình 6.6, Bảng 6.7). Giá trị phục vụ 0.16 đúng là điểm *khuyết*: đi từ 0 lên 0.16, MoodCoherence nhảy từ 0.83 lên 0.95 (+0.12)



Hình 6.6: Đánh đổi NDCG ↔ MoodCoherence theo trọng số V-A: giá trị phục vụ 0.16 là điểm khuỷu — gần như toàn bộ lợi ích nhất quán cảm xúc đạt được với chi phí NDCG nhỏ

trong khi NDCG chỉ giảm ≈ 0.003 ; vượt quá 0.16 thì NDCG tiếp tục giảm còn MoodCoherence gần như bão hòa. Nói cách khác, 0.16 thu gần như toàn bộ phần lợi về nhất quán cảm xúc với chi phí NDCG rất nhỏ. (Lưu ý: giá trị NDCG tuyệt đối ở đây thấp vì được tính bằng cách xếp hạng *toàn bộ kho nhạc* rồi đối chiếu với tập đã chấm nhỏ, khác với NDCG kiểm-chứng-chéo trên pool ở mục 6.1.4; chỉ *xu hướng tương đối* giữa các trọng số là điều cần đọc.)

Bảng 6.7: Độ nhạy của trọng số V-A trong gợi ý bài tương tự (52 hạt giống ground truth tương đồng âm nhạc)

Trọng số V-A	Trọng số âm thanh	NDCG@10 (xu hướng)	MoodCoherence
0.00	0.92	0.0414	0.833
0.08	0.84	0.0362	0.924
0.16 (phục vụ)	0.76	0.0386	0.948
0.24	0.68	0.0335	0.957
0.32	0.60	0.0299	0.964

Tổng hợp lại, phân tích độ nhạy cho thấy: ở những trục đặt theo nguyên tắc (σ), kết quả bền với lựa chọn chính xác; còn ở những trục mang tính đánh đổi (nhịp độ, V-A), giá trị phục vụ nằm đúng vùng/điểm cân bằng đã nêu lý do. Không có trọng số nào được chọn cảm tính mà không kiểm chứng vùng lân cận.

6.1.6 Bàn luận và mối đe dọa tính hợp lệ

Tổng hợp lại, các kết quả trên cho thấy hệ thống đạt mục tiêu kép: khớp cảm xúc (TE thấp, vượt mọi phương pháp nền thực) và nghe đồng nhất (độ nhất quán tăng

mạnh). Tuy nhiên, để diễn giải đúng mức ý nghĩa của chúng, cần nêu rõ các mối đe dọa tính hợp lệ theo ba nhóm thường dùng trong đánh giá hệ thống.

Hợp lệ về cấu trúc (construct validity) — liệu độ đo có đo đúng thứ cần đo. Sai số nhắm đích TE đo trên chính nhãn V-A được dùng để truy hồi, nên về bản chất là *tự tham chiếu*: nó kiểm tra hệ thống có truy hồi đúng theo định nghĩa của chính nó hay không, chứ chưa khẳng định nhãn V-A là “đúng” theo cảm nhận người. Đây là lý do đề án bổ sung các kiểm chứng *độc lập với nhãn*: tương quan với nhịp độ thật (cho trục Arousal của màu), khớp chuẩn ICEAS (cho trục Valence của màu), và chuyển miền sang PMemo (cho các đầu dò cảm xúc). Sự nhất quán giữa các kiểm chứng độc lập này làm tăng đáng kể độ tin cậy rằng nhãn V-A nắm bắt cảm xúc thật.

Nguyên tắc dùng dữ liệu nước ngoài. Một câu hỏi tự nhiên là vì sao có thể dùng các tập do con người gán nhãn ở nước ngoài (DEAM, EmoBank, PMemo, chuẩn màu ICEAS) cho một hệ thống nhạc Việt. Nguyên tắc xuyên suốt là dữ liệu nước ngoài chỉ được dùng ở những trục mà tín hiệu *không phụ thuộc ngôn ngữ*. Arousal được suy từ năng lượng âm thanh (nhịp độ, độ to, đặc trưng MuQ) — một bài nhanh và to mang năng lượng cao bất kể hát bằng tiếng nào — nên đầu dò huấn luyện trên DEAM (nhạc phương Tây) chuyển sang nhạc Việt là hợp lệ; tương tự, ánh xạ màu dựa trên tri giác màu của chuẩn ICEAS. Ngược lại, Valence *phụ thuộc nghĩa của lời* nên *không* được lấy chủ yếu từ dữ liệu nước ngoài: trong tổ hợp EWE, các tín hiệu lời chiếm $\approx 91\%$ trọng số, trong đó $\approx 57\%$ đến từ tài nguyên *tiếng Việt bản địa* (từ điển NRC-VAD-VN cùng VnEmoLex, và đầu dò ViSoBERT trên dữ liệu cảm xúc tiếng Việt) và $\approx 34\%$ từ EmoBank tiếng Anh được *chuyển ngữ* qua mô hình đa ngữ XLM-R; đầu dò âm thanh chỉ đóng góp $\approx 9\%$. Cách phân vai theo phương thức (âm thanh/tri giác dùng nguồn quốc tế, ngữ nghĩa lời dùng nguồn bản địa) chính là điều được kiểm chứng bằng phép đo nêu ở mục hợp lệ ngoại tại: nếu cố suy Valence từ âm thanh nước ngoài thì kết quả rất yếu ($R^2 \approx 0.06$).

Vì sao không tự gán nhãn cảm xúc cho kho nhạc Việt. Việc không xây một bộ nhãn cảm xúc do chính tác giả gán là một lựa chọn có chủ đích về phương pháp, không phải do thiếu dữ liệu. Thứ nhất, một bộ nhãn do *một người gán duy nhất* không có độ tin cậy liên-người-gán (inter-rater reliability) nên về mặt thống kê không cấu thành một ground truth đáng tin — nó chỉ phản ánh phán đoán của một cá nhân. Thứ hai, vì người gán cũng chính là người xây dựng hệ thống, nhãn tự gán có nguy cơ *thiên lệch xác nhận* (confirmation bias) khiến việc “kiểm chứng” trở thành lập luận vòng tròn. Thay vì tạo ra một chuẩn so yếu và dễ thiên lệch như vậy, đề án kiểm chứng nhãn bằng sự *hội tụ với nhiều tập do con người gán nhãn đã công bố và bình duyệt* (DEAM, PMemo cho âm thanh; ICEAS cho màu — mỗi

tập là phán đoán tổng hợp của hàng chục đến hàng trăm người gán độc lập) cùng một panel nhiều bộ chấm (mục 6.1.3); riêng Valence còn được đối chiếu với một bộ tham chiếu GPT-4o-mini đọc trực tiếp lời tiếng Việt ($\rho = 0.63$, mục 4.2.1). Sự nhất quán giữa các nguồn độc lập này là bằng chứng khách quan hơn so với một tập tự gán đơn lẻ. Việc xây dựng một bộ dữ liệu cảm xúc nhạc Việt có nhiều người gán và báo cáo độ tin liên-người-gán được để lại như một hướng phát triển (Chương 8).

Hợp lệ nội tại (internal validity) — liệu kết luận so sánh có vững. Việc so với năm phương pháp nền (trong đó có hai đường loại bỏ từng trục) kèm kiểm định Wilcoxon và hiệu chỉnh FDR bảo đảm cải thiện không phải do ngẫu nhiên; khoảng tin cậy bootstrap cho thấy độ ổn định của ước lượng. Riêng đường “lân cận V-A tham lam” là một trần lý thuyết (oracle) chứ không phải đối thủ công bằng, nên việc hệ thống tiệm cận nó (chứ không vượt) là kết quả mong đợi, cho thấy phần đa dạng hóa chỉ đánh đổi rất ít độ chính xác nhắm đích. Riêng với gợi ý bài tương tự, ground truth tương đồng âm nhạc còn được xác nhận bằng hai bộ chấm độc lập của hai nhà cung cấp ($\kappa = 0.958$, mục 6.1.3), nên kết luận so sánh không phải là tạo tác của một bộ chấm duy nhất; hạn chế còn lại là cỡ mẫu hạt giống ($n = 52$).

Hợp lệ ngoại tại (external validity) — liệu kết quả có tổng quát hóa. Đây là hạn chế lớn nhất: chưa có nghiên cứu nghe của người dùng thật (theo Dacrema và cộng sự, tương quan giữa độ đo ngoại tuyến và mức hài lòng thực tế chỉ vào khoảng $r \approx 0.28$), và ánh xạ màu–cảm xúc là ngoại suy từ dữ liệu quốc tế (Việt Nam không nằm trong khảo sát ICEAS gốc). Một hạn chế cụ thể của trục Valence là *chuyển giao yếu qua biên giới văn hóa*: trong phạm vi nhạc phương Tây, phép chuyển miền DEAM→PMEmo khá tốt ($\rho = 0.69$ cho Valence), nhưng khi áp đầu dò âm thanh huấn luyện trên DEAM sang nhạc Việt thì Valence rất yếu ($R^2 \approx 0.06$). Đây chính là lý do Valence được lấy chủ yếu từ các tín hiệu lời (phần lớn là tài nguyên tiếng Việt bản địa, phần còn lại là EmoBank tiếng Anh chuyển ngữ qua XLM-R; chi tiết phân vai và trọng số nêu ở phần hợp lệ cấu trúc trên) thay vì từ âm thanh nước ngoài — một lựa chọn đúng nhưng phụ thuộc chất lượng các tài nguyên đó và độ tốt của phép chuyển ngữ liên ngữ. Ngoài ra, do tương quan dương giữa Valence và Arousal trong kho nhạc, các góc phần tư lệch trục (“bình yên”: V cao–A thấp; “căng thẳng”: V thấp–A cao) thừa dữ liệu, khiến màu âm phải nhắm vào phần đuôi Arousal cao mông ($\approx 22\%$ kho nhạc) — đây là thuộc tính của dữ liệu. Chỉ số NDCG@10 biên tập tuyệt đối thấp (≈ 0.066) cũng cần đọc thận trọng: nó là đại diện gần đúng cho mức liên quan và còn bị một phương pháp nền theo độ phổ biến vượt qua (mục 6.1.3), nên chỉ phù hợp để tham khảo xu hướng chứ không khẳng định chất lượng tuyệt đối. Những hạn chế này được nêu lại và đề xuất hướng khắc phục ở Chương 8.

6.2 Thời gian phản hồi và triển khai

Hệ thống được triển khai thử nghiệm với pha ngoại tuyến chạy trước để sinh các đặc trưng và ma trận biểu diễn cho toàn bộ kho nhạc, sau đó động cơ gợi ý nạp các đặc trưng này vào bộ nhớ và phục vụ truy vấn qua giao diện lập trình ứng dụng cho ứng dụng trang đơn.

6.2.1 Thời gian phản hồi đo được


Vì mọi tính toán nặng đã thực hiện ở pha ngoại tuyến và không có mô hình nào được suy luận lúc phục vụ (nhấn cảm xúc đã đóng băng thành tra cứu), mỗi truy vấn chỉ gồm vài phép nhân ma trận trên ma trận 5138×1024 . Đo trực tiếp trong tiến trình trên một máy Apple Silicon bằng `tools/bench_latency.py` (1500 lần lặp, chưa tính thời gian mạng và tuần tự hóa JSON), kết quả như Bảng 6.8 và Hình 6.7: nạp động cơ lõi một lần chỉ mất vài giây (đo được khoảng 1–6 giây tùy bộ nhớ đệm; khởi động đầy đủ kèm bộ mã hóa tìm kiếm tùy chọn sẽ lâu hơn), còn mỗi truy vấn lúc phục vụ ở mức **vài mili-giây** (gợi ý theo một màu ≈ 3.1 ms, gợi ý bài tương tự ≈ 4.1 ms); hành trình hai màu nặng hơn (≈ 70 ms) do bước sắp xếp chuỗi cảm xúc. Đây là độ trễ tính toán lõi; độ trễ đầu cuối nhìn từ trình duyệt sẽ cao hơn do mạng và phát âm thanh.

Bảng 6.8: Thời gian phản hồi tính toán lõi (đo trong tiến trình, không gồm mạng)

Thao tác	Trung vị	p95
Nạp động cơ lõi (một lần, lúc khởi động)	$\approx 1\text{--}6$ s	—
Gợi ý theo một màu (UC02)	3.1 ms	3.6 ms
Gợi ý bài tương tự (UC01)	4.1 ms	4.5 ms
Hành trình hai màu	70 ms	72 ms

6.3 Kiểm thử chức năng hệ thống

Ngoài đánh giá mô hình, hệ thống còn được kiểm thử như một sản phẩm phần mềm. Bảng 6.9 tóm tắt các ca kiểm thử chính. Một phần được tự động hóa bằng `pytest` (`test/test_color_reco.py` kiểm tính hợp lệ cấu hình, ánh xạ 12 màu về đúng góc phần tư cảm xúc, đa dạng nghệ sĩ, tính đơn điệu của hành trình, độ trải Arousal; `test/test_endless_radio.py` kiểm hợp đồng loại trừ để chế độ “đài” không lặp), một phần được kiểm theo hợp đồng API và thủ công. Tổng cộng 37 ca kiểm thử tự động trong hai tệp cốt lõi này hiện đều đạt.



Hình 6.7: Thời gian phản hồi tính toán lỗi theo thao tác (thang log); truy vấn đơn ở mức vài mili-giây

Bảng 6.9: Các ca kiểm thử chức năng hệ thống

Mã	Mục tiêu	Kết quả mong đợi	Trạng thái
TC01	Chọn màu và nhận danh sách bài hát	Trả về ≥ 5 bài, V-A hợp lệ, đa dạng nghệ sĩ	Đạt (tự động)
TC02	Chọn bài và nhận bài tương tự	Trả về danh sách không chứa bài nguồn, đã loại cover	Đạt (tự động)
TC03	Xử lý mã màu không hợp lệ	Từ chối với lỗi xác thực đầu vào, không lỗi máy chủ	Đạt (hợp đồng API)
TC04	Xử lý bài không có lời	Trường lời rỗng, không gây lỗi	Đạt (hợp đồng API)
TC05	Xử lý bài không có đặc trưng	Trường tương ứng rỗng; lùi về tín hiệu còn lại	Đạt (hợp đồng API)
TC06	Kiểm tra thời gian phản hồi	Truy vấn đơn ở mức vài mili-giây	Đạt (mục 6.2.1)
TC07	Kiểm tra giao diện trên trình duyệt	Hai giao diện dựng và hoạt động	Đạt một phần (smoke; đa trình duyệt: hướng hoàn thiện)

Các kết quả đánh giá định lượng và kiểm thử trên là cơ sở để rút ra các giải pháp

và đóng góp nổi bật được phân tích ở chương tiếp theo.

CHƯƠNG 7. CÁC GIẢI PHÁP VÀ ĐÓNG GÓP NỔI BẬT

Chương này trình bày năm đóng góp nổi bật của đề án. Mỗi đóng góp được trình bày theo bốn phần: *bài toán* đặt ra, *giải pháp* đã thực hiện, *minh chứng* (kết quả) đạt được, và *giới hạn* của đóng góp, kèm phân tích ý nghĩa. Các chi tiết kỹ thuật và số liệu đã nêu ở các Chương 4–6 chỉ được tham chiếu lại, không lặp lại.

7.1 Quy trình gán tọa độ cảm xúc cho nhạc Việt trong điều kiện thiếu nhãn

Bài toán. Để gợi ý theo cảm xúc, mỗi bài hát cần một tọa độ cảm xúc có cơ sở và kiểm chứng được. Khó khăn đặc thù của nhạc Việt là *không tồn tại* tập dữ liệu cảm xúc âm nhạc tiếng Việt được con người gán nhãn để huấn luyện trực tiếp, trong khi các đặc trưng âm thanh thủ công lại nắm bắt Valence (vui–buồn) rất yếu. Việc tự đặt nhãn hoặc tinh chỉnh trên dữ liệu lệch miền dễ dẫn tới kết luận vòng tròn và khó bảo vệ về mặt khoa học.

Giải pháp. Đề án tách cảm xúc thành hai trục và gán mỗi trục bằng nguồn phù hợp nhất: Valence là tổ hợp **EWE phi vòng tròn** của bốn tín hiệu (ba tín hiệu lời có nguồn gốc công bố, một tín hiệu âm thanh bổ trợ; trọng số bằng độ tin cậy đo được nên không cần nhãn đích), còn Arousal là hồi quy trên tập DEAM kết hợp biểu diễn MuQ với nhịp độ và độ to. Toàn bộ mô hình dùng ở dạng đóng băng kèm đầu dò tuyến tính và không gọi mô hình ngôn ngữ lớn khi phục vụ; chi tiết tín hiệu, trọng số và công thức ở mục 4.2.1.

Minh chứng. Các đầu dò chuyển miền tốt sang PMEmo ($\rho = 0.69$ cho Valence, 0.65 cho Arousal) và Arousal bám nhịp độ thật ($\rho = 0.47$) (mục 6.1.3); quan trọng nhất, bộ nhãn *tái lập bit-cho-bit* ($\rho = 1.00$ khi chạy lại từ các tín hiệu nền) và đồng thuận với một bộ tham chiếu GPT độc lập ($\rho = 0.63$ cho Valence). Giá trị cốt lõi không nằm ở một con số chính xác hơn mà ở một *quy trình làm nhãn phi vòng tròn, truy nguồn được tới tài liệu gốc và tái lập được* — một khuôn mẫu cho bất kỳ miền ngôn ngữ nào thiếu dữ liệu nhãn, nơi tinh chỉnh hay nhờ mô hình ngôn ngữ lớn gán nhãn đều khó tái lập và khó bảo vệ.

Giới hạn. Quy trình vẫn phụ thuộc chất lượng của các tài nguyên lời tiếng Việt và độ tốt của phép chuyển ngữ liên ngữ; trục Valence chuyển giao yếu qua biên giới văn hóa khi suy từ âm thanh nước ngoài ($R^2 \approx 0.06$ trên nhạc Việt). Do chưa tồn tại nhãn cảm xúc nhạc Việt do người chấm, việc kiểm chứng mới dừng ở chuyển miền và một bộ tham chiếu độc lập, chưa phải đối chiếu trực tiếp với cảm nhận của người nghe Việt (mục 6.1.6).

7.2 Cơ chế ánh xạ màu sắc sang nhạc qua không gian Valence–Arousal

Bài toán. Cho phép người dùng chọn nhạc bằng *màu sắc* đòi hỏi đặt màu và nhạc lên cùng một thước đo có ý nghĩa. Quan hệ màu–nhạc ở con người không trực tiếp mà được *trung gian hóa bởi cảm xúc*, nên không thể ghép màu với nhạc một cách tùy tiện; các hệ thống trước đây thường ánh xạ thủ công và gắn với dữ liệu phương Tây.

Giải pháp. Đề án quy màu về cùng không gian Valence–Arousal với bài hát: màu được xử lý trong không gian tri giác Oklab, Valence hồi quy về chuẩn ICEAS, còn Arousal suy theo quan hệ màu–âm nhạc của Whiteford — chứ không phải chuẩn arousal màu khi *nhìn* (vốn coi màu đen là “mạnh”), một lựa chọn có chủ đích vì hệ ánh xạ màu sang nhạc (chi tiết ở mục 4.2.2). Nhờ đó màu trở thành một điểm trên *cùng mặt phẳng cảm xúc* với mọi bài hát, nên gợi ý theo màu và theo bài quy về cùng một phép truy hồi lân cận.


Minh chứng. Valence của màu khớp chuẩn ICEAS ($\rho = 0.969$) và công thức Arousal được kiểm *độc lập* bằng nhịp độ thật (ρ với độ bão hòa = 0.66); so khớp trong không gian phân vị nâng độ tách biệt giữa các màu từ 0.13 lên 0.31 (mục 6.1.2), khắc phục lỗi “chọn màu nào cũng giống nhau” khi nén bảng màu vào một vùng hẹp. Khác với các hệ màu→nhạc trước đây vốn dùng quy tắc thủ công riêng cho từng cặp màu–thuộc tính, đóng góp ở đây là dùng một không gian cảm xúc *học được, dùng chung* cho cả hai chức năng.

Giới hạn. Ánh xạ màu–cảm xúc dựa trên các chuẩn quốc tế (ICEAS, Whiteford) mà Việt Nam không nằm trong khảo sát gốc, nên *mang tính thử nghiệm* và chưa được hiệu chỉnh bằng khảo sát người nghe Việt; ngoài ra hệ chỉ dùng mười hai màu cố định (khoảng tin cậy rộng) và một số màu ám bị đọc là “năng lượng cao” có thể nghịch trực giác (mục 6.1.6).

7.3 Thuật toán truy hồi kết hợp khớp cảm xúc và nhất quán âm thanh

Bài toán. Chỉ khớp cảm xúc là chưa đủ: một danh sách có thể đúng tâm trạng nhưng nghe rời rạc vì các bài thuộc nhiều phong cách khác nhau. Hơn nữa, cosine thô trên biểu diễn học sâu bị thiên lệch dị hướng khiến độ tương đồng gần như mất nghĩa, làm hỏng cả việc đo “nghe giống” lẫn việc gom cụm nhất quán.

Giải pháp. Hệ thống chấm điểm cảm xúc bằng hàm Gauss dị hướng (tin Arousal hơn Valence), so khớp trong không gian phân vị, rồi *tăng nhất quán âm thanh* bằng cách chọn cụm ứng viên gần nhau trên biểu diễn MuQ *đã trừ trung bình* để khử dị hướng, kèm đa dạng hóa theo nghệ sĩ và loại cover/trùng (chi tiết ở mục 4.2.3). Việc trừ trung bình tuy nhỏ về tính toán nhưng có cơ sở lý thuyết vững là khử thành



Hình 7.1: Quy trình đánh giá nhiều tầng: mỗi tầng là một cấp kiểm chứng nghiêm ngặt hơn, trên cùng là cổng không thụ lùi quyết định việc chấp nhận thay đổi

phần trội chung của không gian embedding.

Minh chứng. Trừ trung bình nâng độ nhất quán âm thanh từ ≈ 0.02 lên 0.23 (hơn mười lần); hành trình hai màu đạt kiểm định $KS = 0.21$ và giảm độ chênh nhịp độ giữa các bước từ 31 xuống 2.7 BPM (mục 6.1.2); gợi ý bài tương tự đạt độ nhất quán tâm trạng ≈ 0.94 (mục 6.1.3). Mức cải thiện hơn mười lần cho thấy xử lý *dị hướng* — hiện tượng thường bị bỏ qua khi dùng cosine thô trên embedding — là một sửa lỗi căn bản chứ không phải tinh chỉnh thẩm mỹ; thêm nữa, việc cân bằng tường minh qua hệ số α cho hệ một “núm xoay” kiểm chứng được bằng phân tích độ nhảy.

Giới hạn. Các độ đo nhất quán (MoodCoherence, TempoCoherence) là độ đo *nội tại*, chưa được kiểm chứng bằng người nghe; thêm nữa, do tương quan dương giữa Valence và Arousal trong kho nhạc, các góc phần tư lệch trục thừa dữ liệu khiến một số vùng cảm xúc khó phủ đầy (mục 6.1.6).

7.4 Quy trình đánh giá nhiều tầng và khảo sát so sánh mô hình

Bài toán. Khi không có dữ liệu người dùng, rất dễ rơi vào đánh giá vòng tròn (chỉ so với chính nhãn của mình). Đồng thời, một mô hình “tốt nhất trên giấy” theo các bộ chuẩn quốc tế chưa chắc là lựa chọn tốt nhất cho nhiệm vụ cụ thể trên nhạc Việt.

Giải pháp. Đề án xây dựng một quy trình đánh giá nhiều tầng (Hình 7.1): từ độ đo nội tại, lên các kiểm chứng *độc lập với nhãn* (nhịp độ thật, chuẩn ICEAS, chuyển miền PMEmo), rồi so sánh với các phương pháp nền mạnh kèm kiểm định thống kê (Wilcoxon + hiệu chỉnh FDR, khoảng tin cậy bootstrap), và trên cùng là một *cổng không thụ lùi* trên độ đo cuối. Trên cùng tinh thần đó, đề án tiến hành một khảo sát so sánh nhiều mô hình tiên tiến, trong đó *mỗi ứng viên được tinh chỉnh siêu tham số riêng* trước khi so sánh và được phán quyết bằng độ đo cuối, không phải bằng thứ hạng trên bộ chuẩn (mục 6.1.4).

Minh chứng. Trên độ đo ngoại tuyến, hệ thống vượt cả bốn phương pháp nền

thực (p hiệu chỉnh = 0.00031); trong khảo sát trải trên năm vị trí mô hình (hơn mười ứng viên tiên tiến), chỉ embedding lời multilingual-e5-large được chấp nhận thay thế, còn lại giữ nguyên vì những ứng viên “tốt nhất trên giấy” không vượt được độ đo cuối (mục 6.1.4). Cấu trúc kim tự tháp này chính là tuyến phòng vệ chống *lập luận vòng tròn* khi đánh giá thiếu dữ liệu người dùng; nó cũng rút ra một bài học phương pháp luận có giá trị rộng: phải tinh chỉnh siêu tham số của *chính* thành phần mới rồi mới so sánh, vì “hòa hoặc kém ở thiết lập cũ” không đồng nghĩa với “thành phần mới không tốt hơn”.

Giới hạn. Toàn bộ là đánh giá *ngoại tuyến*: theo Dacrema và cộng sự, tương quan giữa độ đo ngoại tuyến và mức hài lòng thực tế chỉ vào khoảng $r \approx 0.28$; ground truth tương đồng do mô hình ngôn ngữ chấm (đã giảm rủi ro bằng đồng thuận hai bộ chấm) chứ chưa do người gán, và NDCG biên tập tuyệt đối thấp nên chỉ dùng tham khảo. Một nghiên cứu nghe với người dùng thật vẫn là kiểm chứng còn thiếu (Chương 8).

7.5 Hệ thống Brightify như một phần mềm demo hoàn chỉnh

Bài toán. Một đề án tốt nghiệp không chỉ là thuật toán mà còn phải là một phần mềm chạy được, phản hồi nhanh và không phụ thuộc dữ liệu người dùng.

Giải pháp. Đề án hiện thực Brightify theo kiến trúc hai pha (mục 4.1): pha ngoại tuyến tính sẵn mọi đặc trưng nặng cho 5.138 bài hát và lưu ra tệp (mục 5.2); pha phục vụ nạp các đặc trưng này vào bộ nhớ và đáp ứng truy vấn qua giao diện lập trình ứng dụng FastAPI (mục 5.3) cho một ứng dụng trang đơn có *hai giao diện* dùng chung logic gợi ý (mục 5.4). Việc tách hai pha là quyết định kiến trúc then chốt: nó biến mọi tính toán nặng (trích embedding, gán nhãn) thành công việc làm một lần ngoại tuyến, để pha phục vụ chỉ còn các phép đại số tuyến tính.

Minh chứng. Nhờ tách pha, mỗi truy vấn lúc phục vụ chỉ gồm vài phép nhân ma trận và hoàn tất trong *vài mili-giây* theo đo đạc thực tế (mục 6.2.1); hệ cũng vượt các ca kiểm thử chức năng chính, kể cả các trường hợp biên như màu không hợp lệ hay bài thiếu lời/đặc trưng (mục 6.3). Việc vật chất hóa toàn bộ tri thức nặng thành tệp đặc trưng tĩnh khiến kiến trúc hai pha trở thành một *khuôn mẫu* đáng tổng quát hóa cho hệ gợi ý dựa trên nội dung: chi phí phục vụ thấp (chỉ đại số tuyến tính trên CPU, không cần GPU), tính tất định tuyệt đối, và khả năng thay thế thành phần an toàn — đánh đổi là tính “tươi mới” phải chạy lại pha ngoại tuyến khi thêm nhạc.

Giới hạn. Brightify hiện là một *nguyên mẫu nghiên cứu* phi thương mại: dữ liệu nhạc có ràng buộc bản quyền (mục 5.2) nên chưa thể mở công khai như một dịch vụ; hệ thống chưa được kiểm thử ở tải đồng thời lớn; và do tách pha nên việc thêm nhạc mới đòi hỏi chạy lại pha ngoại tuyến (đánh đổi “tươi mới” lấy tốc độ và tính

tái lập).

7.6 Tổng hợp đóng góp và đối chiếu khoảng trống

Bảng 7.1 đối chiếu năm đóng góp với các khoảng trống đã nêu ở Chương 2, cho thấy mỗi đóng góp lấp một khoảng trống cụ thể và cùng nhau tạo nên một hệ thống gợi ý nhạc Việt theo cảm xúc có cơ sở khoa học, không phụ thuộc dữ liệu người dùng.

Nhìn tổng thể, năm đóng góp này không rời rạc mà tạo thành một chuỗi liên mạch: đóng góp thứ nhất tạo ra “nguyên liệu” là tọa độ cảm xúc có cơ sở cho mỗi bài; đóng góp thứ hai mở rộng cùng không gian cảm xúc đó sang màu sắc; đóng góp thứ ba là thuật toán biến tọa độ cảm xúc thành danh sách gợi ý chất lượng; đóng góp thứ tư là phương pháp luận giúp mọi quyết định kỹ thuật đều được kiểm chứng; và đóng góp thứ năm gói tất cả thành một sản phẩm chạy được. Điểm xuyên suốt là cam kết về *tính có thể kiểm chứng*: không có thành phần nào dựa trên trực giác hay con số tự đặt, mọi tín hiệu và trọng số đều truy nguồn được tới tài liệu công bố hoặc dữ liệu công khai, và toàn bộ quy trình tái lập được. Chính cam kết này, hơn là bất kỳ kỹ thuật đơn lẻ nào, là đặc trưng của đồ án.

Bảng 7.1: Đối chiếu đóng góp của đồ án với khoảng trống đã xác định

Đóng góp	Khoảng trống được lấp
Gán cảm xúc nhạc Việt thiếu nhân (5.1)	Không có tập cảm xúc nhạc Việt gán nhân người
Ánh xạ màu→nhạc qua V-A (5.2)	Hệ màu→nhạc cũ thủ công, gán dữ liệu phương Tây
Truy hồi khớp cảm xúc + nhất quán (5.3)	Khớp cảm xúc đơn thuần cho danh sách rời rạc; cosine dị hướng
Đánh giá nhiều tầng + bake-off (5.4)	Để đánh giá vòng tròn khi thiếu dữ liệu người dùng
Sản phẩm demo hai pha (5.5)	Cần một sản phẩm chạy được, nhanh, không cần dữ liệu người dùng

CHƯƠNG 8. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

8.1 Kết luận

Đồ án đã xây dựng được hệ thống Brightify — một hệ thống gợi ý nhạc Việt dựa trên cảm xúc với **hai chức năng chính**: gợi ý bài hát tương tự một bài cho trước, và gợi ý danh sách bài hát theo một (hoặc hai) màu sắc do người dùng chọn. Cả hai chức năng được thống nhất trên một không gian cảm xúc Valence–Arousal, cho phép màu và nhạc gặp nhau trên cùng hệ tọa độ.

Về mặt kỹ thuật, đồ án đã thiết kế một **kiến trúc hai pha offline/serving**: pha ngoại tuyến gán tọa độ cảm xúc, trích embedding âm thanh MuQ và tính sẵn mọi ma trận biểu diễn cho 5.138 bài hát; pha phục vụ chỉ thực hiện các phép nhân ma trận nên đáp ứng truy vấn trong vài mili-giây. Hệ thống được **đánh giá bằng nhiều tầng độ đo ngoại tuyến** có kiểm định thống kê (phương pháp nền mạnh, hiệu chỉnh FDR, khoảng tin cậy bootstrap) và các kiểm chứng độc lập (nhịp độ thật, chuẩn ICEAS, chuyển miền PMEmo), kèm một khảo sát so sánh mô hình để xác nhận mỗi thành phần là lựa chọn tốt theo độ đo cuối trong phạm vi các ứng viên đã khảo sát. So với các hệ thống gợi ý thương mại dựa trên lọc cộng tác, Brightify không phụ thuộc dữ liệu người dùng và cho phép truy vấn trực tiếp theo cảm xúc và theo màu — một hướng mà các nền tảng hiện có chưa hỗ trợ. Năm đóng góp nổi bật của đồ án đã được phân tích chi tiết ở Chương 7.

Để khẳng định mức hoàn thành một cách kiểm chứng được, Bảng 8.1 đối chiếu bốn mục tiêu kiểm chứng đặt ra ở mục 1.2 với mức đạt được và bằng chứng tương ứng. Cả bốn mục tiêu đều đạt, mỗi mục được hậu thuẫn bằng một số liệu cụ thể có thể tái lập ở Chương 6; điều này cho thấy đồ án không chỉ hoàn thành về mặt chức năng mà còn thể hiện được mức hoàn thành bằng các độ đo định lượng có thể tái lập.

Bảng 8.1: Đối chiếu mục tiêu đề ra (mục 1.2) với mức đạt được

Mục tiêu	Mức đạt	Bằng chứng (tham chiếu)
(i) Gán tọa độ V-A tái lập, có cơ sở khoa học	Đạt	Tái lập $\rho = 1.00$; hội tụ GPT độc lập $\rho = 0.63$ (mục 4.2.1)
(ii) Ánh xạ màu + truy hồi vượt phương pháp nền	Đạt	TE 0.0242, vượt 4/4 phương pháp nền thực, $p_{\text{FDR}} = 0.00031$ (mục 6.1.2)

Mục tiêu	Mức đạt	Bằng chứng (tham chiếu)
(iii) Kết quả nhất quán âm thanh	Đạt	MoodCoherence ≈ 0.94 ; nhất quán màu $0.02 \rightarrow 0.23$ (mục 6.1)
(iv) Thời gian phản hồi đủ thấp để tương tác	Đạt	3.1–4.1 ms mỗi truy vấn đơn (mục 6.2.1)

Nhìn lại toàn bộ quá trình, một đặc điểm xuyên suốt đáng để suy ngẫm là đồ án nhất quán *ưu tiên tính kiểm chứng được hơn là độ chính xác tối đa*. Trong bối cảnh nhiều hệ thống hiện nay nghiêng về việc dùng mô hình ngôn ngữ lớn cho hầu hết các khâu, đồ án chọn một hướng có phần ngược lại: mọi tín hiệu đều truy nguồn được tới tài liệu đã công bố, mọi trọng số đều kiểm chứng được bằng phân tích độ nhạy, mọi nhân đều tái lập được, và không có mô hình nào được suy luận lúc phục vụ. Lựa chọn này đánh đổi một phần độ chính xác tuyệt đối để có được một hệ thống minh bạch, nhẹ và dễ bảo vệ về mặt khoa học — điều đặc biệt phù hợp với một đồ án tốt nghiệp, nơi việc *hiểu và chứng minh được vì sao hệ thống hoạt động* quan trọng không kém việc nó hoạt động tốt. Đây cũng là tinh thần mà các hạn chế và hướng phát triển dưới đây được nhìn nhận.

8.2 Hạn chế

Bên cạnh những kết quả đạt được, đồ án còn một số hạn chế cần nêu thẳng. Thứ nhất, hệ thống *chưa có đánh giá người dùng thật*: mọi độ đo đều là proxy ngoại tuyến, và sai số nhắm đích (TE) mang tính tự tham chiếu, nên vẫn còn khoảng cách giữa kết quả ngoại tuyến và cảm nhận trực tuyến của người nghe. Thứ hai, do *chưa có tập nhạc Việt được con người gán nhãn cảm xúc*, tọa độ cảm xúc phải dựa trên chuyển miền và đầu dò tuyến tính thay vì nhãn bản địa; tuy đã kiểm chứng chuyển miền trên PMemo, đây vẫn là một ngoại suy. Thứ ba, *dữ liệu lời bài hát có thể nhiễu* vì được thu thập tự động (có thể sai chính tả hoặc lệch dòng), ảnh hưởng tới tín hiệu Valence. Thứ tư, *ánh xạ màu–cảm xúc còn phụ thuộc nghiên cứu quốc tế* (ICEAS, Whiteford): liên kết màu–cảm xúc có tính đặc thù văn hóa [48] và Việt Nam không nằm trong tập khảo sát gốc, nên việc áp dụng là ngoại suy. Thứ năm, hệ thống mới ở *mức demo, chưa triển khai production*: một số thông tin đã có ở API (tọa độ V-A dạng số, giải thích “vì sao được gợi ý”) chưa được dựng thành màn giao diện riêng, và phân kho nhạc còn thừa ở vùng năng lượng cao.

Cần nhấn mạnh rằng các hạn chế này phần lớn là hệ quả của những ràng buộc tự đặt ra một cách có chủ đích (không dùng dữ liệu người dùng, không tinh chỉnh mô hình, không dùng mô hình ngôn ngữ lớn khi phục vụ) chứ không phải thiếu sót

về thiết kế. Những ràng buộc đó đánh đổi một phần độ chính xác lấy tính tái lập, tính minh bạch khoa học và khả năng triển khai nhẹ. Trong một bối cảnh khác — chẳng hạn khi đã có dữ liệu người dùng và nhận cảm xúc bản địa — nhiều hạn chế trên có thể được nới lỏng, và đó chính là nội dung của phần hướng phát triển dưới đây.

8.3 Hướng phát triển

Để hoàn thiện và nâng cấp hệ thống, đề án đề xuất các hướng phát triển sau.

Trước hết là tổ chức một **khảo sát người dùng thật**: một nghiên cứu nghe có sự tham gia của người nghe sẽ kiểm chứng cảm nhận, thu hẹp khoảng cách giữa kết quả ngoại tuyến và trực tuyến, đồng thời tạo ra một bộ nhãn vàng có thể dùng làm chuẩn cho việc tinh chỉnh sau này. Đây là hướng quan trọng nhất vì nó giải quyết hạn chế cốt lõi về đánh giá. Một thiết kế khả thi là kiểm thử XAB so sánh cặp (cho người nghe một bài mở neo và hai ứng viên, hỏi bài nào “hợp cảm giác” hơn) trên một nhóm người tham gia, kèm thu thập đánh giá trực tiếp về độ phù hợp màu–nhạc; kết quả vừa cho một ước lượng tương quan offline–online cho chính hệ thống này, vừa tạo nền cho các bước cải thiện sau.

Một hướng nghiên cứu sâu hơn, bổ trợ cho khảo sát trên, là **xây dựng một bộ dữ liệu cảm xúc nhạc Việt có nhiều người gán nhãn**. Khác với việc một cá nhân tự gán (vốn không có độ tin cậy liên-người–gán và dễ thiên lệch xác nhận, như đã phân tích ở mục 6.1.6), một bộ dữ liệu với nhiều người gán độc lập trên trục Valence–Arousal và báo cáo độ tin cậy liên-người–gán (inter-rater reliability) sẽ là một chuẩn so bản địa thực sự — thứ hiện không tồn tại cho nhạc Việt. Bộ dữ liệu này không chỉ cho phép kiểm chứng trực tiếp (thay vì chỉ chuyển miền từ DEAM/PMemo) mà còn mở ra khả năng tinh chỉnh có giám sát một cách có cơ sở, và bản thân nó là một đóng góp có giá trị cho cộng đồng nghiên cứu MER tiếng Việt.

Tiếp theo là **mở rộng và cân bằng kho nhạc**: tăng số lượng và độ đa dạng bài hát, đặc biệt bổ sung vùng năng lượng cao còn thưa, để cải thiện việc nhắm đích cho các màu âm và bão hòa. Song song, cần **cải thiện xử lý lời bài hát**: làm sạch và căn dòng lời, xử lý bài thiếu lời tốt hơn, và bổ sung từ điển cảm xúc bản địa để giảm nhiễu cho tín hiệu Valence.

Về phía mô hình, hệ thống có thể **học từ phản hồi người nghe** bằng cách thu nhận tín hiệu ngầm (nghe hết, bỏ qua) và tường minh để tinh chỉnh trọng số, trong khuôn khổ bảo đảm riêng tư; và tiến tới **cá nhân hóa** bằng cách kết hợp gợi ý theo cảm xúc/màu với sở thích cá nhân, nhưng vẫn giữ khả năng truy vấn không cần dữ liệu người dùng làm mặc định.

Cuối cùng, về phía sản phẩm, cần **bổ sung giao diện giải thích khuyến nghị**: dựng màn chi tiết hiển thị tọa độ Valence–Arousal dạng số và bảng giải thích ngắn “vì sao bài được gợi ý” từ dữ liệu đã có ở API, giúp người dùng hiểu cơ sở của mỗi gợi ý và tăng độ tin cậy của hệ thống. Việc này không đòi hỏi thay đổi thuật toán mà chỉ là hiện thực hóa ở tầng giao diện những thông tin đã sẵn sàng.

TÀI LIỆU THAM KHẢO

- [1] S. E. Palmer, K. B. Schloss, Z. Xu, and L. R. Prado-León, “Music–color associations are mediated by emotion,” *Proceedings of the National Academy of Sciences*, vol. 110, no. 22, pp. 8836–8841, 2013. [Online]. Available: <https://doi.org/10.1073/pnas.1212562110>
- [2] J. A. Russell, “A circumplex model of affect,” *Journal of Personality and Social Psychology*, vol. 39, no. 6, pp. 1161–1178, 1980. [Online]. Available: <https://doi.org/10.1037/h0077714>
- [3] A. I. Schein, A. Popescul, L. H. Ungar, and D. M. Pennock, “Methods and metrics for cold-start recommendations,” in *Proceedings of the 25th Annual International ACM SIGIR Conference*, 2002, pp. 253–260. [Online]. Available: <https://doi.org/10.1145/564376.564421>
- [4] A. Aljanaki, Y.-H. Yang, and M. Soleymani, “Developing a benchmark for emotional analysis of music,” *PLoS ONE*, vol. 12, no. 3, e0173392, 2017. [Online]. Available: <https://doi.org/10.1371/journal.pone.0173392>
- [5] K. Zhang, H. Zhang, S. Li, C. Yang, and L. Sun, “The PMEmo dataset for music emotion recognition,” in *Proceedings of the 2018 ACM on International Conference on Multimedia Retrieval (ICMR)*, 2018, pp. 135–142. [Online]. Available: <https://doi.org/10.1145/3206025.3206037>
- [6] M. Pesek, G. Strle, A. Kavčič, and M. Marolt, “The Moodo dataset: Integrating user context with emotional and color perception of music for affective music information retrieval,” *Journal of New Music Research*, vol. 46, no. 3, pp. 246–260, 2017. [Online]. Available: <https://doi.org/10.1080/09298215.2017.1333518>
- [7] K. Kittimathaveenan, “Music recommendation based on color,” in *2020 6th International Conference on Engineering, Applied Sciences and Technology (ICEAST)*, 2020. [Online]. Available: <https://doi.org/10.1109/ICEAST50382.2020.9165455>
- [8] C. C. Aggarwal, *Recommender Systems: The Textbook*. Springer, 2016. [Online]. Available: <https://doi.org/10.1007/978-3-319-29659-3>
- [9] A. Kumar, A. Raghunathan, R. Jones, T. Ma, and P. Liang, “Fine-tuning can distort pretrained features and underperform out-of-distribution,” in *International Conference on Learning Representations (ICLR)*, 2022. [Online]. Available: <https://arxiv.org/abs/2202.10054>

- [10] H. Zhu et al., “MuQ: Self-supervised music representation learning with mel residual vector quantization,” *arXiv preprint arXiv:2501.01108*, 2025. [Online]. Available: <https://arxiv.org/abs/2501.01108>
- [11] D. Jonauskaite et al., “Universal patterns in color-emotion associations are further shaped by linguistic and geographic proximity,” *Psychological Science*, vol. 31, no. 10, pp. 1245–1260, 2020. [Online]. Available: <https://doi.org/10.1177/0956797620948810>
- [12] K. L. Whiteford, K. B. Schloss, N. E. Helwig, and S. E. Palmer, “Color, music, and emotion: Bach to the blues,” *i-Perception*, vol. 9, no. 6, 2018. [Online]. Available: <https://doi.org/10.1177/2041669518808535>
- [13] R. Burke, “Hybrid recommender systems: Survey and experiments,” *User Modeling and User-Adapted Interaction*, vol. 12, no. 4, pp. 331–370, 2002. [Online]. Available: <https://doi.org/10.1023/A:1021240730564>
- [14] Y.-H. Yang and H. H. Chen, “Machine recognition of music emotion: A review,” *ACM Transactions on Intelligent Systems and Technology*, vol. 3, no. 3, p. 40, 2012. [Online]. Available: <https://doi.org/10.1145/2168752.2168754>
- [15] H. Lee et al., “GlobalMood: A cross-cultural benchmark for music emotion recognition,” in *Proceedings of the 26th International Society for Music Information Retrieval Conference (ISMIR)*, 2025. [Online]. Available: <https://arxiv.org/abs/2505.09539>
- [16] S. Buechel and U. Hahn, “EmoBank: Studying the impact of annotation perspective and representation format on dimensional emotion analysis,” in *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics (EACL)*, 2017, pp. 578–585. [Online]. Available: <https://aclanthology.org/E17-2092/>
- [17] C. Spence, “Crossmodal correspondences: A tutorial review,” *Attention, Perception, & Psychophysics*, vol. 73, no. 4, pp. 971–995, 2011. [Online]. Available: <https://doi.org/10.3758/s13414-010-0073-7>
- [18] K. Järvelin and J. Kekäläinen, “Cumulated gain-based evaluation of IR techniques,” *ACM Transactions on Information Systems*, vol. 20, no. 4, pp. 422–446, 2002. [Online]. Available: <https://doi.org/10.1145/582415.582418>
- [19] H. Steck, “Calibrated recommendations,” in *Proceedings of the 12th ACM Conference on Recommender Systems (RecSys)*, 2018, pp. 154–162. [Online]. Available: <https://doi.org/10.1145/3240323.3240372>

- [20] M. Ferrari Dacrema, P. Cremonesi, and D. Jannach, “Are we really making much progress? a worrying analysis of recent neural recommendation approaches,” in *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys)*, 2019, pp. 101–109. [Online]. Available: <https://arxiv.org/abs/1907.06902>
- [21] R. E. Thayer, *The Biopsychology of Mood and Arousal*. Oxford University Press, 1989. [Online]. Available: <https://openlibrary.org/books/OL14959130M>
- [22] J. A. Russell and A. Mehrabian, “Evidence for a three-factor theory of emotions,” *Journal of Research in Personality*, vol. 11, no. 3, pp. 273–294, 1977. [Online]. Available: [https://doi.org/10.1016/0092-6566\(77\)90037-X](https://doi.org/10.1016/0092-6566(77)90037-X)
- [23] M. Zentner, D. Grandjean, and K. R. Scherer, “Emotions evoked by the sound of music: Characterization, classification, and measurement,” *Emotion*, vol. 8, no. 4, pp. 494–521, 2008. [Online]. Available: <https://doi.org/10.1037/1528-3542.8.4.494>
- [24] P. Ekman, “An argument for basic emotions,” *Cognition and Emotion*, vol. 6, no. 3-4, pp. 169–200, 1992. [Online]. Available: <https://doi.org/10.1080/02699939208411068>
- [25] B. Ottosson, *A perceptual color space for image processing (oklab)*, 2020. [Online]. Available: <https://bottosson.github.io/posts/oklab/>
- [26] P. Valdez and A. Mehrabian, “Effects of color on emotions,” *Journal of Experimental Psychology: General*, vol. 123, no. 4, pp. 394–409, 1994. [Online]. Available: <https://doi.org/10.1037/0096-3445.123.4.394>
- [27] Y. Li et al., “MERT: Acoustic music understanding model with large-scale self-supervised training,” *arXiv preprint arXiv:2306.00107*, 2023. [Online]. Available: <https://arxiv.org/abs/2306.00107>
- [28] R. Yuan et al., “MARBLE: Music audio representation benchmark for universal evaluation,” in *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2023. [Online]. Available: <https://arxiv.org/abs/2306.10548>
- [29] S. M. Mohammad, “Obtaining reliable human ratings of valence, arousal, and dominance for 20,000 English words,” in *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2018,

- pp. 174–185. [Online]. Available: <https://aclanthology.org/P18-1017/>
- [30] A. L. Doan and S. T. Luu, “Improving sentiment analysis by emotion lexicon approach on Vietnamese texts,” in *International Conference on Asian Language Processing (IALP)*, VnEmoLex lexicon, DOI 10.5281/zenodo.801610, 2022. [Online]. Available: <https://arxiv.org/abs/2210.02063>
- [31] N. Nguyen, T. C. Phan, D.-V. Nguyen, and K. V. Nguyen, “ViSoBERT: A pre-trained language model for Vietnamese social media text processing,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2023. [Online]. Available: <https://arxiv.org/abs/2310.11166>
- [32] V. A. Ho et al., “Emotion recognition for Vietnamese social media text,” in *Proceedings of the International Conference of the Pacific Association for Computational Linguistics (PACLING)*, 2020. [Online]. Available: <https://arxiv.org/abs/1911.09339>
- [33] A. Conneau et al., “Unsupervised cross-lingual representation learning at scale,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020, pp. 8440–8451. [Online]. Available: <https://aclanthology.org/2020.acl-main.747/>
- [34] D. Q. Nguyen and A. T. Nguyen, “PhoBERT: Pre-trained language models for Vietnamese,” in *Findings of the Association for Computational Linguistics: EMNLP 2020*, 2020, pp. 1037–1042. [Online]. Available: <https://aclanthology.org/2020.findings-emnlp.92/>
- [35] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, “Multilingual E5 text embeddings: A technical report,” *arXiv preprint arXiv:2402.05672*, 2024. [Online]. Available: <https://arxiv.org/abs/2402.05672>
- [36] K. V. Nguyen, V. D. Nguyen, P. X.-V. Nguyen, T. T.-H. Truong, and N. L.-T. Nguyen, “UIT-VSFC: Vietnamese students’ feedback corpus for sentiment analysis,” in *10th International Conference on Knowledge and Systems Engineering (KSE)*, 2018. [Online]. Available: <https://doi.org/10.1109/KSE.2018.8573337>
- [37] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence embeddings using Siamese BERT-networks,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, 2019. [Online]. Available: <https://arxiv.org/abs/1908.10084>

- [38] V. T. Dang, *Vietnamese-embedding: A Simcse sentence-embedding model for Vietnamese*, 2024. [Online]. Available: <https://huggingface.co/dangvantuan/vietnamese-embedding>
- [39] T. Baltrušaitis, C. Ahuja, and L.-P. Morency, “Multimodal machine learning: A survey and taxonomy,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 2, pp. 423–443, 2019. [Online]. Available: <https://doi.org/10.1109/TPAMI.2018.2798607>
- [40] M. Grimm and K. Kroschel, “Evaluation of natural emotions using self assessment manikins,” in *IEEE Workshop on Automatic Speech Recognition and Understanding (ASRU)*, 2005, pp. 381–385. [Online]. Available: <https://doi.org/10.1109/ASRU.2005.1566530>
- [41] K. Ethayarajh, “How contextual are contextualized word representations? comparing the geometry of BERT, ELMo, and GPT-2 embeddings,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, 2019. [Online]. Available: <https://aclanthology.org/D19-1006/>
- [42] J. Mu, S. Bhat, and P. Viswanath, “All-but-the-top: Simple and effective postprocessing for word representations,” in *International Conference on Learning Representations (ICLR)*, 2018. [Online]. Available: <https://arxiv.org/abs/1702.01417>
- [43] J. Carbonell and J. Goldstein, “The use of MMR, diversity-based reranking for reordering documents and producing summaries,” in *Proceedings of the 21st Annual International ACM SIGIR Conference*, 1998, pp. 335–336. [Online]. Available: <https://doi.org/10.1145/290941.291025>
- [44] I. M. Altshuler, “A psychiatrist’s experiences with music as a therapeutic agent,” in *Music and Medicine*, D. M. Schullian and M. Schoen, Eds., Henry Schuman, New York, 1948, pp. 266–281. [Online]. Available: <https://openlibrary.org/works/OL34619214W>
- [45] K. Starcke, R. von Georgi, et al., “Emotion modulation through music after sadness induction—the iso principle in a controlled experimental study,” *International Journal of Environmental Research and Public Health*, vol. 18, no. 23, 2021. [Online]. Available: <https://doi.org/10.3390/ijerph182312486>
- [46] B. Berlin and P. Kay, *Basic Color Terms: Their Universality and Evolution*. University of California Press, 1969. [Online]. Available: <https://archive.org/details/basiccolortermst0000berl>

- [47] Y. Benjamini and Y. Hochberg, “Controlling the false discovery rate: A practical and powerful approach to multiple testing,” *Journal of the Royal Statistical Society: Series B*, vol. 57, no. 1, pp. 289–300, 1995. [Online]. Available: <https://doi.org/10.1111/j.2517-6161.1995.tb02031.x>
- [48] D. Jonauskaite et al., “A machine learning approach to quantify the specificity of colour–emotion associations and their cultural differences,” *Royal Society Open Science*, vol. 6, no. 9, p. 190741, 2019. [Online]. Available: <https://doi.org/10.1098/rsos.190741>
- [49] Y. Wu et al., “Large-scale contrastive language-audio pretraining with feature fusion and keyword-to-caption augmentation,” in *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2023. [Online]. Available: <https://arxiv.org/abs/2211.06687>